

UNIVERSIDAD

Maestría en Ciencia de Datos

Trabajo de Grado


Predicción de propiedades mecánicas de aceros con
distintas composiciones y tratamientos térmicos mediante
modelos de aprendizaje automático

María Claudia Gamboa Castañeda

El presente documento avala la entrega del trabajo de grado por parte del director y codirector.
Documentos anexos: copia digital del Trabajo de Grado (1).

Firma Director
Director:

Firma Codirector
Codirector:



Firma Estudiante
Estudiante

© Únicamente se puede usar el contenido de las publicaciones para propósitos de información. No se debe copiar, enviar, recortar, transmitir o redistribuir este material para propósitos comerciales sin la autorización de la Escuela Colombiana de Ingeniería. Cuando se use el material de la Escuela se debe incluir la siguiente nota "Derechos reservados a Escuela Colombiana de Ingeniería" en cualquier copia en un lugar visible. Y el material no se debe notificar sin el permiso de la Escuela.

Publicado en 2013 por la Escuela Colombiana de Ingeniería Julio Garavito. Avenida 13 No 205-59
Bogotá D.C., Colombia
TEL: +57 – 1 668 36 00

Abril 10, 2026

Agradecimientos

Quiero expresar mi más profundo agradecimiento a mis padres, quienes han sido el pilar fundamental en mi formación personal y académica. Su apoyo incondicional, su confianza constante y sus enseñanzas han sido parte clave para alcanzar este logro. Gracias por acompañarme en cada etapa, por motivarme en los momentos difíciles y por creer en mí incluso cuando el camino se tornaba desafiante. Este trabajo es también el resultado de su esfuerzo, amor y dedicación.

De igual manera, agradezco sinceramente a mi directora de tesis, Johanna Esguerra, por su orientación, paciencia y compromiso durante el desarrollo de este proyecto. Su acompañamiento constante, sus valiosos aportes y su dedicación fueron fundamentales para la construcción y consolidación de este trabajo. Gracias por compartir su conocimiento, por guiarme en cada etapa del proceso y por su disposición para resolver dudas y brindar apoyo académico de manera continua.

Resumen

Este proyecto tuvo como objetivo seleccionar el mejor modelo de aprendizaje automático capaz de predecir las propiedades mecánicas de los aceros con diferentes composiciones químicas y tratamientos térmicos, en particular la resistencia a la tracción, el límite elástico, la elongación, el módulo de elasticidad y el módulo de corte. La investigación parte de una revisión exhaustiva del comportamiento mecánico del acero frente a distintos procesos de temple, revenido, normalizado y recocido, así como sobre la influencia de elementos de aleación como el carbono, manganeso, cromo y níquel. Para el entrenamiento y validación de los modelos, se emplea un conjunto de datos obtenido de fuentes experimentales reportadas en literatura académica y bases de datos especializadas, como kaggle y publicaciones indexadas en ScienceDirect, SpringerLink, Scielo y demás revistas científicas, que contienen registros de propiedades mecánicas vinculadas a composiciones específicas y condiciones térmicas controladas. Esta propuesta busca a futuro predecir el límite elástico de nuevas aleaciones de aceros sometidas a los diferentes tratamientos térmicos teniendo las características evaluadas de otras aleaciones anteriormente para optimizar el diseño y selección de aceros empleados en aplicaciones industriales, médicas y demás, reduciendo el costo y el tiempo requeridos para caracterizaciones físicas mediante ensayos convencionales.

La investigación se sustenta en la metodología CRISP-DM, que guiará el proceso desde la comprensión de los datos hasta la evaluación y validación del modelo predictivo. Este enfoque busca optimizar la selección y diseño de aceros, reduciendo el tiempo y los costos asociados a ensayos físicos tradicionales y promoviendo la adopción de técnicas avanzadas de ciencia de datos en el campo de la ingeniería de materiales.

Adicionalmente, se evidenció que los resultados de esta investigación contribuyen en cierto grado al desarrollo de metodologías innovadoras en el área de la informática de materiales, lo que permitió la generación de modelos predictivos aplicables a otros tipos de aleaciones de aceros según su composición química para determinar las propiedades mecánicas anteriormente mencionadas. Asimismo, el proyecto aportó evidencia de la viabilidad del uso de técnicas de machine learning y análisis de datos avanzados como herramientas de apoyo en la industria, potenciando procesos de diseño de materiales más eficientes, sostenibles y económicos. Finalmente, se ha avanzado en la publicación de los hallazgos en una revista indexada (aproximadamente en un 30%), contribuyendo así al avance del conocimiento científico en ingeniería de materiales y ciencia de datos.

Abstract

This project aimed to select the best machine learning model capable of predicting the mechanical properties of steels with different chemical compositions and heat treatments, particularly tensile strength, yield strength, elongation, Young's modulus, and shear modulus. The research is based on a comprehensive review of the mechanical behavior of steel under various processes such as quenching, tempering, normalizing, and annealing, as well as the influence of alloying elements such as carbon, manganese, chromium, and nickel. For training and validating the models, a dataset was used, obtained from experimental sources reported in academic literature and specialized databases such as Kaggle and indexed publications in ScienceDirect, SpringerLink, Scielo, and

other scientific journals, which contain records of mechanical properties linked to specific compositions and controlled thermal conditions. This proposal aims, in the future, to predict the yield strength of new steel alloys subjected to different heat treatments, using the evaluated characteristics of previously studied alloys, in order to optimize the design and selection of steels used in industrial, medical, and other applications, reducing the cost and time required for physical characterization through conventional testing.

The research is supported by the CRISP-DM methodology, which guides the process from data understanding to the evaluation and validation of the predictive model. This approach seeks to optimize steel selection and design, reducing the time and costs associated with traditional physical testing, while promoting the adoption of advanced data science techniques in the field of materials engineering.

Additionally, it was evidenced that the results of this research contribute, to some extent, to the development of innovative methodologies in the field of materials informatics, enabling the generation of predictive models applicable to other types of steel alloys based on their chemical composition to determine the aforementioned mechanical properties. Likewise, the project provided evidence of the feasibility of using machine learning techniques and advanced data analysis as support tools in the industry, enhancing more efficient, sustainable, and cost-effective material design processes. Finally, progress has been made toward publishing the findings in an indexed journal (approximately 30% completed), thus contributing to the advancement of scientific knowledge in materials engineering and data science.

Tabla de contenidos

1 Introducción	1
1.1 Problemática (Justificación)	1
1.1.1 Alcance del problema	1
1.1.2 Literatura existente y vacíos	2
1.1.3 Preguntas de investigación	2
1.2 Objetivos y pregunta de investigación	3
1.2.1 Pregunta de investigación	3
1.2.2 Objetivo general	3
1.2.3 Objetivos específicos	3
1.3 Alcance y Limitaciones	3
1.4 Metodología	4
1.5 Resultados esperados	5
2 Revisión de la literatura	7
2.1 Aceros	7
2.2 Machine learning	9
2.2.1 Random Forest	9
2.2.2 XG Boost	10
2.2.3 Redes neuronales artificiales	11
2.2.4 Métricas de evaluación	12
2.3 La ciencia de datos en la ciencia de los materiales	12
2.4 Dataset: Materials and their Mechanical Properties	13
3 Metodología	15
3.1 Comprensión del tema	15
3.2 Comprensión de los datos	16
3.3 Preparación de los datos	16
3.3.1 Dataset original	16
3.3.2 Dataset sintéticos	16
3.4 Modelado	17
3.5 Evaluación	18
4 Resultados	20
4.1 Limpieza y aplicación de filtros	20
4.2 Análisis exploratorio de datos (EDA)	21
4.3 Preparación de los datos	26
4.4 Resultados de los modelos	27

4.4.1 Su - Resistencia última a la tracción	27
4.4.2 Sy - Límite elástico	29
4.4.3 A5 - Elongación	31
4.4.4 E - Módulo de elasticidad y G - módulo de corte	32
4.5 Caso de prueba	34
5 Análisis de resultados	36
5.1 Configuraciones y métricas	36
5.2 Desempeño de los modelos para cada propiedad	37
5.3 Caso de prueba	38
6 Conclusiones	40
Bibliografía	41
Abreviaciones	43
Apéndices	44

Lista de Figuras

Figura 1	Proceso CRISP-DM	5
Figura 2	Funcionamiento de random forest	10
Figura 3	Funcionamiento del XG Boost	11
Figura 4	Funcionamiento de las redes neuronales	11
Figura 5	Cronograma del proyecto	15
Figura 6	Tipos de datos	21
Figura 7	Cantidad de datos faltantes	21
Figura 8	Estadística descriptiva	22
Figura 9	Distribución de variables numéricas	23
Figura 10	Boxplot para cada variable	23
Figura 11	Matriz de correlación	24
Figura 12	Conteo de tratamientos térmicos	25

Lista de Tablas

Tabla 1	Variables del dataset original	14
Tabla 2	Dataset sintético	17
Tabla 3	Estructura de la tabla original	20
Tabla 4	Dataset original preparado	27
Tabla 5	Dataset completo	27
Tabla 6	Resultados de Su para la primera configuración	28
Tabla 7	Resultados de Su para la segunda configuración	28
Tabla 8	Resultados de Su para la tercera configuración	29
Tabla 9	Resultados de Sy para la primera configuración	30
Tabla 10	Resultados de Sy para la segunda configuración	30
Tabla 11	Resultados de Sy para la tercera configuración	30
Tabla 12	Resultados de A5 para la primera configuración	31
Tabla 13	Resultados de A5 para la segunda configuración	32

Tabla 14	Resultados de A5 para la tercera configuración	32
Tabla 15	Resultados de E para la segunda configuración	33
Tabla 16	Resultados de G para la segunda configuración	33
Tabla 17	Resultados de la ecuación error configuración	34
Tabla 18	Caso de prueba 1	35
Tabla 18	Caso de prueba 2	35

1 Introducción

1.1 Problemática (Justificación)

La predicción precisa de las propiedades mecánicas de aceros con distintas composiciones y tratamientos térmicos representa un avance significativo en el diseño, desarrollo y optimización de materiales para aplicaciones industriales, biomédicas, estructurales y demás. Los métodos tradicionales de caracterización, aunque fiables, requieren la fabricación de probetas, la realización de ensayos exhaustivos y el uso de equipos especializados, lo que se traduce en altos costos y largos periodos de tiempo para la obtención de resultados. Esta situación limita la capacidad de innovación en la creación de nuevas aleaciones y retrasa los procesos de selección de materiales para aplicaciones específicas.

El uso de técnicas de aprendizaje automático ofrece una alternativa eficiente y precisa para predecir la propiedad de límite elástico a partir de datos previamente obtenidos de estudios experimentales. Con bases de datos consolidadas, como la disponible en Kaggle y complementada con información académica, es posible entrenar modelos predictivos capaces de generalizar el comportamiento mecánico de nuevas aleaciones sin necesidad de realizar ensayos físicos en cada caso.

Además, este enfoque contribuye a la sostenibilidad de los procesos de investigación y desarrollo de materiales, reduciendo el consumo de recursos y el impacto ambiental asociado a la experimentación. También favorece la adopción de metodologías de informática de materiales, alineando la investigación con tendencias actuales en ingeniería y ciencia de datos. En este sentido, el proyecto no solo responde a una necesidad técnica, sino que también aporta valor científico y práctico, con potencial de aplicación en la industria metalúrgica, biomédica y manufacturera, y con la posibilidad de publicar los resultados en revistas indexadas, fortaleciendo la producción académica en esta área emergente.

1.1.1 Alcance del problema

El diseño y la selección de aceros adecuados para aplicaciones industriales, estructurales, biomédicas y demás, dependen directamente de la comprensión de sus propiedades mecánicas, las cuales están determinadas por su composición química y los tratamientos térmicos aplicados. Sin embargo, los métodos tradicionales de caracterización como los ensayos de tracción, dureza, fatiga y demás, son costosos, requieren tiempo y demandan equipos especializados, lo que limita la rapidez con la que pueden desarrollarse o evaluarse nuevas aleaciones.

En un contexto donde la industria metalúrgica busca optimizar tiempos y costos sin comprometer la calidad, surge la necesidad de métodos alternativos que permitan predecir el comportamiento mecánico de los aceros a partir de información preexistente y datos experimentales disponibles. El alcance del problema se centra en la brecha entre la disponibilidad de grandes volúmenes de datos experimentales sobre aceros y la capacidad actual de analizarlos de manera eficiente para generar modelos predictivos útiles y generalizables.

Aunque existen numerosas investigaciones experimentales sobre la relación entre composición, tratamiento térmico y propiedades mecánicas, aún es limitada la integración de estos datos dentro de

enfoques sistemáticos basados en ciencia de datos y aprendizaje automático. Por ello, el problema adquiere relevancia tanto científica como tecnológica, ya que la implementación de modelos predictivos confiables puede reducir significativamente el número de pruebas físicas requeridas, acelerar la innovación en el diseño de materiales y fortalecer la competitividad industrial mediante el aprovechamiento inteligente de la información disponible.

1.1.2 Literatura existente y vacíos

La literatura reciente evidencia un creciente interés en la aplicación de técnicas de aprendizaje automático para la predicción de propiedades mecánicas en aceros y otras aleaciones metálicas. Diversos estudios han demostrado el potencial de algoritmos como Random Forest, Support Vector Machines y Redes Neuronales Artificiales para estimar parámetros como la resistencia a la tracción, la dureza y el módulo elástico a partir de datos experimentales. Por ejemplo, (Xiong et al., 2020) desarrollaron un modelo de aprendizaje automático para predecir las propiedades de aceros al carbono, identificando que la composición y el tratamiento térmico son los factores más determinantes en la predicción de resistencia y dureza. De igual forma, (Zippo et al., 2025) diseñaron un sistema actualizable que integra modelos predictivos en una planta siderúrgica, optimizando la producción y reduciendo el desperdicio de material. Otros trabajos, como los de (Peng et al., 2020; Stoll & Benner, 2021), han destacado la incorporación de principios físicos en los modelos de predicción para mejorar su interpretación y precisión, consolidando el campo de la informática de materiales.

No obstante, a pesar de estos avances, persisten vacíos significativos en la literatura. En primer lugar, la mayoría de los estudios se centra en datasets experimentales específicos y limitados, lo que restringe la generalización de los modelos a nuevos tipos de aceros o condiciones de tratamiento térmico. En segundo lugar, se observa una escasa documentación sobre la comparación sistemática del desempeño de distintos algoritmos bajo un mismo conjunto de datos, lo que dificulta determinar cuál modelo ofrece la mejor capacidad predictiva y estabilidad. Finalmente, pocos trabajos abordan la validación cruzada de los modelos con datos externos o la evaluación de su aplicabilidad práctica en entornos industriales. En este contexto, la presente investigación busca contribuir al cierre de estos vacíos mediante el desarrollo y la comparación de diferentes modelos de aprendizaje automático aplicados a un conjunto de datos público, con el propósito de establecer un marco metodológico reproducible y transferible para la predicción de propiedades mecánicas de aceros en distintos escenarios de ingeniería.

1.1.3 Preguntas de investigación

La pregunta de investigación puede redactarse según diferentes perspectivas que se puedan tener dentro de la redacción de los objetivos, la justificación y demás apartados.

Para enfocar la pregunta hacia un enfoque metodológico, se planteó la siguiente: ¿Cuál es la metodología más adecuada para integrar datos de composición química, tratamiento térmico y propiedades mecánicas en un modelo de aprendizaje automático que permita generar predicciones confiables y generalizables? Sin embargo, esta pregunta no resuelve lo que principalmente se quiere lograr con el presente trabajo.

La pregunta enfocada a las diferentes aplicaciones puede ser la siguiente: ¿De qué manera el uso de técnicas de machine learning puede contribuir a reducir el tiempo y el costo asociados a la caracterización experimental de aceros en procesos industriales? No obstante, esta pregunta resuelve solo una parte del problema principal de investigación.

Lo que da paso al planteamiento de la pregunta de investigación que abarca todo el problema de investigación, donde se plasman los objetivos, la cual se presenta en el apartado 1.2.1.

1.2 Objetivos y pregunta de investigación

1.2.1 Pregunta de investigación

¿Qué modelos de aprendizaje automático presentan el mejor desempeño para predecir propiedades mecánicas como resistencia a la tracción, límite elástico, elongación, módulo de elasticidad y módulo de corte en aceros con diferentes composiciones y tratamientos térmicos?

1.2.2 Objetivo general

Desarrollar un modelo de aprendizaje automático para predecir las propiedades mecánicas de aceros con distintas composiciones químicas y tratamientos térmicos, a partir de datos experimentales disponibles y sintéticos, con el fin de optimizar el diseño, selección y caracterización de los mismos sin depender exclusivamente de ensayos experimentales.

1.2.3 Objetivos específicos

1. Analizar y procesar el conjunto de datos de aceros con diferentes composiciones y tratamientos térmicos para identificar las variables más relevantes en la predicción de propiedades mecánicas.
2. Implementar y comparar distintos modelos de aprendizaje automático supervisado para predecir propiedades como límite elástico, resistencia a la tracción y módulo de elasticidad.
3. Evaluar el desempeño de los modelos desarrollados mediante métricas estadísticas y validar su capacidad predictiva sobre nuevas aleaciones para garantizar su aplicabilidad en contextos reales de ingeniería de materiales.

1.3 Alcance y Limitaciones

El presente trabajo de investigación se enfoca en el desarrollo, entrenamiento y validación de modelos de aprendizaje automático para la predicción de propiedades mecánicas de diferentes aleaciones de aceros, específicamente la resistencia última a la tracción, el límite elástico y la elongación a partir de su composición química, tratamiento térmico y otras características presentes en el dataset. El estudio se fundamenta en el análisis de un conjunto de datos experimentales disponible públicamente (*Materials and Their Mechanical Properties*, 2023), (*Material Science | News | Materials Engineering | News*, s/f) que contiene información sobre la composición química, los tratamientos térmicos aplicados y las propiedades resultantes de distintas aleaciones. El proyecto se enmarca dentro de la metodología CRISP-DM, abarcando las fases de comprensión del problema, procesamiento de datos, modelado, evaluación y documentación de resultados.

Su alcance comprende la comparación de diferentes algoritmos de aprendizaje supervisado (Random Forest, aumento de gradiente extremo y redes neuronales) con el propósito de identificar el modelo que ofrezca el mejor desempeño predictivo y la mayor capacidad de generalización.

El alcance del proyecto no incluye la obtención experimental de nuevos datos ni la caracterización física o metalográfica de materiales, ya que el trabajo se sustenta exclusivamente en información previamente publicada y validada por fuentes académicas y experimentales. Por tanto, las conclusiones derivadas estarán limitadas por la calidad, tamaño y representatividad del conjunto de datos utilizado. Asimismo, las predicciones del modelo se restringen al rango de composiciones químicas y tratamientos térmicos presentes en dicho dataset, por lo que su extrapolación a aceros o condiciones no representadas debe realizarse con precaución.

Otro aspecto limitante radica en que no se consideran factores microestructurales detallados (como tamaño de grano, fases secundarias o inclusiones), los cuales también influyen en el comportamiento mecánico del material. Finalmente, si bien el modelo pretende alcanzar alta precisión y aplicabilidad práctica, su validación industrial requerirá ensayos físicos complementarios para confirmar los resultados y garantizar su implementación en contextos reales de ingeniería.

1.4 Metodología

Para el desarrollo de este proyecto, se implementó una metodología denominada Proceso Estándar de Inter-Industrias para Minería de Datos con siglas CRISP-DM (del inglés *Cross- Industry Standard Process for Data Mining*) la cual es una de las principales metodologías para el desarrollo de nuevos proyectos relacionados con minería de datos o características similares ya que es una de las metodologías que ha tenido más apoyo de las empresas privadas y organismos públicos (Cortina & Galán, s/f).

Esta metodología consta de diferentes etapas. En la fase de comprensión del negocio, se define el objetivo principal: predecir propiedades mecánicas de aceros a partir de su composición y tratamiento térmico, lo cual tiene implicaciones directas en la optimización de procesos industriales. En la etapa de comprensión de los datos, se explora el dataset seleccionado desde Kaggle, identificando las variables disponibles, su significado técnico y su relación con las propiedades mecánicas de interés. Posteriormente, en la fase de preparación de los datos, se limpiarán, transformarán y seleccionarán las variables pertinentes, gestionando valores faltantes y codificando adecuadamente las características categóricas y numéricas, y se desarrollarán otras variables que también pueden ser muy útiles para el entrenamiento de los modelos. En la etapa de modelado, se aplicarán algoritmos de aprendizaje automático, ajustando sus hiperparámetros para lograr mejores predicciones. La fase de evaluación implica comparar modelos con métricas como RMSE, MAPE y R^2 para seleccionar el más eficaz. Finalmente, en la etapa de despliegue, se documentaron los resultados y se planteó un posible sistema de predicción como herramienta de apoyo para ingenieros de materiales en futuras aplicaciones. Esta metodología garantiza un enfoque sistemático y reproducible en todo el ciclo de desarrollo del modelo predictivo.




Figura 1. Proceso CRISP-DM

1.5 Resultados esperados

Se espera obtener un modelo de aprendizaje automático confiable y validado para cada propiedad mecánica de interés que permita predecir con alta precisión las propiedades mecánicas fundamentales de los aceros, más específicamente la resistencia última a la tracción, el límite elástico y la elongación, a partir de su composición química, tratamiento térmico y otras

propiedades mecánicas. Este modelo deberá evidenciar una relación clara entre los elementos de aleación (por ejemplo, carbono, cromo, manganeso y níquel) y las respuestas mecánicas resultantes, proporcionando información útil para optimizar la formulación y selección de aceros en distintas aplicaciones industriales. De esta manera, el estudio busca demostrar que el uso de técnicas de machine learning puede reducir la necesidad de ensayos experimentales extensos, disminuyendo costos, tiempo y recursos en los procesos de diseño de materiales.

Adicionalmente, se espera identificar las variables más influyentes en la predicción de cada propiedad mecánica, lo cual permitirá generar conocimiento interpretativo y aplicable dentro del campo de la ingeniería de materiales. La comparación entre diversos modelos supervisados como Random Forest, redes neuronales, entre otros, permitirá determinar cuál ofrece el mejor desempeño predictivo bajo métricas estadísticas robustas (R^2 , RMSE, MAPE). Este análisis también contribuirá a establecer criterios de selección de modelos aplicables a otras aleaciones metálicas.

Finalmente, se proyecta que los resultados de esta investigación sirvan como base para la elaboración y publicación de un artículo científico en una revista indexada, fortaleciendo la producción académica en el área de informática de materiales y demostrando la relevancia del aprendizaje automático en la caracterización y optimización de materiales metálicos. A largo plazo, los hallazgos podrán contribuir al desarrollo de sistemas inteligentes de apoyo a la toma de decisiones en la industria metalúrgica y de manufactura, promoviendo prácticas más sostenibles, eficientes y orientadas a la innovación tecnológica.

2 Revisión de la literatura

Para abordar toda la temática que se encuentra en el desarrollo de este proyecto, se realizó el acercamiento a los aceros y sus aleaciones, la relación entre la ciencia de datos y el mundo de los materiales y realizar un análisis exhaustivo del dataset y los trabajos relacionados a la misma.

2.1 Aceros

El acero es una aleación metálica principalmente compuesta por hierro y carbono, con la adición de diversos elementos aleantes que permiten modificar y optimizar sus propiedades mecánicas. Dependiendo de su composición química y de los tratamientos térmicos aplicados, el acero puede presentar variaciones significativas en características como dureza, resistencia a la tracción, módulo de elasticidad, ductilidad, tenacidad y resistencia a la fatiga. Estas propiedades son fundamentales para determinar su idoneidad en aplicaciones industriales, biomédicas y estructurales. (Jr & Rethwisch, 2020).

Los aceros constituyen uno de los materiales más utilizados en ingeniería debido a su versatilidad y capacidad de adaptación a diferentes aplicaciones mediante modificaciones en su composición química y procesamiento térmico. Desde el punto de vista metalúrgico, los aceros se clasifican principalmente en aceros al carbono, aceros aleados y aceros inoxidables, dependiendo de la cantidad y tipo de elementos aleantes presentes como lo son el cromo, níquel, molibdeno y manganeso, que son los más comunes, o el fósforo, azufre o silicio en menor proporción. Los aceros se clasifican principalmente según su contenido de carbono y elementos aleantes, lo que determina sus propiedades mecánicas base. Entre los tipos comunes están los aceros al carbono (bajo, medio y alto), aceros aleados de baja templabilidad (series SAE 4000, 5000), intermedia (SAE 4300, 4400) y alta (SAE 4800, 9300), además de aceros de gran resistencia. (Monsalve, 2023).

Los elementos aleantes son aquellos que se adicionan al acero con el propósito de modificar y mejorar sus propiedades mecánicas, físicas y químicas, permitiendo ajustar el material a requerimientos específicos de la industria. Estos desempeñan un papel fundamental en la determinación del comportamiento mecánico de los aceros, ya que influyen directamente en la microestructura del material. Entre los más utilizados se encuentran el cromo, níquel, molibdeno, vanadio y manganeso, los cuales influyen en la dureza, resistencia a la tracción, tenacidad, resistencia a la corrosión y estabilidad a altas temperaturas. (*Effect of nutrient-based alloying elements on biodegradable magnesium alloys: Evolution, challenges, and strategies for orthopaedic applications* - ScienceDirect, s/f; Jr & Rethwisch, 2020). Por ejemplo, el cromo y el níquel son esenciales en la fabricación de aceros inoxidables utilizados en la industria biomédica y alimentaria debido a su resistencia a la corrosión, mientras que el molibdeno mejora el comportamiento a altas temperaturas, lo cual es crítico en aplicaciones aeroespaciales y petroquímicas. El manganeso, por su parte, incrementa la templabilidad y la resistencia al impacto, siendo ampliamente usado en la industria automotriz y en maquinaria pesada. (Ghali, 2021; Kako et al., 2002). Adicionalmente, a

nivel microestructural se ha demostrado que la combinación de estos elementos puede modificar la formación de fases como ferrita, perlita, bainita y martensita, las cuales determinan propiedades clave como la ductilidad, la resistencia y la dureza. (Dong et al., 2023).

Por otro lado, los tratamientos térmicos representan una de las herramientas más importantes para ajustar las propiedades mecánicas de los aceros sin modificar su composición química y transformando la microestructura de los aceros. Procesos como el recocido, normalizado, temple y revenido permiten controlar la transformación de fases y el tamaño de grano, afectando directamente las propiedades mecánicas. (Bhat et al., 2021).

Para el desarrollo de la presente investigación, se empleó el dataset “*Materials and their Mechanical Properties*”, para el cual se identifican múltiples tratamientos térmicos con diferentes condiciones en procesos clásicos y variantes específicas. El tratamiento normalizado (*Normalized*) consiste en calentar el acero por encima de su temperatura crítica y enfriarlo al aire, lo que permite obtener una microestructura más uniforme y de grano fino, mejorando la tenacidad del material. También se tiene el tratamiento recocido (*Annealed*), el cual implica un calentamiento seguido de un enfriamiento lento dentro del horno, con el objetivo de ablandar el material, eliminar tensiones internas y facilitar procesos posteriores como el mecanizado. Dentro del mismo existen variantes como recocido o revenido alto (*Annealing or high tempering*) que combinan efectos de ablandamiento y estabilización estructural, reduciendo la dureza y aumentando la ductilidad. (Orlando & David et al., 2017).

Uno de los tratamientos más importantes es el temple (*Quenching*), presente en formas como temple y enfriamiento en aceite (*Quenching and cooling in the oil*) o temple y enfriamiento en agua (*Quenching and cooling in the water*). Este proceso consiste en calentar el acero hasta la región de austenita y enfriarlo rápidamente para formar martensita, una fase dura y resistente. El medio de enfriamiento influye directamente en la velocidad de enfriamiento y, por tanto, en la microestructura final: el agua genera enfriamientos más rápidos que el aceite, produciendo mayor dureza pero también mayor riesgo de fragilidad. (Pérez-Ruiz et al., 2019). Así mismo, el acero suele someterse a revenido (*tempering*), como en templado y revenido (*Quenched and tempered*) o con condiciones específicas como 400°F, 600°F u 800°F. El revenido reduce la fragilidad inducida por el temple, alivia tensiones internas y mejora la tenacidad del material.

Adicionalmente, el dataset incluye condiciones como cementado o endurecimiento superficial (*Case-hardened*) y cementado seguido de temple en aceite (*Case-hardening, quenching and cooling in the oil*), que corresponden a tratamientos termoquímicos en los cuales se modifica la composición química de la superficie del material, generalmente aumentando el contenido de carbono para obtener una capa superficial dura y resistente al desgaste, manteniendo un núcleo más dúctil. También se identifican estados del material asociados al proceso de fabricación, como laminado en caliente (*As-rolled*), que corresponde al material sin tratamiento térmico posterior, y trabajo en frío (*Cold working*), en el cual el material es deformado plásticamente a temperatura ambiente, generando endurecimiento por deformación. Asimismo, aparecen condiciones como completamente

endurecido (*Full-hard*) y fracciones como Hard-1/4, Hard-1/2, Hard-3/4, que representan distintos niveles de endurecimiento del material, usualmente asociados a tratamientos de deformación o procesamiento industrial. (Monsalve, 2022).

Finalmente, se incluyen estados más generales como tratado térmicamente (*Heat treated*) y mejorado (*Improved*), los cuales indican que el material ha sido sometido a algún proceso térmico, aunque sin especificar el detalle del mismo. También aparece la condición *Quenching and heating*, que sugiere ciclos térmicos combinados, posiblemente asociados a procesos industriales más complejos.

2.2 Machine learning

El aprendizaje automático (*machine learning*) es una rama de la inteligencia artificial que permite a los sistemas desarrollar algoritmos capaces de aprender patrones a partir de datos para hacer predicciones o tomar decisiones sin ser programados explícitamente para cada tarea. En lugar de seguir reglas fijas, los modelos se entrenan con datos históricos para identificar relaciones entre variables y realizar predicciones sobre nuevos datos. Este enfoque se ha convertido en una herramienta fundamental en el modelado predictivo, ya que, en lugar de depender de reglas fijas, estos modelos identifican relaciones entre variables de entrada y una variable objetivo, por lo que son especialmente útiles cuando el fenómeno es complejo, multivariable o no lineal. En problemas de regresión, como la predicción de propiedades mecánicas de aceros, Machine Learning permite relacionar composición química, tratamientos térmicos y condiciones de procesamiento con respuestas a las propiedades mecánicas, facilitando la predicción de comportamientos sin recurrir exclusivamente a ensayos experimentales. (Ali et al., 2025; Janiesch et al., 2021; Wang, 2025).

En términos metodológicos, el proceso suele incluir preparación de datos, selección de variables, entrenamiento del modelo, validación y evaluación con métricas de desempeño. La calidad del modelo depende tanto del algoritmo como de la calidad y representatividad de los datos, por lo que la validación cruzada y el ajuste de hiperparámetros son etapas críticas en investigaciones aplicadas. Esto significa que el aprendizaje automático aplicado en la investigación sirve tanto para predecir como para identificar qué variables tienen mayor peso en el comportamiento mecánico del acero. (Wang, 2025). Dentro de este estudio se emplearon tres modelos de aprendizaje automático: Random Forest, XG Boost y redes neuronales artificiales, cada uno con características particulares.

2.2.1 Random Forest

Este es un modelo de aprendizaje supervisado que combina múltiples árboles de decisión contruidos sobre subconjuntos aleatorios de los datos y de las variables. El modelo Random Forest se puede emplear para 2 diferentes propósitos, la clasificación o la regresión, sin embargo, la esencia sigue siendo la misma. Su funcionamiento se basa en generar múltiples modelos simples,

llamados árboles, en donde cada árbol aprende una parte del patrón y, para la regresión, se promedia la salida de todos los árboles, y para la clasificación se usa la votación mayoritaria. Esta lógica de ensamble reduce la varianza del modelo y lo hace más robusto frente al sobreajuste que un árbol individual. (Dutta et al., 2021; Gustafsson, 2019; Song, 2023).

Este modelo es útil cuando existen relaciones no lineales, interacciones complejas entre variables y ruido en los datos, porque puede capturar estructuras difíciles de representar con modelos lineales. En investigaciones de materiales, Random Forest suele funcionar bien cuando la composición química y el tratamiento térmico interactúan de forma no trivial, porque no exige supuestos estrictos sobre la forma de la relación entre variables. (Gustafsson, 2019)




Figura 2. Funcionamiento de random forest

2.2.2 XG Boost

El aumento de gradiente extremo (*Extreme Gradient Boosting*), más conocido como XG Boost, es un modelo basado en técnicas de boostig que construye árboles de manera secuencial, donde cada nuevo árbol intenta corregir los errores del conjunto anterior. Adicionalmente, XG Boost ha sido ampliamente reconocido en la literatura por su eficiencia computacional y su capacidad para manejar grandes volúmenes de datos y relaciones no lineales complejas ya que este aprende de forma iterativa para minimizar una función de pérdida mediante gradiente descendente y regularización. Esa combinación de secuencialidad y regularización suele darle muy buen desempeño en datos tabulares, especialmente cuando hay relaciones complejas y no lineales. (Chen & Guestrin, 2016; Gustafsson, 2019; Onyebueke et al., 2023).

Este modelo es bueno cuando se busca alta precisión predictiva en conjuntos de datos estructurados, como bases experimentales de materiales con variables de composición, temperatura, tiempo de tratamiento o condición mecánica. Su ventaja principal es que suele capturar patrones sutiles mejor que modelos más simples, aunque puede ser más sensible al ajuste de hiperparámetros y al riesgo de sobreajuste si no se valida correctamente. (Gustafsson, 2019; Onyebueke et al., 2023).




Figura 3. Funcionamiento del XG Boost

2.2.3 Redes neuronales artificiales

Las redes neuronales son modelos inspirados en el funcionamiento y la estructura del cerebro que consisten en capas de nodos conectados que procesan la información de manera jerárquica. Estas redes son capaces de modelar relaciones altamente no lineales y complejas entre variables ya que durante el entrenamiento, el modelo ajusta esos pesos para reducir el error entre predicción y valor real mediante retropropagación y optimización numérica, siendo especialmente útiles en problemas donde existen interacciones difíciles de representar mediante modelos tradicionales. Sin embargo, su desempeño depende en gran medida de la cantidad y calidad de los datos disponibles, y pueden ser más sensibles a problemas como el sobreajuste o la falta de información representativa. Son especialmente útiles cuando la relación entre composición, proceso y propiedad no puede describirse bien con funciones simples. Sin embargo, suelen requerir más datos, más cuidado en la normalización de variables y más control del sobreajuste que modelos como Random Forest o XG Boost. (Gustafsson, 2019; Wang, 2025)




Figura 4. Funcionamiento de las redes neuronales

2.2.4 Métricas de evaluación

Para evaluar el desempeño de los diferentes modelos, se emplean métricas de regresión ampliamente utilizadas en la literatura, como R^2 , MAE, RMSE y MAPE. El coeficiente de determinación (R^2) mide la proporción de la variabilidad de la característica objetivo que es explicada por el modelo. Su valor suele interpretarse entre 0 y 1, donde valores cercanos a 1 indican mejor ajuste, aunque también puede ser negativo si el modelo predice peor que usar el promedio de los datos observados. Se calcula como $R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$, donde SS_{res} es la suma de errores cuadrados del modelo y SS_{tot} es la variabilidad total de los datos. Sin embargo, un R^2 cercano a 1 no garantiza por sí solo que el modelo sea bueno ya que no informa el tamaño real del error. (Botchkarev, 2018; Chicco et al., 2021).

El error absoluto medio (MAE), mide el promedio de las diferencias absolutas entre valores reales y predichos siendo una métrica fácil de interpretar al interpretar su valor directamente en las mismas unidades de la variable objetivo. se calcula como $MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$, y cuanto menor sea, mejor es el modelo. (Botchkarev, 2018; Chicco et al., 2021).

El RMSE, o raíz del error cuadrático medio, penaliza más los errores grandes porque eleva al cuadrado las desviaciones antes de promediarlas; luego aplica raíz cuadrada para volver a las mismas unidades de la variable objetivo y se calcula $RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$, y también se considera que el modelo es mejor cuanto menor sea su valor. (Botchkarev, 2018; Chicco et al., 2021).

Por último, se tiene el error porcentual absoluto medio (MAPE), el cual expresa el error promedio en porcentaje respecto al valor real. Este se calcula como $MAPE = \frac{100}{n} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right|$, por lo que resulta útil para comunicar el error de forma intuitiva. (Botchkarev, 2018; Chicco et al., 2021). Su limitación principal es que se vuelve problemático cuando hay valores reales cercanos a cero, ya que el denominador puede inflar artificialmente el error. (Botchkarev, 2018; Chicco et al., 2021).

2.3 La ciencia de datos en la ciencia de los materiales

La aplicación del aprendizaje automático en el dominio de los materiales metálicos ha emergido como una línea de investigación muy prometedora, en la cual se busca modelar las relaciones complejas entre composición química, microestructura, procesamiento y propiedades mecánicas. Por ejemplo, en el estudio de (Xiong et al., 2020), se analizaron 360 muestras de aceros al carbono y de baja aleación, utilizando cinco algoritmos de machine learning para predecir propiedades como

resistencia a la tracción, fatiga y dureza. Los autores identificaron que el modelo Random Forest fue el que mejor desempeño presentó, y además detectaron que la temperatura de revenido y los elementos de aleación carbono, cromo y molibdeno fueron las variables más influyentes en las propiedades mecánicas de los aceros. Este trabajo demuestra la viabilidad de los enfoques de la informática de materiales (*materials informatics*) para avanzar en el diseño de aceros, reduciendo la dependencia exclusiva de ensayos experimentales tradicionales.

Asimismo, investigaciones más recientes amplían el alcance y refinan la metodología, empleando composición, procesamiento, microestructura, defectos y condiciones extremas como la temperatura elevada. En la investigación llevada a cabo por Shaheen, se puede reflejar el desarrollo de modelos supervisados capaces de estimar resistencia a la fluencia, módulo de elasticidad y esfuerzo máximo para aceros de alta resistencia bajo temperaturas elevadas, alcanzando una precisión significativamente alta. (Shaheen et al., 2022). De igual forma, la revisión realizada por Frydrych, Karimi, Pecelerowicz, Alvarez, Dominguez-Gutiérrez, Rovaris y Papanikolaou, aborda cómo los métodos de regresión y clasificación se han utilizado para predecir propiedades mecánicas a partir de grandes volúmenes de datos experimentales o simulados, destacando que el mayor reto está en la calidad de los datos, la integración de microestructura y la interpretabilidad del modelo. (Frydrych et al., 2021). Tales avances posicionan al aprendizaje automático no sólo como herramienta predictiva, sino también como vía para descubrir relaciones de causalidad y optimizar el diseño de materiales hacia resultados más rápidos, eficientes y menos costosos.

Cuando se tienen suficientes datos, se pueden desarrollar modelos para la detección de reglas físicas como lo son las propiedades mecánicas de los materiales, ya que una computadora es capaz de determinar las leyes físicas que conducen a los datos dados sin entrada humana. Esto es posible gracias a que los enfoques de aprendizaje automático aprenden las reglas que subyacen a un conjunto de datos evaluando una parte de esos datos y construyendo un modelo para hacer predicciones, sin embargo, para que esta tarea tenga buenos resultados, el ser humano debe elegir y/o diseñar correctamente modelos de aprendizaje de máquina adecuados que representen correctamente los datos. (Stoll & Benner, 2021).

2.4 Dataset: Materials and their Mechanical Properties

Para conocer más a fondo el dataset, se realizó una búsqueda exhaustiva sobre la misma. El dataset “*Materials and their Mechanical Properties*” encontrada en (*Materials and Their Mechanical Properties*, s/f-b), fue publicado el 15 de abril del 2023 por Purushottam Nawale. Este dataset recopila propiedades mecánicas de distintos materiales con composiciones químicas variadas, incluyendo aleaciones metálicas, polímeros, cerámicas, entre otros.

El dataset tiene un tamaño de ~142 KB y una cantidad de registros suficiente para explorar relaciones entre composiciones, condiciones, origen y propiedades mecánicas. Está estructurada en

dos archivos CSV que incluyen variables de entrada como lo son la composición, tratamiento, clase de material, entre otros y variables de salida que representan las propiedades mecánicas.

El primer archivo CSV llamado “data.csv”, se encuentran las siguientes variables

1	STD	Estándar de referencia
2	ID	Identificador único de material
3	Material	Nombre del material
4	Heat treatment	Tratamiento térmico aplicado
5	Su	Resistencia última a la tracción (MPa)
6	Sy	Límite elástico (MPa)
7	A5	Elongación (%)
8	Bhn	Dureza Brinell (BHN)
9	E	Módulo de elasticidad (MPa)
10	G	Módulo de corte (MPa)
11	mu	Coefficiente de Poisson
12	Ro	Densidad (Kg/m3)
13	pH	Presión en el límite elástico
14	Desc	Descripción adicional del material
15	HV	Dureza Vickers

Tabla 1. Variables del dataset original

3 Metodología

Esta sección es crucial ya que describe el proceso de investigación paso a paso y permite a otros reproducir el estudio y validar las conclusiones. Esta sección está basada en la estructura del cronograma (figura 5), donde se muestra el paso a paso de las actividades necesarias para el desarrollo de la misma. A su vez, el cronograma está elaborado bajo los parámetros de la metodología CRISP-DM, lo que permite construir el modelo predictivo de forma ordenada, clara y fácil de replicar.

		Mes	Mes 1				Mes 2				Mes 3				Mes 4				Mes 5				Mes 6				Mes 7				Mes 8			
		Semana	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4				
Comprensión del negocio/tema	Item	Descripción (numeral tabla contenido)																																
	1	Definir el objetivo de predicción y sus aplicaciones industriales	x	x																														
	2	Revisar bibliografía sobre aceros y tratamientos térmicos	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x			
	3	Reuniones con tutores para validar alcance	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x			
Comprensión de los datos	4	Revisión profunda del dataset de Kaggle					x	x	x	x																								
	5	Identificación de variables clave (inputs y outputs)						x	x																									
	6	Análisis exploratorio (distribuciones, correlaciones, outliers)					x	x	x	x																								
Preparación de los datos	7	Limpieza de datos nulos o inconsistentes							x	x	x								x	x	x													
	8	Transformaciones necesarias (escalado, codificación)							x	x	x	x																						
	9	División del dataset en entrenamiento, validación y prueba											x																					
Modelado	10	Selección de algoritmos adecuados											x	x																				
	11	Entrenamiento de modelos													x	x	x	x	x															
	12	Evaluación de métricas (R², MAE, RMSE)															x	x	x	x														
	13	Ajuste de hiperparámetros																x	x	x														
Evaluación	14	Comparación entre modelos																	x	x	x													
	15	Validación cruzada																		x	x													
	16	Interpretación de resultados (importancia de variables)																				x	x											
	17	Análisis de errores																				x	x											
Despliegue	18	Documentación del proceso y resultados					x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x	x				
	19	Redacción del trabajo de grado																							x	x	x	x						
	20	Desarrollo de conclusiones y recomendaciones																											x	x				
	21	Presentación final (defensa)																												x				

Figura 5. Cronograma del proyecto

El desarrollo de toda la sección técnica (limpieza, filtros, modelado, obtención de resultados y demás) se llevó a cabo en el entorno de Google Colab con el lenguaje de programación Python y con el apoyo de las diferentes bibliotecas de análisis de datos , visualización, modelado y demás que se mencionarán en los siguientes apartados.

3.1 Comprensión del tema

Iniciando con la fase de comprensión del tema, se definieron los objetivos relacionados con la predicción de las propiedades mecánicas de los aceros y su importancia en el contexto industrial, académico y de ingeniería de materiales, junto con la revisión bibliográfica complementaria.

Adicionalmente, esta fase incluye la delimitación del alcance y la formulación de la pregunta de investigación. Igualmente, a lo largo del desarrollo del proyecto, se ha realizado una recopilación y revisión bibliográfica constantes que son cruciales para fundamentar las decisiones técnicas para asegurar que el enfoque adoptado esté respaldado por evidencia científica.

3.2 Comprensión de los datos

La fase de comprensión de los datos tuvo diferentes retos. En primera instancia, se realizó una exploración del dataset para identificar su estructura, calidad, origen y consistencia. En este se encontraron múltiples valores faltantes, los cuales se eliminaron del dataset al igual que las columnas no relevantes. El número de muestras se redujo significativamente, sin embargo, no se encontró un dataset o una base de datos similar para complementar la anterior.

En esta fase se identificaron las variables clave asociadas a la composición química, los tratamientos térmicos y las propiedades mecánicas de los aceros, lo cual ayudó más adelante a establecer las características con mayor influencia en el desarrollo de modelos de machine learning.

Para entender más a fondo el dataset, se realizó un análisis exploratorio profundo de los datos (EDA), generando visualizaciones, estadísticas descriptivas y evaluaciones preliminares que ayudaron a identificar patrones, anomalías y relaciones entre las diferentes variables.

3.3 Preparación de los datos

El proceso de la preparación de los datos se basó en la aplicación de diferentes filtros y la creación de datos sintéticos según la literatura para complementar aún mejor el dataset original.

3.3.1 Dataset original

El dataset original viene con materiales como cerámicos, siliconas y otros metales que no se querían incluir en el desarrollo del proyecto, así que el primer filtro aplicado permitió dejar en la tabla solo los aceros. Seguido esto, se encontró que el dataset contenía columnas prácticamente vacías que no aportaban datos significativos al desarrollo del proyecto, por lo que se tomó la decisión de eliminar dichas columnas utilizando las librerías NumPy y Pandas. El último factor que se tuvo en cuenta fueron los datos faltantes de la columna de “Heat treatment”, la cual contiene la información de los tratamientos térmicos de cada una de las aleaciones. Esta es una de las columnas más importantes para el desarrollo de los modelos, por lo cual se eliminan las filas con valores faltantes en la misma. Al momento de realizar el análisis exploratorio de datos (EDA), también se emplean librerías como NumPy y Pandas para realizar ciertos análisis previos y se utilizan librerías como Seaborn y Matplotlib para desarrollar temas de visualización de datos y obtener un mejor panorama del dataset original.

3.3.2 Dataset sintéticos

Posterior a la filtración y limpieza del dataset original, se puso como desafío realizar los modelos con algunas propiedades mecánicas y composiciones químicas de las distintas aleaciones de acero junto con su respectivo tratamiento térmico. Para llevar esto a la práctica, se desarrolló un dataset

sintético con el objetivo de complementar la información existente y mejorar las variables de entrada de los modelos de machine learning. Para esto se llevó a cabo una investigación profunda de información metalúrgica y técnica en fuentes académicas e industriales especializadas, como los sitios web AZoM (Material Science | News | Materials Engineering | News, s/f) y Materiales Gelson Luz (Materiales (ES), s/f), en los que se determinaron las proporciones usuales de composición química (porcentaje en peso) de elementos aleantes importantes como carbono (C), manganeso (Mn), silicio (Si), cromo (Cr), níquel (Ni), entre otros vinculados con cada aleación de acero registrada en la base. Conforme a las proporciones, se establecieron límites mínimos y máximos para cada elemento químico en función de la aleación, asegurando la consistencia con los textos metalúrgicos y las regulaciones técnicas vinculadas a los aceros explorados.

Posteriormente, utilizando scripts y funciones desarrollados en Python en el entorno Google Colab, se produjeron valores aleatorios controlados dentro de esos intervalos, garantizando que las composiciones sintéticas sean físicamente creíbles y que reflejen adecuadamente la conducta real de los materiales. Este procedimiento posibilitó extender el conjunto de datos mientras se conservaba la consistencia metalúrgica, disminuir inconvenientes de falta de información química y hacer más sencillo el entrenamiento de modelos predictivos más sólidos, sin incluir combinaciones químicamente inviables o irreales.

El dataset construido consta de los diferentes elementos aleantes presentes en los diferentes tipos de acero, como se muestra en la tabla 2.

	C	Mn	P	S	Si	Ni	Cr	Mo	Fe	Aleacion
0	0.649107	1.093896	0.011472	0.328900	0.338481	0.0	0.0	0.0	97.578144	Steel 25ChS GOST 4543-71
1	0.661561	0.952008	0.033726	0.190987	0.247611	0.0	0.0	0.0	97.914108	Steel 25ChS GOST 4543-71
2	0.664959	1.163877	0.007215	0.254978	0.283318	0.0	0.0	0.0	97.625653	Steel 25ChS GOST 4543-71
3	0.640359	1.151906	0.028972	0.011105	0.201182	0.0	0.0	0.0	97.966475	Steel 25ChS GOST 4543-71
4	0.686116	1.194729	0.008613	0.177742	0.195787	0.0	0.0	0.0	97.737013	Steel 25ChS GOST 4543-71

Tabla 2. Dataset sintético

Finalmente, se combinaron las propiedades mecánicas y las variables de proceso filtradas con el dataset sintético. Luego, antes de ser empleada en los procesos de modelación y evaluación, fue sometida a validaciones elementales como la verificación de rangos, la coherencia estadística y la no presencia de valores incoherentes. Esta táctica logró optimizar la habilidad de generalización de los modelos y reforzar el enfoque de ciencia de datos en la predicción del comportamiento mecánico de los aceros.

3.4 Modelado

En la fase de modelado, se llevaron a cabo tres métodos de aprendizaje automático supervisado orientados a la predicción de propiedades mecánicas de las aleaciones de aceros basándose en sus atributos físico-químicos y de proceso. Los modelos escogidos posibilitaron el análisis desde relaciones lineales sencillas hasta patrones no lineales complejos que aparecen en los datos. Esta selección responde a la necesidad de comparar modelos con diferentes niveles de complejidad y capacidad de generalización y analizar su rendimiento utilizando un conjunto idéntico de variables de entrada para predecir las mismas propiedades mecánicas.

El proceso de elección de las variables predictoras requirió de varios ensayos con los tres modelos. Principalmente se tomaron las composiciones químicas sintéticas en las cuales están los porcentajes de carbono (C), manganeso (Mn), fósforo (P), azufre (S), silicio (Si), níquel (Ni), cromo (Cr), molibdeno (Mo) y hierro (Fe) y también por defecto se tomó el tratamiento térmico (Heat treatment) codificado a través de métodos de one-hot encoding. Por otro lado, se hicieron varias pruebas para determinar qué otras características ayudaban al desempeño del modelo, ya que el objetivo principal es la reducción de costos. Se encontró que lo más óptimo era incluir la dureza Brinell (Bhn) y la densidad (RO) en las variables de entrada del modelo.

A diferencia de un enfoque multisalida, en este proyecto se desarrollaron modelos independientes para cada propiedad mecánica objetivo, permitiendo analizar de forma específica el desempeño predictivo para cada una de las propiedades. Las variables de salida del modelo fueron la resistencia última a la tracción (S_u), el límite elástico (S_y) y la elongación al 5% (A_5). Esta perspectiva permite evaluar la capacidad del modelo para capturar las relaciones particulares entre las variables de entrada y cada respuesta mecánica.

Como se mencionó anteriormente, para el modelado se implementaron tres algoritmos con diferentes niveles de complejidad en los cuales están el Random Forest, XG Boost y una red neuronal artificial de tipo MLP Regressor para los cuales se emplearon las bibliotecas de modelado Scikit-learn y xgboost que permitieron importar los estimadores RandomForestRegressor, XGBRegressor y MLPRegressor respectivamente. El Random Forest se escogió por su solidez ante el ruido y las correlaciones entre variables, su habilidad para modelar relaciones no lineales y su óptimo rendimiento en datos tabulares. El XG Boost, que se basa en métodos de boosting sobre árboles de decisión, se empleó por su eficiencia al optimizar modelos complejos y por su gran capacidad para realizar predicciones. Por último, se utilizó una red neuronal artificial de arquitectura multicapa (MLP) para capturar patrones no lineales y potenciales interacciones complejas entre la composición química, el tratamiento térmico y las propiedades resultantes.

3.5 Evaluación

Una vez los modelos fueron entrenados con conjuntos de entrenamiento y prueba previamente definidos, se realizó una evaluación de su rendimiento, aplicando métricas estadísticas de

desempeño, con el propósito de cotejar su capacidad para calcular con precisión las propiedades mecánicas de resistencia última a la tracción (S_u), límite elástico (S_y) y elongación al 5% (A_5) de los aceros para cada modelo implementado. Esto posibilitó realizar comparaciones directas entre algoritmos bajo las mismas condiciones experimentales.

La evaluación se llevó a cabo mediante cuatro métricas estadísticas comúnmente utilizadas en problemas estadísticos para medir el rendimiento, las cuales son: el coeficiente de determinación (R^2), el error porcentual absoluto medio (MAPE), el error absoluto medio (MAE) y el error cuadrático medio (RMSE). El coeficiente R^2 permite cuantificar la proporción de la variabilidad de los datos reales que es explicada por el modelo, donde valores próximos a 1 son claros indicios de una alta capacidad para realizar predicciones correctas. El MAPE proporcionó una medida relativa de la equivocación en términos porcentuales, lo que hizo más fácil contrastar propiedades con escalas y magnitudes diferentes, en términos más coloquiales, este indicador dice que el modelo se equivoca en un X%, siendo así valores menores al 10% indicadores de un excelente desempeño. Por otro lado, el MAE realiza la evaluación del error promedio entre los valores reales y los valores predichos utilizando las mismas unidades de la propiedad mecánica evaluada, por lo que se trata de una interpretación directa del error. Por último, el RMSE, al castigar más los errores de gran magnitud, ayudó a detectar modelos con predicciones inestables o que tenían valores atípicos mal calculados.

La integración de estas métricas posibilitó una evaluación completa del rendimiento de cada modelo, evitando la dependencia exclusiva de un solo indicador. Así se pudo determinar qué algoritmo tiene mejor balance entre estabilidad, precisión y capacidad de generalización para cada propiedad mecánica analizada. Esto permitió escoger el modelo más apropiado para cada propiedad y tenerlo en cuenta para futuras aplicaciones en la optimización del diseño de aleaciones y en la predicción del comportamiento mecánico de las aleaciones de los aceros.

4 Resultados

Esta sección muestra los resultados obtenidos durante la evaluación y desarrollo de modelos de aprendizaje automático que se aplicaron para la predicción de las propiedades mecánicas de aceros con composiciones químicas y tratamientos térmicos diversos. Se presentan los resultados obtenidos del análisis de datos procesados, así como el rendimiento logrado por cada modelo a través de las métricas de evaluación definidas, lo que facilita la comparación entre su estabilidad y su capacidad predictiva.

Los hallazgos posibilitan el análisis de la conexión entre las variables de entrada y las propiedades mecánicas calculadas, así como determinar cuál modelo es el que brinda un rendimiento superior para cada propiedad analizada. Para verificar el uso de las técnicas de aprendizaje automático como instrumento auxiliar en la caracterización y selección de materiales, disminuyendo la dependencia de los ensayos experimentales tradicionales, este análisis es un paso esencial.

Antes del tratamiento de los datos, se debe tener en cuenta la estructura inicial con la que se inició a trabajar todo el proyecto, como se evidencia en la tabla 3.

	Std	ID	Material	Heat treatment	Su	Sy	A5	Bhn	E	G	mu	Ro	pH	Desc	HV
0	ANSI	D8894772B88F495093C43AF905AB6373	Steel SAE 1015	as-rolled	421	314	39.0	126.0	207000	79000	0.3	7860	NaN	NaN	NaN
1	ANSI	05982AC66F064F9EBC709E7A4164613A	Steel SAE 1015	normalized	424	324	37.0	121.0	207000	79000	0.3	7860	NaN	NaN	NaN
2	ANSI	356D6E63FF9A49A3AB23BF66BAC85DC3	Steel SAE 1015	annealed	386	284	37.0	111.0	207000	79000	0.3	7860	NaN	NaN	NaN
3	ANSI	1C758F8714AC4E0D9BD8D8AE1625AECD	Steel SAE 1020	as-rolled	448	331	36.0	143.0	207000	79000	0.3	7860	NaN	NaN	NaN
4	ANSI	DCE10036FC1946FC8C9108D598D116AD	Steel SAE 1020	normalized	441	346	35.8	131.0	207000	79000	0.3	7860	550.0	NaN	NaN

Tabla 3. Estructura de la tabla original

4.1 Limpieza y aplicación de filtros

Ya que el dataset contenía diversos materiales, el primer paso para preparar el conjunto de datos fue un proceso de filtrado, con el propósito de garantizar que la investigación se centrara únicamente en los materiales relevantes. Se empleó un filtro en la columna “Material” para mantener solo aquellos registros que incluyeran la palabra “Steel”. De esa manera se aseguró que el conjunto final de los datos solo incluyera aceros, eludiendo la inclusión de variabilidad relacionada con otros materiales que tienen comportamientos mecánicos diferentes.

Posteriormente, se realizó un análisis con el fin de detectar la existencia de valores faltantes en cada columna del conjunto de datos. Este método posibilitó la cuantificación de los registros incompletos y el análisis de su posible efecto en el entrenamiento de los modelos de machine learning. Detectar los datos faltantes es un paso crucial, ya que, si no se gestionan correctamente, estos pueden introducir sesgos o perjudicar la capacidad predictiva de los modelos. Tras este diagnóstico se procedió a eliminar aquellos registros que presentaban valores faltantes en la columna “Heat treatment”, debido a que esta variable es una de las más influyentes sobre las propiedades

mecánicas del acero y es esencial para entrenar modelos predictivos. Conservar registros sin esos datos habría disminuido la calidad del entrenamiento y puesto en riesgo la coherencia de los resultados. Por otro lado, los valores faltantes.

Finalmente, se realizó una modificación en la forma de escribir los nombres de los tratamientos térmicos para garantizar que todos empezaran con mayúscula. A pesar de que este cambio no tiene ningún impacto directo en el rendimiento de los modelos, sí posibilita la consistencia en el dataset y simplifica la lectura, estructuración y creación de gráficas a lo largo de las presentaciones de resultados y los análisis exploratorios. Esta normalización ayuda a una interpretación visual más precisa y previene la creación de categorías repetidas que solo se originan por variaciones en la escritura.

4.2 Análisis exploratorio de datos (EDA)

El apartado de análisis exploratorio de datos se llevó a cabo en 2 etapas. La primera corresponde a las tablas de contenido y al análisis estadístico del dataset y la segunda se centra en los diferentes hallazgos obtenidos mediante gráficas y comparaciones entre las columnas.

Std	object
ID	object
Material	object
Heat treatment	object
Su	int64
Sy	int64
A5	float64
Bhn	float64
E	int64
G	int64
mu	float64
Ro	int64
pH	float64
Desc	object
HV	float64

Figura 6. Tipos de datos

Std	0
ID	0
Material	0
Heat treatment	59
Su	0
Sy	0
A5	68
Bhn	176
E	0
G	0
mu	0
Ro	0
pH	435
Desc	109
HV	454

Figura 7. Cantidad de datos faltantes

	Su	Sy	A5	Bhn	E	G	mu	Ro	pH	HV
count	395.000000	395.000000	327.000000	243.000000	395.000000	395.000000	395.000000	395.000000	17.000000	0.0
mean	805.972152	557.582278	19.325382	237.358025	205118.987342	166594.936709	0.297139	7865.916456	729.411765	NaN
std	362.635820	368.923458	11.169739	108.278220	5498.824885	226597.818939	0.004525	68.778284	383.723054	NaN
min	290.000000	190.000000	1.000000	111.000000	193000.000000	77000.000000	0.290000	7640.000000	310.000000	NaN
25%	575.000000	320.000000	12.000000	170.000000	200000.000000	79000.000000	0.290000	7820.000000	420.000000	NaN
50%	689.000000	405.000000	17.000000	207.000000	206000.000000	79000.000000	0.300000	7860.000000	550.000000	NaN
75%	916.000000	650.000000	23.000000	255.000000	207000.000000	82000.000000	0.300000	7860.000000	1210.000000	NaN
max	2220.000000	2048.000000	60.000000	627.000000	219000.000000	769000.000000	0.300000	8030.000000	1300.000000	NaN

Figura 8. Estadística descriptiva

En la primera parte del análisis exploratorio de datos se logró verificar la estructura y calidad general del conjunto de datos utilizado en el estudio. Se determinó que las variables relacionadas con propiedades físicas y mecánicas fueron correctamente comprendidas como datos numéricos. Por otro lado, los campos vinculados al estándar identificador, material y tratamiento térmico permanecen siendo variables categóricas, lo cual es consistente con el carácter descriptivo de los atributos. Esta categorización corrobora que las variables mecánicas se pueden usar directamente en los modelos, pero las variables categóricas necesitan ser codificadas antes de ser incluidas en los modelos de aprendizaje automático.

El resumen estadístico revela que las variables contienen cerca de 395 registros válidos, una cantidad adecuada para el entrenamiento de los modelos supervisados clásicos. No obstante, uno de los factores más importantes a analizar son los valores faltantes, ya que esta métrica permite determinar si hay algunos valores en ciertas columnas que pueden ser imputados o si la mejor decisión es eliminar el registro. En los registros se detectan valores ausentes en ciertas propiedades, especialmente en dureza Brinell (Bhn) y elongación (A5), aunque variables como el pH y la dureza Vickers (HV) tienen poca o ninguna información disponible. Esta conducta avaló la exclusión o el tratamiento particularizado de estas dos últimas variables a lo largo de la preparación del conjunto de datos, dando prioridad a aquellas características que eran más completas y relevantes para el modelo.

El análisis de las distribuciones muestra también que características como el límite elástico (Sy) y la resistencia última a la tracción (Su) tienen distribuciones asimétricas. Estas distribuciones se concentran en rangos medios y tienen una cola hacia valores altos, lo cual está ligado a aceros resistentes. Durante la formación de los modelos, hay que tener en cuenta la existencia de estos valores extremos, ya que tienen el potencial de afectar la estabilidad y exactitud de las predicciones. Adicionalmente, variables como el módulo de elasticidad (E), el módulo de corte (G) o el coeficiente de Poisson (mu) presentan distribuciones altamente concentradas alrededor de valores típicos de los aceros, lo cual confirma que estas propiedades varían poco entre aleaciones ferrosas y dependen principalmente de la estructura cristalina del material más que del tratamiento térmico. De manera semejante, la densidad muestra una dispersión baja, acorde con los materiales que tienen

como base el hierro. Sin embargo, se pueden apreciar diferencias que se deben a la presencia de elementos aleantes o variaciones en la composición química.




Figura 9. Distribución de variables numéricas




Figura 10. Boxplot para cada variable

Los histogramas son una gran ayuda visual que permite observar la distribución de los valores de cada propiedad dentro del conjunto de datos, evidenciando la frecuencia con que aparecen ciertos rangos. La distribución de la resistencia última a la tracción (S_u) es notablemente asimétrica a la izquierda, teniendo una concentración de datos más alta entre 450 a 800 MPa. Para el límite elástico (S_y) muestra un comportamiento similar con una concentración de datos más evidente entre 200 a 500 MPa. La elongación al 5% (A_5) presenta una distribución más dispersa con la mayoría de valores entre el 10 y 20%. La dureza de Brinell (B_{hn}) muestra un comportamiento semejante al de las resistencias mecánicas: predominan valores entre 150 y 250 HB, aunque se encuentran también materiales con una dureza por encima de 400 HB, lo que sugiere la presencia de aceros endurecidos. Al igual que se dedujo del análisis estadístico, el módulo de elasticidad (E), el coeficiente de Poisson (μ) y la densidad (R_o) muestran una distribución muy concentrada en torno a valores típicos del acero, lo que es consistente con la teoría de materiales. Finalmente, la variable pH muestra una escasez de datos y una amplia dispersión, lo que sugiere que esta variable no tiene una estructura constante dentro del conjunto de datos y es posible que no sea útil para modelar.

Por otra parte, los diagramas de caja permiten identificar la presencia de valores atípicos en cada propiedad. Para la resistencia última a la tracción (S_u) y el límite elástico (S_y), se puede evidenciar una cantidad considerable de puntos por encima del rango intercuartílico, lo que confirma la presencia de aceros de muy alta resistencia. La dureza de Brinell (B_{hn}) muestra números valores extremos, esto es coherente con características de aceros endurecidos, lo que puede llegar a ser muy útil para el entrenamiento de los modelos. La propiedad con más motivos de análisis detallado es el módulo de corte (G) ya que presenta algunos valores extremadamente altos, lo que puede indicar errores en las mediciones o un cambio en las unidades.




Figura 11. Matriz de correlación

La matriz de correlación, como su nombre lo indica, permite entender cómo se relacionan las diferentes propiedades entre sí y da opciones de posibles variables predictoras. La correlación más destacada está entre la resistencia última a la tracción (S_u) y el límite elástico (S_y) con un valor del 0.96, lo cual confirma que ambas propiedades están fuertemente relacionadas, cuando aumenta una, aumenta la otra. La dureza de Brinell (B_{hn}) muestra una correlación del 0.94 - 0.96 con el límite elástico (S_y) y la resistencia última a la tracción (S_u) respectivamente, lo que indica que esta característica puede funcionar como un buen predictor indirecto. Por otro lado, la elongación (A_5) presenta correlaciones negativas, lo que físicamente es coherente, ya que a mayor resistencia, menor es la ductilidad. Una relación interesante se presenta en el módulo de corte (G) y la densidad (R_o), sin embargo, estas pueden deberse a la forma en la que fueron calculados.




Figura 12. Conteo de tratamientos térmicos

La gráfica de conteo de tratamientos térmicos muestra una distribución claramente desigual en la frecuencia de registros asociados a cada condición de procesamiento. Se evidencia que los tratamientos “Normalized”, “Quenched and tempered” y “Annealed” concentran la mayor cantidad de datos dentro del conjunto, lo cual indica que estos estados metalúrgicos son los más reportados en la literatura y en bases de datos industriales, probablemente debido a que representan

condiciones comunes de suministro y uso de aceros estructurales e industriales. En contraste, tratamientos más específicos o combinaciones particulares de endurecimiento, temple y revenido aparecen con una frecuencia considerablemente menor, generando una larga cola de categorías con pocos registros. Esta distribución implica que el modelo de aprendizaje automático contará con abundante información para aprender patrones en los tratamientos más comunes, pero tendrá menor capacidad de generalización para tratamientos poco representados. Por ello, resulta importante considerar estrategias de agrupación o normalización de categorías durante el modelado para evitar sesgos y mejorar la estabilidad de las predicciones cuando se enfrenten a tratamientos térmicos menos frecuentes.

4.3 Preparación de los datos

Tras la etapa del análisis exploratorio de datos, se llevó a cabo la limpieza y preparación del conjunto de datos para asegurar su calidad y consistencia antes del modelado. Primero, se detectaron los outliers en la columna del módulo de corte (G), con registros mayores a 100000. Físicamente estos valores no son consistentes para aceros estructurales, ya que el módulo de corte para los aceros en la literatura no es mayor a 85000. Por lo tanto, estos registros se eliminaron del conjunto de datos para no generar sesgos en el entrenamiento de los modelos.

A continuación se eliminaron las columnas “pH”, “Desc” y “HV”, ya que contenían muy pocos datos válidos o estaban prácticamente vacías. Fijar estas variables habría añadido demasiado ruido innecesario y habría aumentado la dimensionalidad del problema sin mejorar la capacidad predictiva. Esta elección simplificó el conjunto de datos y se centró en las variables más completas y físicamente significativas.

Debido a los datos faltantes en las columnas de elongación al 5% (A5) y dureza de Brinell (Bhn), se realizó una imputación con un modelo RandomForestRegressor. Este modelo fue capaz de predecir los valores faltantes en función de las demás variables disponibles, aprendiendo relaciones no lineales entre la composición, el tratamiento térmico y las propiedades mecánicas. Se seleccionó este método por su robustez frente a distribuciones no normales y su capacidad para modelar interacciones complejas.

Luego, se validó la coherencia estructural entre el dataset original de propiedades mecánicas y el dataset sintético de composiciones químicas creado anteriormente. Se verificó que ambos conjuntos tuvieran la misma cantidad de registros, asegurando así que a cada material le correspondiera una única composición química. Esta verificación fue crucial para garantizar la integridad de los conjuntos de datos al momento de combinarlos y prevenir errores en el entrenamiento de los modelos.

	Std	ID	Material	Heat treatment	Su	Sy	A5	Bhn	E	G	mu	Ro
0	ANSI	D8894772B88F495093C43AF905AB6373	Steel SAE 1015	As-rolled	421	314	39.0	126.0	207000	79000	0.3	7860
1	ANSI	05982AC66F064F9EBC709E7A4164613A	Steel SAE 1015	Normalized	424	324	37.0	121.0	207000	79000	0.3	7860
2	ANSI	356D6E63FF9A49A3AB23BF66BAC85DC3	Steel SAE 1015	Annealed	386	284	37.0	111.0	207000	79000	0.3	7860
3	ANSI	1C758F8714AC4E0D9BD8D8AE1625AEC	Steel SAE 1020	As-rolled	448	331	36.0	143.0	207000	79000	0.3	7860
4	ANSI	DCE10036FC1946FC8C9108D598D116AD	Steel SAE 1020	Normalized	441	346	35.8	131.0	207000	79000	0.3	7860

Tabla 4. Dataset original preparado

Como resultado de estas etapas, se generó un conjunto de datos limpio, constante e imputado y sin inconsistencias obvias con alta completitud en las variables de interés. Este último conjunto fué el utilizado para entrenar y probar los modelos de aprendizaje automático desarrollados en la presente investigación.

	Material	Heat treatment	Su	Sy	A5	Bhn	E	G	mu	Ro	C	Mn	P	S	Si	Ni	Cr	Mo	Fe
0	Steel SAE 1015	As-rolled	421	314	39.0	126.0	207.0	79.0	0.3	7860	0.136184	0.342828	0.001075	0.007927	0.0	0.0	0.0	0.0	99.511986
1	Steel SAE 1015	Normalized	424	324	37.0	121.0	207.0	79.0	0.3	7860	0.149983	0.563571	0.027726	0.028617	0.0	0.0	0.0	0.0	99.230103
2	Steel SAE 1015	Annealed	386	284	37.0	111.0	207.0	79.0	0.3	7860	0.172061	0.356569	0.002655	0.045889	0.0	0.0	0.0	0.0	99.422826
3	Steel SAE 1020	As-rolled	448	331	36.0	143.0	207.0	79.0	0.3	7860	0.220168	0.455266	0.027873	0.020515	0.0	0.0	0.0	0.0	99.276178
4	Steel SAE 1020	Normalized	441	346	35.8	131.0	207.0	79.0	0.3	7860	0.222798	0.465205	0.014807	0.036727	0.0	0.0	0.0	0.0	99.260463

Tabla 5. Dataset completo

4.4 Resultados de los modelos

Se entrenaron tres configuraciones experimentales para la predicción de la resistencia última a la tracción (Su), el límite elástico (Sy) y la elongación (A5) cambiando el conjunto de variables de entrada para determinar la influencia de la información adicional sobre en el desempeño de los modelos.

Para el primer conjunto de variables de entrada, se emplearon únicamente variables de composición química: C, Mn, P, S, Si, Ni, Cr, Mo y Fe junto con el tratamiento térmico. Para el segundo conjunto de variables de entrada, se emplearon las mismas variables de composición química, se mantuvo el tratamiento térmico y adicionalmente se incorporaron Bhn y Ro. Por último, en el tercer conjunto de variables de entrada, se reemplazó Bhn por G y el coeficiente de Poisson.

4.4.1 Su - Resistencia última a la tracción

Bajo la configuración del primer conjunto de variables de entrada, los coeficientes de determinación (R^2) se situaron en un rango moderado, alcanzando 0.6388 con Random Forest, 0.5456 con XG Boost y 0.6143 con la red neuronal. Los errores también fueron relativamente elevados, con valores

de RMSE superiores a 218 MPa en todos los casos. Estos resultados indican que, si bien la composición química contiene información relevante para estimar la Su, por sí sola no logra capturar por completo la variabilidad del comportamiento mecánico del material.

Su - Primera configuración				
	R ²	MAPE	MAE	RMSE
Random forest	0.6388	22.5793	162.6008	218.1072
XG Boost	0.5456	23.6509	181.2411	244.6410
Red neuronal	0.6143	20.8958	155.5094	225.3971

Tabla 6. Resultados de Su para la primera configuración

La configuración del segundo conjunto de variables produjo una mejora sustancial en el desempeño de los tres modelos. El R² aumentó hasta 0.9398 para Random Forest, 0.9193 para XG Boost y 0.9105 con la red neuronal, mientras que RMSE se redujo significativamente a 88.9980 en el mejor caso. Asimismo, el MAPE descendió a valores cercanos al 9-10 %, evidenciando una predicción considerablemente más precisa. Esta mejora puede deberse a la fuerte correlación existente entre la dureza y la resistencia mecánica, ya observada en el análisis exploratorio, lo que convierte a Bhn en una variable predictora altamente informativa para Su.

Su - Segunda configuración				
	R ²	MAPE	MAE	RMSE
Random forest	0.9398	9.1214	63.1015	88.9980
XG Boost	0.9193	9.7688	70.3057	103.0769
Red neuronal	0.9105	9.7698	72.8593	108.5334

Tabla 7. Resultados de Su para la segunda configuración

Para el escenario de la tercera configuración, el desempeño volvió a disminuir, con valores de R² de 0.6668 para Random Forest, 0.5872 para XG Boost y 0.5393 para la red neuronal. Los errores RMSE fueron similares a los obtenidos en la primera configuración, con un RMSE mayor a 209.4994 en todos los casos. Esto indica que, aunque G y μ son propiedades mecánicas vinculadas

al comportamiento elástico del material, no proporcionan información tan directamente relacionada con la resistencia última como lo hace la dureza.

Su - Tercera configuración				
	R²	MAPE	MAE	RMSE
Random forest	0.6668	21.0736	15.8384	209.4994
XG Boost	0.5872	21.2571	165.832	233.171
Red neuronal	0.5393	21.6092	159.699	246.3416

Tabla 8. Resultados de Su para la tercera configuración

Resulta evidente que la segunda configuración es la que tiene mejor desempeño para la predicción de la resistencia última a la tracción (Su). Por otro lado, realizando la comparativa entre los modelos, se aprecia que el modelo Random Forest obtuvo el mayor R² y los errores más bajos. Estos resultados confirman que la incorporación de variables mecánicas más relacionadas con la resistencia mejora sustancialmente la capacidad predictiva de los modelos, mientras que variables relacionadas principalmente con el comportamiento elástico no generan el mismo impacto en la estimación de la resistencia última a la tracción.

4.4.2 Sy - Límite elástico

Del mismo modo que en el análisis realizado para la resistencia última a la tracción (Su), se evaluó el desempeño de los modelos para predecir el límite elástico (Sy) empleando tres configuraciones diferentes de variables de entrada mencionadas anteriormente. El objetivo fue analizar cómo la incorporación de las propiedades adicionales afecta la capacidad predictiva de los modelos.

Para la primera configuración, el modelo Random Forest presentó el mejor desempeño de los tres modelos con un R² de 0.7445, de 0.6307 para XG Boost y 0.6393 para la red neuronal. Los errores cometidos al predecir los valores fueron relativamente altos, obteniéndose valores de RMSE que oscilaron entre 184 MPa y 221 MPa. Estos resultados indican que la composición química por sí sola permite capturar una parte importante de la variabilidad del límite elástico, aunque no es suficiente para explicar completamente su comportamiento, ya que este también depende de factores microestructurales asociados al procesamiento del material.

Sy - Primera configuración				
	R²	MAPE	MAE	RMSE
Random forest	0.7445	24.7578	126.9181	184.2355

XG Boost	0.6307	24.7777	141.0877	221.5212
Red neuronal	0.6393	24.9699	134.4347	218.9095

Tabla 9. Resultados de Sy para la primera configuración

La segunda configuración resultó en un incremento importante del desempeño de los modelos. En particular, Random Forest obtuvo un R^2 de 0.9445, mientras que XG Boost y la red neuronal lograron valores de 0.9154 y 0.8742 respectivamente. Los errores de predicción se vieron reducidos de forma muy considerable, y el RMSE mínimo fue de 85.83 MPa aproximadamente en el caso de Random Forest con un MAPE del 12.89%. Esta mejora puede deberse a la estrecha relación entre la dureza y las propiedades de resistencia del material, ya que la dureza es un reflejo indirecto de la resistencia del acero a la deformación plástica.

Sy - Segunda configuración				
	R^2	MAPE	MAE	RMSE
Random forest	0.9445	12.8947	61.5361	85.8323
XG Boost	0.9154	13.7719	70.2285	105.9977
Red neuronal	0.8742	20.4213	94.4248	129.2407

Tabla 10. Resultados de Sy para la segunda configuración

Con la tercera configuración los modelos volvieron a disminuir su desempeño, con resultados muy similares al la primera configuración. Los resultados de R^2 para cada uno de los modelos fueron de 0.7461 para Random Forest, mientras que para XG Boost y la red neuronal fueron de 0.6235 y 0.6019 respectivamente. Se mantuvieron errores de predicción elevados, con RMSE cercanos a los 183–229 MPa y errores porcentuales mayores a 24%.

Sy - Tercera configuración				
	R^2	MAPE	MAE	RMSE
Random forest	0.7461	24.802	127.9259	183.6719
XG Boost	0.6235	24.0179	142.2591	223.6654
Red neuronal	0.6019	24.2214	138.5012	229.9903

Tabla 11. Resultados de Sy para la tercera configuración

Nuevamente se puede apreciar un mayor rendimiento con la segunda configuración. Esto puede exponer a la dureza Brinell como una mejor variable de entrada ya que mejora significativamente la capacidad predictiva de los modelos para estimar el límite elástico. Entre los modelos evaluados, el Random Forest presento el mejor desempeño en las tres configuraciones analizadas evidenciando su capacidad para capturar relaciones no lineales.

4.4.3 A5 - Elongación

Para la propiedad de la elongación se realizó exactamente el mismo ejercicio que se desarrolló con Su y Sy. La predicción de la elongación al 5% (A5) se evaluó mediante las mismas tres configuraciones de entrada, con el objetivo de analizar el impacto de diferentes tipos de información sobre la capacidad de los diferentes modelos para estimar esta propiedad mecánica. A diferencia de las propiedades de resistencia analizadas previamente, la elongación está asociada al comportamiento dúctil del material, por lo que su relación con la composición química y otras propiedades puede ser más compleja.

En la primera configuración, los modelos XG Boost y red neuronal mostraron un desempeño moderado, alcanzando coeficientes de determinación R^2 de 0.5857 y 0.5746 respectivamente, con valores de RMSE cercanos a 5 unidades de elongación. Sin embargo, el modelo Random Forest, mostró un comportamiento extraño, obteniendo un valor R^2 muy negativo y errores mucho mayores.

A5 - Primera configuración				
	R^2	MAPE	MAE	RMSE
Random forest	-6089.8404	4804.1362	550.7598	626.7479
XG Boost	0.5857	28.8705	3.7819	5.1688
Red neuronal	0.5746	30.1826	3.7544	5.2373

Tabla 12. Resultados de A5 para la primera configuración

Con la segunda configuración se obtuvieron mejores resultados en los modelos de XG Boost y red neuronal, con valores de R^2 de 0.8646 y 0.7906 respectivamente. También se redujeron de manera considerable los errores de predicción, con RMSE menor a 4 unidades y con un MAPE menor a 22%. Por otro lado, el modelo Random Forest siguió mostrando un comportamiento inestable, con valores de R^2 extremadamente negativos y errores muy altos nuevamente.

A5 - Segunda configuración				
	R ²	MAPE	MAE	RMSE
Random forest	-6329.2580	4978.35	539.2618	638.9473
XG Boost	0.8646	17.7071	2.3038	2.9541
Red neuronal	0.7906	21.6025	2.8331	3.6743

Tabla 13. Resultados de A5 para la segunda configuración

En la tercera configuración, los modelos XG Boost y red neuronal volvieron a mostrar un desempeño moderado, con valores de R² de 0.6375 y 0.5466 respectivamente, y errores de predicción ligeramente superiores a los del segundo intento. El modelo Random Forest siguió arrojando resultados inconsistentes, con valores negativos de R² y errores elevados nuevamente.

A5 - Tercera configuración				
	R ²	MAPE	MAE	RMSE
Random forest	-6128.92	4805.448	549.8376	628.7556
XG Boost	0.6375	25.9746	3.405	4.835
Red neuronal	0.5466	30.6166	3.9588	5.4071

Tabla 14. Resultados de A5 para la tercera configuración

En general, los resultados muestran que predecir la deformación es más difícil que predecir las propiedades de resistencia estudiadas anteriormente. Sin embargo, la inclusión de la dureza Brinell como variable de entrada permitió mejorar sustancialmente la capacidad predictiva de los modelos XG Boost y Red Neuronal, lo que sugiere que las propiedades relacionadas con la resistencia del material pueden aportar información relevante para estimar su comportamiento dúctil. De entre las configuraciones estudiadas, el segundo intento obtuvo el mejor comportamiento global en la predicción de la elongación.

4.4.4 E - Módulo de elasticidad y G - módulo de corte

La predicción del módulo de elasticidad (E) y el módulo de corte (G) se realizó únicamente mediante el empleo de la segunda configuración de variables de entrada, la cual incluye los

elementos de composición química (C, Mn, P, S, Si, Ni, Cr, Mo y Fe), así como el tratamiento térmico, la dureza Brinell (Bhn) y la densidad (Ro). Esta configuración fue elegida porque previamente había dado el mejor desempeño para predecir otras propiedades mecánicas, como la resistencia última a la tracción y el límite elástico.

Por un lado, los resultados de las métricas tradicionales de evaluación mostraron un desempeño limitado de la capacidad predictiva de los modelos. Los valores de R^2 para el módulo de elasticidad fueron cercanos a 0.32 para los modelos Random Forest y XG Boost, mientras que la red neuronal tuvo un valor negativo de R^2 (-1.365), lo que sugiere que el modelo no pudo capturar adecuadamente la relación entre las variables de entrada y esta propiedad. Un comportamiento análogo fue observado en la predicción del módulo de corte, donde los valores de R^2 fueron aún menores (0.2676 para Random Forest y 0.1934 para XG Boost), mientras que la red neuronal nuevamente arrojó un valor negativo (-2.1069). Estos resultados indican que las variables estudiadas no explican de forma adecuada la variabilidad de estas propiedades elásticas cuando se evalúan con las métricas convencionales.

E - Segunda configuración				
	R^2	MAPE	MAE	RMSE
Random forest	0.3210	1.0249	2.1370	3.6071
XG Boost	0.3219	0.9866	2.0536	3.6048
Red neuronal	-1.3650	2.4793	5.1673	6.7321

Tabla 15. Resultados de E para la segunda configuración

G - Segunda configuración				
	R^2	MAPE	MAE	RMSE
Random forest	0.2676	1.2027	0.9678	1.5433
XG Boost	0.1934	1.1904	0.9588	1.6197
Red neuronal	-2.1069	3.1244	2503.3269	3.6743

Tabla 16. Resultados de G para la segunda configuración

Desde el punto de vista físico, este comportamiento puede explicarse, ya que tanto el módulo de elasticidad como el módulo de corte son propiedades determinadas fundamentalmente por la naturaleza del enlace atómico y la estructura cristalina del material. Para los aceros, estas propiedades exhiben una variabilidad relativamente baja entre las distintas aleaciones, lo cual

restringe la habilidad de los modelos de aprendizaje automático para descubrir patrones importantes en los datos.

Debido a estas limitaciones, se realizó una evaluación adicional utilizando la ecuación del error porcentual, con el fin de analizar la precisión real de las predicciones realizadas por los modelos.

$$E\% = \frac{|Valor\ medido - valor\ real|}{valor\ real} * 100$$

Con este criterio los resultados obtenidos fueron bastante más favorables. En cuanto al módulo de elasticidad, los errores porcentuales se ubicaron en torno al 1 % para los modelos Random Forest (1,025 %) y XG Boost (0,992 %), mientras que la red neuronal presentó un error mayor de aproximadamente el 3,5 %. Los errores porcentuales para el módulo de corte también fueron bajos, con valores cercanos al 1.2% para Random Forest y XG Boost, y cerca del 3.1% para la red neuronal.

Resultados con ecuación error		
	E% para E	E% para G
Random forest	1.025	1.203
XG Boost	0.992	1.186
Red neuronal	3.525	3.124

Tabla 17. Resultados de la ecuación error configuración

4.5 Casos de prueba

Con el fin de evaluar la aplicabilidad práctica de los modelos desarrollados, se implementó un caso de prueba interactivo en el cual el usuario puede ingresar manualmente las variables de entrada correspondientes a un acero específico. estas variables son exactamente las mismas que se sauron para la predicción de los modelos la cual corresponde a la composición química (C, Mn, P, S, Si, Ni, Cr, Mo y Fe), la dureza Brinell (Bhn), la densidad (Ro) y el tratamiento térmico (HT). A partir de estos datos, el sistema genera como salida la predicción de las principales propiedades mecánicas las cuales corresponden a la resistencia última a la tracción (Su), límite elástico (Sy), elongación (A5), módulo de elasticidad (E) y módulo de corte (G). Este ejercicio permite simular un escenario real de uso del modelo, demostrando su aplicabilidad en procesos de diseño y selección de materiales.

4.5.1 Primer caso de prueba

Como primer caso de prueba se utilizó el acero AISI 316, cuyas propiedades de entrada fueron definidas de acuerdo con valores típicos reportados en la literatura (Padilla, 1999) de la siguiente manera: C=0.08, Mn=2, P=0.045, S=0.03, Si=1, Ni=12, Cr=17, Mo=2, Fe=65.845, Bhn=175, Ro=8000 y tratamiento térmico “*Annealed*”. A partir de estos datos de entrada, el modelo generó predicciones para las propiedades mecánicas, las cuales fueron comparadas con los valores teóricos de referencia.

Resultados caso de prueba				
	Valores teóricos	Valores predichos	E% individual	E % general
Su	515 - 620	563.53	0 %	10.568 %
Sy	205 - 290	358.17	22.24 %	
A5	40%	20.86%	20.79 %	
E	193000	206103.16	6.79 %	
G	77000	79331.16	3.02 %	

Tabla 18. Caso de prueba 1

4.5.2 Segundo caso de prueba

Como segundo caso de prueba se utilizó el acero AISI D2, cuyas propiedades de entrada fueron definidas de acuerdo con valores típicos reportados en la literatura (Illanes, 2010) de la siguiente manera: C=1.6, Mn=0.6, P=0.03, S=0.03, Si=0.5, Ni=0, Cr=13, Mo=1.2, Fe=82.54, Bhn=650, Ro=7700 y tratamiento térmico “*Quenched and tempered*”. A partir de estos datos de entrada, el modelo generó predicciones para las propiedades mecánicas, las cuales fueron comparadas con los valores teóricos de referencia.

Resultados caso de prueba				
	Valores teóricos	Valores predichos	E% individual	E % general
Su	1900 - 2200	2086.19	0 %	2.216 %
Sy	1600 - 1900	1756.10	0 %	
A5	1 - 5	5.44	8.80 %	
E	210000	209409.16	0.28 %	

G	80000	81603.38	2 %	
---	-------	----------	-----	--

Tabla 19. Caso de prueba 2

5 Análisis de resultados

Los hallazgos de este estudio posibilitan examinar el rendimiento de diversos modelos de aprendizaje automático en la predicción de las propiedades mecánicas del acero, basándose en su composición química, características físicas y variables vinculadas con el procesamiento del material. Para esta investigación se llevó a cabo una evaluación de varias configuraciones de variables de entrada durante todos los experimentos, con el objetivo de determinar cuáles contribuyen en mayor medida a la estimación de propiedades como la elongación (A5), la resistencia última a la tracción (Su), el límite elástico (Sy), el módulo de elasticidad (E) y el módulo de corte (G). La comparación de modelos y configuraciones permitió la detección de patrones significativos sobre cómo las variables elegidas influyen en el comportamiento de los algoritmos ante distintos tipos de propiedades mecánicas y también permitió determinar el mejor modelo para cada propiedad mecánica evaluada.

En este contexto, la discusión se enfoca en analizar los resultados obtenidos teniendo como foco el objetivo principal, el cual se centra, en pocas palabras, en desarrollar un modelo apto para predecir las propiedades mecánicas de aceros basándose en datos en su mayoría de composición química, disminuyendo así la necesidad de pruebas experimentales convencionales con el ánimo de reducir costos. Así pues, en esta sección se examinan las diferencias encontradas entre los modelos, el efecto de añadir variables extra como la dureza o las propiedades elásticas y también las restricciones halladas al predecir determinadas características. Finalmente, este análisis permite comprender tanto el rendimiento de los modelos como su comportamiento mecánico de las diferentes composiciones, aportando elementos para la optimización del diseño y selección de aceros mediante herramientas basadas en datos.

5.1 Configuraciones y métricas

En términos generales, los resultados obtenidos evidencian que la configuración que presentó el mejor desempeño en todas las propiedades mecánicas evaluadas fue la segunda, la cual corresponde a las siguientes variables de entrada:

- **C:** Carbono
- **Mn:** Manganeso
- **P:** Fósforo
- **S:** Azufre
- **Si:** Silicio
- **Ni:** Níquel
- **Cr:** Cromo
- **Mo:** Molibdeno
- **Fe:** Hierro
- **HT:** Tratamiento térmico
- **Bhn:** Dureza Brinell
- **Ro:** Densidad

En el caso de la resistencia última a la tracción (Su) y el límite elástico (Sy), esta configuración permitió alcanzar los valores más altos de R^2 y los menores errores MAE y RMSE, lo cual indica una alta capacidad predictiva de los modelos. Este comportamiento se demuestra gracias a la fuerte relación que existe entre la dureza y las propiedades de resistencia del material como se muestra en la matriz de correlación en la figura 8, ya que ambas están asociadas a la capacidad del acero para resistir la deformación plástica. La inclusión de la dureza brinell (Bhn) aportó información clave

sobre el estado microestructural del material, permitiendo a los modelos capturar de manera más precisa las relaciones entre las variables.

De manera similar ocurre para la elongación (A5), aunque la predicción resultó más compleja debido a la naturaleza dúctil de esta propiedad, la segunda configuración también mostró el mejor desempeño, especialmente en modelos como XG Boost y la red neuronal. Esto sugiere que la dureza no solo está relacionada con la resistencia, sino que también aporta información indirecta sobre la ductilidad del material.

Por otro lado, los resultados de las métricas tradicionales del módulo de elasticidad (E) y el módulo de corte (G) mostraron valores anormales, particularmente el coeficiente de determinación (R^2) obtuvo valores muy bajos o incluso negativos, lo cual lo hace objeto de profundización ya que a primera vista se podría interpretar que como un pésimo desempeño de cada uno de los modelos. Sin embargo, ese primer vistazo es errado puesto que este resultado se explica principalmente por la baja variabilidad de estas propiedades dentro del conjunto de datos.

A diferencia de propiedades como la resistencia última a la tracción (S_u) o el límite elástico (S_y), que pueden variar ampliamente dependiendo de la composición, el tratamiento térmico y la microestructura, los módulos elásticos de los aceros presentan valores relativamente constantes, ya que dependen principalmente de la estructura cristalina y de la rigidez de los enlaces atómicos del hierro, factores que cambian muy poco entre diferentes aleaciones de acero. En contextos donde la variable objetivo tiene una dispersión muy reducida, métricas como R^2 se vuelven poco representativas, ya que incluso pequeñas desviaciones entre los valores predichos y los reales pueden generar una gran penalización estadística. Esto ocurre porque el R^2 compara el error del modelo con la varianza total de los datos; cuando dicha varianza es pequeña, cualquier error absoluto se vuelve relativamente grande en términos estadísticos, produciendo valores bajos o negativos. No obstante, al evaluar los resultados mediante error porcentual, se observó que las predicciones presentan desviaciones cercanas al 1% para los modelos Random Forest y XG Boost y cercanas al 3% para Redes Neuronales, lo cual indica que, en términos prácticos, las estimaciones son bastante precisas. Por lo tanto, las métricas aparentemente desfavorables no reflejan una incapacidad real del modelo para predecir estas propiedades, sino una limitación de las métricas utilizadas cuando se aplican a variables con baja variabilidad.

5.2 Desempeño de los modelos para cada propiedad

A partir de la comparación de resultados obtenidos, fue posible identificar que el desempeño de los modelos varía según la naturaleza de la propiedad mecánica a predecir, lo cual está directamente relacionado con el tipo de relaciones presentes en los datos.

En el caso de la resistencia última a la tracción (S_u) y el límite elástico (S_y), el modelo que presentó el mejor desempeño fue Random Forest. Esto se debe a que estas propiedades tienen una fuerte

dependencia de variables como la dureza y la composición química, las cuales presentan relaciones no lineales pero relativamente estructuradas. Random Forest, al estar basado en múltiples árboles de decisión, es eficiente para capturar este tipo de relaciones sin necesidad de supuestos previos sobre la distribución de los datos. Además, su capacidad para manejar interacciones entre variables y su robustez frente a outliers le permiten adaptarse bien a la variabilidad presente en propiedades de resistencia, donde existen tanto aceros convencionales como de alta resistencia dentro del mismo conjunto de datos.

Ahora bien, para la elongación (A5), el mejor desempeño se obtuvo con XG Boost. Esta propiedad está asociada a la ductilidad del material y presenta una relación más compleja y menos directa con las variables de entrada, ya que depende de múltiples factores microestructurales que no están completamente representados en el dataset. XG Boost, al ser un modelo de boosting, construye los árboles de manera secuencial corrigiendo los errores del modelo anterior, lo que le permite capturar patrones más sutiles y complejos. Por otro lado, se obtuvo un error extremadamente alto en la predicción de A5 con el modelo Random Forest. Esto puede explicarse porque Random Forest, al promediar múltiples árboles, tiende a suavizar las predicciones y puede perder sensibilidad frente a relaciones más complejas o dispersas como las que presenta la elongación. Además, la presencia de mayor ruido y variabilidad en esta propiedad puede generar que los árboles individuales produzcan predicciones muy distintas, lo que al combinarse en el modelo final puede generar resultados inestables.

Finalmente, para el módulo de elasticidad (E) y el módulo de corte (G), el mejor desempeño se obtuvo con XG Boost. Aunque estas propiedades presentan baja variabilidad, el modelo de boosting demostró una mejor capacidad para ajustar pequeñas diferencias entre los valores reales y predichos. XG Boost optimiza iterativamente los errores residuales, lo que le permite refinar las predicciones incluso cuando las variaciones en los datos son mínimas. Esto resulta útil para propiedades elásticas, donde pequeñas desviaciones pueden ser significativas desde el punto de vista estadístico, pero no necesariamente desde el punto de vista físico. En este contexto, XG Boost logró capturar de manera más precisa estas variaciones sutiles, superando a los otros modelos evaluados.

5.3 Casos de prueba

Los resultados muestran que el modelo logra una aproximación adecuada en la mayoría de las propiedades. El desarrollo de las pruebas de los aceros ASI 316 y D2 permitió evaluar la capacidad de respuesta del modelo frente a materiales con comportamientos mecánicos significativamente distintos.

Para el primer caso correspondiente a AISI 316, se observa que el modelo logra una buena aproximación en la mayoría de las propiedades, especialmente en la resistencia última (Su), donde la predicción se encuentra dentro del rango teórico esperado. En el módulo de elasticidad (E) y el

módulo de corte (G), obtuvieron errores relativamente bajos. Sin embargo, se presentan desviaciones más notables en el límite elástico (S_y) y la elongación (A5), con errores cercanos al 20%, lo cual es consistente con lo observado previamente en los resultados del modelo, donde estas propiedades dependen en mayor medida de características microestructurales no incluidas explícitamente en las variables de entrada. A pesar de ello, el error general del caso se mantiene en un valor aceptable del 10.568%, lo que indica un desempeño global adecuado.

En el segundo caso de prueba correspondiente al acero D2, el modelo presenta un comportamiento aún más preciso, evidenciado en un error general considerablemente bajo del 2.216%. Las predicciones de S_u y S_y se encuentran dentro de los rangos teóricos, con errores prácticamente nulos, lo que demuestra la capacidad del modelo para capturar adecuadamente el comportamiento de aceros de alta resistencia. Asimismo, los errores en las propiedades restantes como A5, E y G son bajos, destacándose especialmente el módulo de elasticidad con un error inferior al 1%. Estos resultados sugieren que el modelo tiene una mejor capacidad de predicción en materiales con comportamientos más definidos o representados en el conjunto de entrenamiento. En conjunto, ambos casos de prueba confirman que el modelo es capaz de generar predicciones confiables, con mayor precisión en propiedades de resistencia y propiedades elásticas, y con ciertas limitaciones en la estimación de la ductilidad.

6 Conclusiones

- El análisis y procesamiento del conjunto de datos permitió identificar las variables más relevantes en la predicción de las propiedades mecánicas de los aceros. Se evidenció que la composición química constituye una base importante para explicar el comportamiento del material, sin embargo, por sí sola resulta insuficiente para lograr predicciones de alta precisión. Por otro lado, la incorporación de variables como la dureza Brinell (Bhn) demostró ser determinante para el entrenamiento de los diferentes modelos. Asimismo, se confirmó que variables como el módulo de elasticidad y el coeficiente de Poisson presentan menor aporte predictivo por su poca dispersión.
- La implementación y comparación de diferentes modelos de aprendizaje automático permitió identificar el algoritmo más adecuado para cada propiedad mecánica. Se encontró que el modelo Random Forest presenta el mejor desempeño en la predicción de propiedades de resistencia como la resistencia última a la tracción (S_u) y el límite elástico (S_y), debido a su capacidad para capturar relaciones no lineales y manejar adecuadamente la variabilidad del dataset. Por su parte, el modelo XG Boost mostró un mejor desempeño en la predicción de propiedades más complejas o con mayor dispersión, como la elongación (A_5), o en propiedades con poca dispersión como el módulo de elasticidad (E) y el módulo de corte (G). Estos resultados evidencian que no existe un único modelo óptimo para todas las propiedades y que adicionalmente, la selección del algoritmo depende de la naturaleza de la variable a predecir.
- La evaluación del desempeño de los modelos mediante métricas como R^2 , MAE, RMSE y MAPE permitió validar su capacidad predictiva y analizar su aplicabilidad en contextos reales. Adicionalmente, la validación mediante los casos de prueba con el acero AISI 316 y AISI D2 permitieron comprobar la capacidad de generalización del modelo frente a nuevas combinaciones de entrada no utilizadas directamente en el entrenamiento. Para propiedades elásticas como el módulo de elasticidad (E) y el módulo de corte (G), aunque las métricas tradicionales no reflejaron un alto desempeño, el análisis mediante error porcentual y los casos de prueba demostraron que las predicciones son cercanas a los valores reales. Por otro lado, se identificaron mayores desviaciones en la predicción de la elongación (A_5) y, en algunos casos, del límite elástico (S_y), esto se atribuye a la influencia de factores microestructurales no incluidos en el modelo, lo que limita la precisión. No obstante los resultados globales obtenidos en ambos casos de prueba confirman que los modelos desarrollados tienen una adecuada capacidad de generalización y pueden ser utilizados como herramientas para la estimación de propiedades mecánicas.

Bibliografía

- Zippo, V., Robotti, E., Maestri, D., Fossati, P., Valenza, D., Maggi, S., ... & Marengo, E. (2025). Development of a self-updating system for the prediction of steel mechanical properties in a steel company by machine learning procedures. *Technologies*, 13(2), 75.
- Xiong, J., Zhang, T., & Shi, S. (2020). Machine learning of mechanical properties of steels. *Science China Technological Sciences*, 63(7), 1247-1255.
- Peng, J., Yamamoto, Y., Hawk, J. A., Lara-Curzio, E., & Shin, D. (2020). Coupling physics in machine learning to predict properties of high-temperatures alloys. *npj Computational Materials*, 6(1), 141.
- Stoll, A., & Benner, P. (2021). Machine learning for material characterization with an application for predicting mechanical properties. *GAMM-Mitteilungen*, 44(1), e202100003.
- Cortina, V. G. (2015). Aplicación de la metodología crisp-dm a un proyecto de minería de datos en el entorno universitario. *Universidad Carlos III de Madrid*.
- Callister Jr, W. D., & Rethwisch, D. G. (2020). *Materials science and engineering: an introduction*. John wiley & sons.
- NB, K. B., Balaji, N. S., & Saikiran, A. (2025). Effect of nutrient-based alloying elements on biodegradable magnesium alloys: Evolution, challenges, and strategies for orthopaedic applications. *Biomedical Engineering Advances*, 9, 100161.
- Ghali, S. (2021). Development of Molybdenum Nickel Steel to Improve Mechanical Properties at High Temperature. *International Journal of Materials Technology and Innovation*, 1(2), 40-47.
- Kako, K., Kawakami, E., Ohta, J., & Mayuzumi, M. (2002). Effects of various alloying elements on tensile properties of high-purity Fe-18Cr-(14-16) Ni alloys at room temperature. *Materials transactions*, 43(2), 155-162.
- Dong, Y., Liu, D., Du, H., Sun, H., & Zuo, X. (2023). Effect of microstructure on the mechanical properties and corrosion resistance of a welded joint of 620-grade marine steel. *Frontiers in Materials*, 10, 1107125.
- Monsalve, A. (2022). Modelos constitutivos y predicción de propiedades mecánicas en aceros multifásicos. *Remetallica*, 37(25).
- Gonzalez Espinosa, J. D., & Galvis Triana, D. O. (2017). Micromodelamiento mecánico del diagrama esfuerzo-deformación en un acero AISI 1045 templado desde temperaturas intercríticas.
- Pérez-Ruiz, E., Llano-Martínez, J., & Ravagli-Reyes, J. (2019). Estudio del grado de endurecimiento y resistencia al desgaste por deslizamiento del acero AISI 1045 endurecido por temple con refrigerante automotriz y para mecanizado. *Revista UIS Ingenierías*, 18(2), 113-120.
- Ali, F., Tan, A. S. C., & Wang, S. J. W. (2025). Can machine learning help accelerate article screening for systematic reviews? Yes, when article separability in embedding space is high. *Research Synthesis Methods*, 1-17.
- Janiesch, C., Zschech, P., & Heinrich, K. (2021). Machine learning and deep learning: C. Janiesch et al. *Electronic markets*, 31(3), 685-695.
- Wang, S. (2025). A Comprehensive Review of Machine Learning and Data Science Applications: From Fundamentals to Advanced Techniques. *Science and Technology of Engineering, Chemistry and Environmental Protection*, 1(2).

GUSTAFSSON, F. Comparing Random Forest, XGBoost and Neural Networks With Hyperparameter Optimization by Nested Cross-Validation.

Song, J. (2023, October). Comparison and analysis of accuracy of traditional random forest machine learning model and XGBoost model on music emotion classification dataset. In *Proceedings of the 2023 4th international conference on machine learning and computer application* (pp. 712-716).

Dutta, P., Paul, S., & Kumar, A. (2021). Comparative analysis of various supervised machine learning techniques for diagnosis of COVID-19. In *Electronic devices, circuits, and systems for biomedical applications* (pp. 521-540). Academic Press.

Chen, T., & Guestrin, C. (2016, August). Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining* (pp. 785-794).

Onyebueke, A. E., David, A. A., & Munu, S. (2023). Network intrusion detection system using XGBoost and random forest algorithms. *Asian J. Pure Appl. Math*, 5(1), 321-335.

Botchkarev, A. (2018). Evaluating performance of regression machine learning models using multiple error metrics in azure machine learning studio. *Available at SSRN 3177507*.

Chicco, D., Warrens, M. J., & Jurman, G. (2021). The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *Peerj computer science*, 7, e623.

Shaheen, M., Presswood, R., & Afshan, S. (2022). Application of machine learning to predict the mechanical properties of high strength steel at elevated temperature. *ce/papers*, 5(4), 420-428.

Frydrych, K., Karimi, K., Pecelerowicz, M., Alvarez, R., Dominguez-Gutiérrez, F. J., Rovaris, F., & Papanikolaou, S. (2021). Materials informatics for mechanical deformation: A review of applications and challenges. *Materials*, 14(19), 5764.

Chaires, J. M., Segura, J. Á., Serna Barquera, S. A., Ocampo, A. M., Cedillo, O. F., & Illianes, B. C. (2010). Evaluación de propiedades mecánicas de dos aceros grado herramienta AISI-O1, AISI-D2 y obtención de la concentración de esfuerzos en la geometría de mordazas de sujeción de especímenes compactos de tensión. *Superficies y vacío*, 23.

Apéndices

Incluyo material suplementario alojado en un repositorio de GitHub. En este se encuentra el archivo .ipynb desarrollado durante la tesis y los datasets correspondientes.

- <https://github.com/mclau14/Tesis-Prediccion-de-propiedades-mecanicas-de-aceros>