



VIGILADA MINEDUCACIÓN

UNIVERSIDAD


Maestría en Ciencia de Datos

Trabajo de Grado

Predicción de propiedades mecánicas de aceros con  
distintas composiciones y tratamientos térmicos mediante  
modelos de aprendizaje automático

**María Claudia Gamboa Castañeda**

El presente documento avala la entrega del trabajo de grado por parte del director y codirector.  
Documentos anexos: copia digital del Trabajo de Grado (1).



Firma Director  
Director: Johanna Esguerra Arce



Firma Estudiante  
Estudiante

© Únicamente se puede usar el contenido de las publicaciones para propósitos de información. No se debe copiar, enviar, recortar, transmitir o redistribuir este material para propósitos comerciales sin la autorización de la Escuela Colombiana de Ingeniería. Cuando se use el material de la Escuela se debe incluir la siguiente nota "Derechos reservados a Escuela Colombiana de Ingeniería" en cualquier copia en un lugar visible. Y el material no se debe notificar sin el permiso de la Escuela.

Publicado en 2013 por la Escuela Colombiana de Ingeniería Julio Garavito. Avenida 13 No 205-59  
Bogotá D.C., Colombia  
TEL: +57 – 1 668 36 00

Abril 10, 2026

## **Agradecimientos**

Quiero expresar mi más profundo agradecimiento a mis padres, quienes han sido el pilar fundamental en mi formación personal y académica. Su apoyo incondicional, su confianza constante y sus enseñanzas han sido parte clave para alcanzar este logro. Gracias por acompañarme en cada etapa, por motivarme en los momentos difíciles y por creer en mí incluso cuando el camino se tornaba desafiante. Este trabajo es también el resultado de su esfuerzo, amor y dedicación.

De igual manera, agradezco sinceramente a mi directora de tesis, Johanna Esguerra, por su orientación, paciencia y compromiso durante el desarrollo de este proyecto. Su acompañamiento constante, sus valiosos aportes y su dedicación fueron fundamentales para la construcción y consolidación de este trabajo. Gracias por compartir su conocimiento, por guiarme en cada etapa del proceso y por su disposición para resolver dudas y brindar apoyo académico de manera continua.

## Resumen

Este proyecto tuvo como objetivo seleccionar el mejor modelo de aprendizaje automático capaz de predecir las propiedades mecánicas de los aceros con diferentes composiciones químicas y tratamientos térmicos, en particular la resistencia a la tracción, el límite elástico, la elongación, el módulo de elasticidad y el módulo de corte. La investigación parte de una revisión exhaustiva del comportamiento mecánico del acero frente a distintos procesos de temple, revenido, normalizado y recocido, así como sobre la influencia de elementos de aleación como el carbono, manganeso, cromo y níquel. Para el entrenamiento y validación de los modelos, se emplea un conjunto de datos obtenido de fuentes experimentales reportadas en literatura académica y bases de datos especializadas, como kaggle (*Kaggle*, s/f) y publicaciones indexadas en ScienceDirect (ScienceDirect.com | Science, health and medical journals, full text articles and books., s/f), SpringerLink (*link.springer.com* | *Springer*, s/f), Scielo (*Scielo.org* | *Scientific Electronic Library Online*, s/f) y demás revistas científicas, que contienen registros de propiedades mecánicas vinculadas a composiciones específicas y condiciones térmicas controladas. Esta propuesta busca a futuro predecir el límite elástico de nuevas aleaciones de aceros sometidas a los diferentes tratamientos térmicos teniendo las características evaluadas de otras aleaciones anteriormente para optimizar el diseño y selección de aceros empleados en aplicaciones industriales, médicas y demás, reduciendo el costo y el tiempo requeridos para caracterizaciones físicas mediante ensayos convencionales.

La investigación se sustenta en la metodología CRISP-DM, que guió el proceso desde la comprensión de los datos hasta la evaluación y validación del modelo predictivo. Este enfoque busca optimizar la selección y diseño de aceros, reduciendo el tiempo y los costos asociados a ensayos físicos tradicionales y promoviendo la adopción de técnicas avanzadas de ciencia de datos en el campo de la ingeniería de materiales.

Adicionalmente, los resultados obtenidos contribuyen al área de la informática de materiales al demostrar la viabilidad del uso de técnicas de aprendizaje automático para la predicción de propiedades mecánicas de aceros a partir de variables relacionadas con su composición química y tratamiento térmico. La investigación permitió establecer un procedimiento metodológico para la preparación de los datos, entrenamiento y evaluación de modelos predictivos, así como comparar el desempeño de algoritmos como Random Forest, XGBoost y Redes Neuronales en este contexto. Estos hallazgos aportan evidencia sobre las capacidades y limitaciones de cada enfoque, generando una base de conocimiento que puede ser utilizada en futuras investigaciones orientadas a la predicción de propiedades mecánicas de otras aleaciones metálicas, el desarrollo de herramientas de apoyo en la industria y al fortalecimiento de la informática de materiales como disciplina aplicada, potenciando procesos de diseño de materiales más eficientes, sostenibles y económicos.

## Abstract

This project aimed to select the best machine learning model capable of predicting the mechanical properties of steels with different chemical compositions and heat treatments, particularly tensile strength, yield strength, elongation, Young's modulus, and shear modulus. The research is based on

a comprehensive review of the mechanical behavior of steel under various processes such as quenching, tempering, normalizing, and annealing, as well as the influence of alloying elements such as carbon, manganese, chromium, and nickel. For training and validating the models, a dataset was used, obtained from experimental sources reported in academic literature and specialized databases such as Kaggle and indexed publications in ScienceDirect, SpringerLink, Scielo, and other scientific journals, which contain records of mechanical properties linked to specific compositions and controlled thermal conditions. This proposal aims, in the future, to predict the yield strength of new steel alloys subjected to different heat treatments, using the evaluated characteristics of previously studied alloys, in order to optimize the design and selection of steels used in industrial, medical, and other applications, reducing the cost and time required for physical characterization through conventional testing.

The research is supported by the CRISP-DM methodology, which guides the process from data understanding to the evaluation and validation of the predictive model. This approach seeks to optimize steel selection and design, reducing the time and costs associated with traditional physical testing, while promoting the adoption of advanced data science techniques in the field of materials engineering.

Additionally, the results obtained contribute to the field of materials informatics by demonstrating the viability of using machine learning techniques to predict the mechanical properties of steels based on variables related to their chemical composition and heat treatment. The research established a methodological procedure for data preparation, training, and evaluation of predictive models, as well as comparing the performance of algorithms such as Random Forest, XGBoost, and Neural Networks in this context. These findings provide evidence regarding the capabilities and limitations of each approach, generating a knowledge base that can be used in future research aimed at predicting the mechanical properties of other metallic alloys, developing support tools for the industry, and strengthening materials informatics as an applied discipline, thus enhancing more efficient, sustainable, and cost-effective material design processes.

# Tabla de contenidos

|                                                         |           |
|---------------------------------------------------------|-----------|
| <b>1 Introducción</b>                                   | <b>1</b>  |
| 1.1 Problemática (Justificación)                        | 1         |
| 1.1.1 Alcance del problema                              | 1         |
| 1.1.2 Literatura existente y vacíos                     | 2         |
| 1.1.3 Preguntas de investigación                        | 3         |
| 1.2 Objetivos y pregunta de investigación               | 3         |
| 1.2.1 Pregunta de investigación                         | 3         |
| 1.2.2 Objetivo general                                  | 3         |
| 1.2.3 Objetivos específicos                             | 3         |
| 1.3 Alcance y Limitaciones                              | 4         |
| 1.4 Metodología                                         | 5         |
| 1.5 Resultados esperados                                | 6         |
| <b>2 Revisión de la literatura</b>                      | <b>7</b>  |
| 2.1 Aceros                                              | 7         |
| 2.2 Machine learning                                    | 10        |
| 2.2.1 Random Forest                                     | 10        |
| 2.2.2 XG Boost                                          | 11        |
| 2.2.3 Redes neuronales artificiales                     | 12        |
| 2.2.4 Métricas de evaluación                            | 13        |
| 2.3 La ciencia de datos en la ciencia de los materiales | 13        |
| 2.4 Dataset: Materials and their Mechanical Properties  | 14        |
| <b>3 Metodología</b>                                    | <b>17</b> |
| 3.1 Comprensión del tema                                | 17        |
| 3.2 Comprensión de los datos                            | 18        |
| 3.3 Preparación de los datos                            | 18        |
| 3.3.1 Dataset original                                  | 18        |
| 3.3.2 Dataset sintético                                 | 18        |
| 3.4 Modelado                                            | 20        |
| 3.5 Evaluación                                          | 21        |
| <b>4 Resultados</b>                                     | <b>23</b> |
| 4.1 Limpieza y aplicación de filtros                    | 23        |
| 4.2 Análisis exploratorio de datos (EDA)                | 24        |
| 4.3 Preparación de los datos                            | 29        |
| 4.4 Resultados de los modelos                           | 30        |

|                                                       |           |
|-------------------------------------------------------|-----------|
| 4.4.1 Su - Resistencia última a la tracción           | 31        |
| 4.4.2 Sy - Límite elástico                            | 32        |
| 4.4.3 A5 - Elongación                                 | 34        |
| 4.4.4 E - Módulo de elasticidad y G - módulo de corte | 35        |
| 4.4.5 Validación cruzada                              | 37        |
| 4.5 Casos de prueba                                   | 39        |
| 4.5.1 Primer caso de prueba                           | 39        |
| 4.5.2 Segundo caso de prueba                          | 40        |
| <b>5 Análisis de resultados</b>                       | <b>41</b> |
| 5.1 Configuraciones y métricas                        | 41        |
| 5.2 Desempeño de los modelos para cada propiedad      | 42        |
| 5.3 Casos de prueba                                   | 44        |
| 5.4 Oportunidades de mejora y trabajo a futuro        | 45        |
| <b>6 Conclusiones</b>                                 | <b>47</b> |
| <b>Bibliografía</b>                                   | <b>48</b> |
| <b>Apéndices</b>                                      | <b>50</b> |

## Lista de Figuras

|           |                                        |    |
|-----------|----------------------------------------|----|
| Figura 1  | Proceso CRISP-DM                       | 5  |
| Figura 2  | Funcionamiento de random forest        | 11 |
| Figura 3  | Funcionamiento del XG Boost            | 12 |
| Figura 4  | Funcionamiento de las redes neuronales | 12 |
| Figura 5  | Cronograma del proyecto                | 17 |
| Figura 6  | Tipos de datos                         | 23 |
| Figura 7  | Cantidad de datos faltantes            | 23 |
| Figura 8  | Estadística descriptiva                | 24 |
| Figura 9  | Distribución de variables numéricas    | 25 |
| Figura 10 | Boxplot para cada variable             | 25 |
| Figura 11 | Matriz de correlación                  | 26 |
| Figura 12 | Conteo de tratamientos térmicos        | 27 |

## Lista de Tablas

|          |                                                |    |
|----------|------------------------------------------------|----|
| Tabla 1  | Variables del dataset original                 | 16 |
| Tabla 2  | Dataset sintético                              | 19 |
| Tabla 3  | Estructura de la tabla original                | 22 |
| Tabla 4  | Dataset original preparado                     | 29 |
| Tabla 5  | Dataset completo                               | 29 |
| Tabla 6  | Resultados de Su para la primera configuración | 30 |
| Tabla 7  | Resultados de Su para la segunda configuración | 30 |
| Tabla 8  | Resultados de Su para la tercera configuración | 30 |
| Tabla 9  | Resultados de Sy para la primera configuración | 31 |
| Tabla 10 | Resultados de Sy para la segunda configuración | 32 |
| Tabla 11 | Resultados de Sy para la tercera configuración | 32 |
| Tabla 12 | Resultados de A5 para la primera configuración | 33 |
| Tabla 13 | Resultados de A5 para la segunda configuración | 33 |

|          |                                                |    |
|----------|------------------------------------------------|----|
| Tabla 14 | Resultados de A5 para la tercera configuración | 32 |
| Tabla 15 | Resultados de E para la segunda configuración  | 33 |
| Tabla 16 | Resultados de G para la segunda configuración  | 33 |
| Tabla 17 | Resultados de la ecuación error configuración  | 35 |
| Tabla 18 | Validación cruzada de Su                       | 35 |
| Tabla 19 | Validación cruzada de Sy                       | 36 |
| Tabla 20 | Validación cruzada de A5                       | 35 |
| Tabla 21 | Validación cruzada de E                        | 35 |
| Tabla 22 | Validación cruzada de G                        | 35 |
| Tabla 18 | Caso de prueba 1                               | 35 |
| Tabla 18 | Caso de prueba 2                               | 35 |



# **1 Introducción**

## **1.1 Problemática (Justificación)**

La predicción precisa de las propiedades mecánicas de aceros con distintas composiciones y tratamientos térmicos representa un avance significativo en el diseño, desarrollo y optimización de materiales para aplicaciones industriales, biomédicas, estructurales y demás. Los métodos tradicionales de caracterización, aunque fiables, requieren la fabricación de probetas, la realización de ensayos exhaustivos y el uso de equipos especializados, lo que se traduce en altos costos y largos periodos de tiempo para la obtención de resultados. Esta situación limita la capacidad de innovación en la creación de nuevas aleaciones y retrasa los procesos de selección de materiales para aplicaciones específicas.

El uso de técnicas de aprendizaje automático ofrece una alternativa eficiente y precisa para predecir la propiedad de límite elástico a partir de datos previamente obtenidos de estudios experimentales. Con bases de datos consolidadas, como la disponible en Kaggle y complementada con información académica, es posible entrenar modelos predictivos capaces de generalizar el comportamiento mecánico de nuevas aleaciones sin necesidad de realizar ensayos físicos en cada caso.

Además, este enfoque contribuye a la sostenibilidad de los procesos de investigación y desarrollo de materiales, reduciendo el consumo de recursos y el impacto ambiental asociado a la experimentación. También favorece la adopción de metodologías de informática de materiales, alineando la investigación con tendencias actuales en ingeniería y ciencia de datos. En este sentido, el proyecto no solo responde a una necesidad técnica, sino que también aporta valor científico y práctico, con potencial de aplicación en la industria metalúrgica, biomédica y manufacturera, y con la posibilidad de publicar los resultados en revistas indexadas, fortaleciendo la producción académica en esta área emergente.

### **1.1.1 Alcance del problema**

El diseño y la selección de aceros adecuados para aplicaciones industriales, estructurales, biomédicas y demás, dependen directamente de la comprensión de sus propiedades mecánicas, las cuales están determinadas por su composición química y los tratamientos térmicos aplicados. Sin embargo, los métodos tradicionales de caracterización como los ensayos de tracción, dureza, fatiga y demás, son costosos, requieren tiempo y demandan equipos especializados, lo que limita la rapidez con la que pueden desarrollarse o evaluarse nuevas aleaciones.

En un contexto donde la industria metalúrgica busca optimizar tiempos y costos sin comprometer la calidad, surge la necesidad de métodos alternativos que permitan predecir el comportamiento mecánico de los aceros a partir de información preexistente y datos experimentales disponibles. El alcance del problema se centra en la limitada explotación de los datos experimentales disponibles sobre aceros para la construcción de modelos predictivos que apoyen la estimación de sus propiedades mecánicas. En este contexto, la investigación busca evaluar el potencial de diferentes técnicas de aprendizaje automático para extraer patrones relevantes a partir de dichos datos y contribuir al desarrollo de herramientas predictivas en el campo de la informática de materiales.

Aunque existen numerosas investigaciones experimentales sobre la relación entre composición, tratamiento térmico y propiedades mecánicas, aún es limitada la integración de estos datos dentro de enfoques sistemáticos basados en ciencia de datos y aprendizaje automático. Por ello, el problema adquiere relevancia tanto científica como tecnológica, ya que la implementación de modelos predictivos confiables puede reducir significativamente el número de pruebas físicas requeridas, acelerar la innovación en el diseño de materiales y fortalecer la competitividad industrial mediante el aprovechamiento inteligente de la información disponible.

### **1.1.2 Literatura existente y vacíos**

La literatura reciente evidencia un creciente interés en la aplicación de técnicas de aprendizaje automático para la predicción de propiedades mecánicas en aceros y otras aleaciones metálicas. Diversos estudios han demostrado el potencial de algoritmos como Random Forest, Support Vector Machines y Redes Neuronales Artificiales para estimar parámetros como la resistencia a la tracción, la dureza y el módulo elástico a partir de datos experimentales. Por ejemplo, (Xiong et al., 2020) desarrollaron un modelo de aprendizaje automático para predecir las propiedades de aceros al carbono, identificando que la composición y el tratamiento térmico son los factores más determinantes en la predicción de resistencia y dureza. De igual forma, (Zippo et al., 2025) diseñaron un sistema actualizable que integra modelos predictivos en una planta siderúrgica, optimizando la producción y reduciendo el desperdicio de material. Otros trabajos, como los de (Peng et al., 2020; Stoll & Benner, 2021), han destacado la incorporación de principios físicos en los modelos de predicción para mejorar su interpretación y precisión, consolidando el campo de la informática de materiales.

No obstante, a pesar de estos avances, persisten vacíos significativos en la literatura. En primer lugar, numerosos estudios se desarrollan utilizando conjuntos de datos obtenidos bajo condiciones experimentales específicas, con un número limitado de composiciones químicas, tratamientos térmicos o familias de aceros. Esta situación restringe la capacidad de los modelos para generalizar adecuadamente a nuevos materiales o condiciones de procesamiento no representadas durante el entrenamiento. En consecuencia, continúa existiendo la necesidad de evaluar metodologías predictivas utilizando conjuntos de datos más diversos que permitan analizar con mayor profundidad la robustez y transferibilidad de los modelos desarrollados. En segundo lugar, se observa una escasa documentación sobre la comparación sistemática del desempeño de distintos algoritmos bajo un mismo conjunto de datos, lo que dificulta determinar cuál modelo ofrece la mejor capacidad predictiva y estabilidad.

Finalmente, pocos trabajos abordan la validación cruzada de los modelos con datos externos o la evaluación de su aplicabilidad práctica en entornos industriales. En este contexto, la presente investigación busca contribuir al cierre de estos vacíos mediante el desarrollo y la comparación de diferentes modelos de aprendizaje automático aplicados a un conjunto de datos público, con el propósito de establecer un marco metodológico reproducible y transferible para la predicción de propiedades mecánicas de aceros en distintos escenarios de ingeniería.

### **1.1.3 Preguntas de investigación**

La pregunta de investigación puede redactarse según diferentes perspectivas que se puedan tener dentro de la redacción de los objetivos, la justificación y demás apartados.

Para enfocar la pregunta hacia un enfoque metodológico, se planteó la siguiente: ¿Cuál es la metodología más adecuada para integrar datos de composición química, tratamiento térmico y propiedades mecánicas en un modelo de aprendizaje automático que permita generar predicciones confiables y generalizables? Sin embargo, esta pregunta no resuelve lo que principalmente se quiere lograr con el presente trabajo.

La pregunta enfocada a las diferentes aplicaciones puede ser la siguiente: ¿De qué manera el uso de técnicas de machine learning puede contribuir a reducir el tiempo y el costo asociados a la caracterización experimental de aceros en procesos industriales? No obstante, esta pregunta resuelve solo una parte del problema principal de investigación.

Lo que da paso al planteamiento de la pregunta de investigación que abarca todo el problema de investigación, donde se plasman los objetivos, la cual se presenta en el apartado 1.2.1.

## **1.2 Objetivos y pregunta de investigación**

### **1.2.1 Pregunta de investigación**

¿Qué modelos de aprendizaje automático presentan el mejor desempeño para predecir propiedades mecánicas como resistencia a la tracción, límite elástico, elongación, módulo de elasticidad y módulo de corte en aceros con diferentes composiciones y tratamientos térmicos?

### **1.2.2 Objetivo general**

Desarrollar un modelo de aprendizaje automático para predecir las propiedades mecánicas de aceros con distintas composiciones químicas y tratamientos térmicos, a partir de datos experimentales disponibles y sintéticos, con el fin de optimizar el diseño, selección y caracterización de los mismos sin depender exclusivamente de ensayos experimentales.

### **1.2.3 Objetivos específicos**

1. Analizar y procesar el conjunto de datos de aceros con diferentes composiciones y tratamientos térmicos para identificar las variables más relevantes en la predicción de propiedades mecánicas.

2. Implementar y comparar distintos modelos de aprendizaje automático supervisado para predecir propiedades como límite elástico, resistencia a la tracción y módulo de elasticidad.
3. Evaluar el desempeño de los modelos desarrollados mediante métricas estadísticas y validar su capacidad predictiva sobre nuevas aleaciones para garantizar su aplicabilidad en contextos reales de ingeniería de materiales.

### 1.3 Alcance y Limitaciones

El presente trabajo de investigación se enfoca en el desarrollo, entrenamiento y validación de modelos de aprendizaje automático para la predicción de propiedades mecánicas de diferentes aleaciones de aceros, específicamente la resistencia última a la tracción, el límite elástico y la elongación a partir de su composición química, tratamiento térmico y otras características presentes en el dataset. El estudio se fundamenta en el análisis de un conjunto de datos experimentales disponible públicamente (*Materials and Their Mechanical Properties*, 2023), (*Material Science | News | Materials Engineering | News*, s/f) que contiene información sobre la composición química, los tratamientos térmicos aplicados y las propiedades resultantes de distintas aleaciones. El proyecto se enmarca dentro de la metodología CRISP-DM, abarcando las fases de comprensión del problema, procesamiento de datos, modelado, evaluación y documentación de resultados.

Su alcance comprende la comparación de diferentes algoritmos de aprendizaje supervisado (Random Forest, aumento de gradiente extremo y redes neuronales) con el propósito de identificar el modelo que ofrezca el mejor desempeño predictivo y la mayor capacidad de generalización.

El alcance del proyecto no incluye la obtención experimental de nuevos datos ni la caracterización física o metalográfica de materiales, ya que el trabajo se sustenta exclusivamente en información previamente publicada y validada por fuentes académicas y experimentales. Por tanto, las conclusiones derivadas estarán limitadas por la calidad, tamaño y representatividad del conjunto de datos utilizado. Asimismo, las predicciones del modelo se restringen al rango de composiciones químicas y tratamientos térmicos presentes en dicho dataset, por lo que su extrapolación a aceros o condiciones no representadas debe realizarse con precaución.

Otro aspecto limitante radica en que no se consideran factores microestructurales detallados (como tamaño de grano, fases secundarias o inclusiones), los cuales también influyen en el comportamiento mecánico del material. Finalmente, aunque los modelos desarrollados evidenciaron un desempeño predictivo satisfactorio y muestran potencial para apoyar procesos de selección y diseño de materiales en contextos de ingeniería, su adopción industrial requiere procesos adicionales de validación experimental que permitan contrastar su comportamiento bajo condiciones reales de operación. Esta etapa constituye una práctica habitual en la transferencia de modelos predictivos hacia entornos productivos y no limita su utilidad como herramienta de apoyo.

## 1.4 Metodología

Para el desarrollo de este proyecto, se implementó una metodología denominada Proceso Estándar de Inter-Industrias para Minería de Datos con siglas CRISP-DM (del inglés *Cross- Industry Standard Process for Data Mining*) la cual es una de las principales metodologías para el desarrollo de nuevos proyectos relacionados con minería de datos o características similares ya que es uno de los procedimientos que ha tenido más apoyo de las empresas privadas y organismos públicos (Cortina & Galán, s/f). hola

Esta metodología consta de diferentes etapas. En la fase de comprensión del negocio, se define el objetivo principal: predecir propiedades mecánicas de aceros a partir de su composición y tratamiento térmico, lo cual tiene implicaciones directas en la optimización de procesos industriales. En la etapa de comprensión de los datos, se explora el dataset seleccionado desde Kaggle, identificando las variables disponibles, su significado técnico y su relación con las propiedades mecánicas de interés. Posteriormente, en la fase de preparación de los datos, se limpiaron, transformaron y seleccionaron las variables pertinentes, gestionando valores faltantes y codificando adecuadamente las características categóricas y numéricas, y se desarrollarán otras variables que también pueden ser muy útiles para el entrenamiento de los modelos. En la etapa de modelado, se aplicarán algoritmos de aprendizaje automático, ajustando sus hiperparámetros para lograr mejores predicciones. La fase de evaluación implica comparar modelos con métricas como RMSE, MAPE y  $R^2$  para seleccionar el más eficaz. Finalmente, en la etapa de despliegue, se documentaron los resultados y se planteó un posible sistema de predicción como herramienta de apoyo para ingenieros de materiales en futuras aplicaciones. Esta metodología garantiza un enfoque sistemático y reproducible en todo el ciclo de desarrollo del modelo predictivo.




Figura 1. Proceso CRISP-DM (Figura generada con la IA ChatGPT)

## 1.5 Resultados esperados

Se espera obtener un modelo de aprendizaje automático confiable y validado para cada propiedad mecánica de interés que permita predecir con alta precisión las propiedades mecánicas fundamentales de los aceros, más específicamente la resistencia última a la tracción, el límite elástico y la elongación, a partir de su composición química, tratamiento térmico y otras propiedades mecánicas. Este modelo deberá evidenciar una relación clara entre los elementos de aleación (por ejemplo, carbono, cromo, manganeso y níquel) y las respuestas mecánicas resultantes, proporcionando información útil para optimizar la formulación y selección de aceros en distintas aplicaciones industriales. De esta manera, el estudio busca demostrar que el uso de técnicas de machine learning puede reducir la necesidad de ensayos experimentales extensos, disminuyendo costos, tiempo y recursos en los procesos de diseño de materiales.

Adicionalmente, se espera identificar las variables más influyentes en la predicción de cada propiedad mecánica, lo cual permitirá generar conocimiento interpretativo y aplicable dentro del campo de la ingeniería de materiales. La comparación entre diversos modelos supervisados como Random Forest, redes neuronales, entre otros, permitirá determinar cuál ofrece el mejor desempeño predictivo bajo métricas estadísticas robustas ( $R^2$ , RMSE, MAPE). Este análisis también contribuirá a establecer criterios de selección de modelos aplicables a otras aleaciones metálicas.

Finalmente, se espera obtener un conjunto de modelos predictivos basados en técnicas de aprendizaje automático capaces de estimar propiedades mecánicas de aceros a partir de variables relacionadas con su composición química y tratamiento térmico. Asimismo, se espera generar evidencia comparativa sobre el desempeño de algoritmos como Random Forest, XGBoost y Redes Neuronales, identificando sus fortalezas y limitaciones para apoyar futuros procesos de selección, diseño y caracterización de materiales en el ámbito de la informática de materiales. A largo plazo, los hallazgos podrán contribuir al desarrollo de sistemas inteligentes de apoyo a la toma de decisiones en la industria metalúrgica y de manufactura, promoviendo prácticas más sostenibles, eficientes y orientadas a la innovación tecnológica.

## 2 Revisión de la literatura

Para abordar toda la temática que se encuentra en el desarrollo de este proyecto, se realizó el acercamiento a los aceros y sus aleaciones, la relación entre la ciencia de datos y el mundo de los materiales y realizar un análisis exhaustivo del dataset y los trabajos relacionados a la misma.

### 2.1 Aceros

El acero es una aleación metálica principalmente compuesta por hierro y carbono, con la adición de diversos elementos aleantes que permiten modificar y optimizar sus propiedades mecánicas. Dependiendo de su composición química y de los tratamientos térmicos aplicados, el acero puede presentar variaciones significativas en características como dureza, resistencia a la tracción, módulo de elasticidad, ductilidad, tenacidad y resistencia a la fatiga. Estas propiedades son fundamentales para determinar su idoneidad en aplicaciones industriales, biomédicas y estructurales. (Jr & Rethwisch, 2020). Los aceros constituyen uno de los materiales más utilizados en ingeniería debido a su versatilidad y capacidad de adaptación a diferentes aplicaciones mediante modificaciones en su composición química y procesamiento térmico. Desde el punto de vista metalúrgico, los aceros se clasifican principalmente en aceros al carbono, aceros aleados y aceros inoxidables, dependiendo de la cantidad y tipo de elementos aleantes presentes como lo son el cromo, níquel, molibdeno y manganeso, que son los más comunes, o el fósforo, azufre o silicio en menor proporción. Los aceros se clasifican principalmente según su contenido de carbono y elementos aleantes, lo que determina sus propiedades mecánicas base. Entre los tipos comunes están los aceros al carbono (bajo, medio y alto), aceros aleados de baja templabilidad (series SAE 4000, 5000), intermedia (SAE 4300, 4400) y alta (SAE 4800, 9300), además de aceros de gran resistencia. (Monsalve, 2022).

Las propiedades mecánicas de los aceros son indicadores fundamentales que describen cómo funciona el material ante la aplicación de diferentes fuerzas externas aplicadas ya sean unidireccionales, cíclicas o de choque. (Hougardy et al., 2011). Dichas propiedades no son fijas, sino que dependen directamente de la microestructura del acero, de su composición química y tratamientos térmicos específicos. (Eisenhuettenleute (VDEh) & Duesseldorf (Germany), 1992). En el ámbito de la ingeniería, estas características permiten predecir el desempeño del material en diferentes aplicaciones, asegurando que el acero cumpla con los requisitos de seguridad y eficiencia necesarios.

La resistencia a la tracción es una de las principales propiedades mecánicas que se estudia para tener en cuenta el comportamiento de un acero. Es la máxima tensión mecánica que un material puede soportar cuando se le aplica una fuerza de estiramiento antes de que se produzca la fractura o falla y en el sistema internacional, esta tiene unidades de Megapascuales (MPa) aunque también se puede encontrar en Newtons por milímetro cuadrado (N/mm<sup>2</sup>). (Hougardy et al., 2011; H & B, 2021). Por otro lado, el límite elástico es la máxima tensión que un material puede soportar sin sufrir deformaciones permanentes. En otras palabras, en la deformación elástica el material puede

volver a su forma de origen cuando se elimina la carga, cuando se supera, comienza la deformación plástica al cual causa un daño permanente en el material y en el punto justo cuando la deformación elástica pasa a ser plástica, a eso se le llama el límite elástico y en el sistema internacional, esta tiene unidades de Megapascuales (MPa). (Hougardy et al., 2011; H & B, 2021). La Elongación cuantifica la ductilidad de un material la cual se define como la capacidad de un material para estirarse antes de fracturarse, expresada como el incremento de longitud relativo respecto a la longitud original y ya que es una relación de deformación se expresa típicamente en porcentaje (%). (Gutiérrez Aguilera, 2023). Cuando se habla de módulo de elasticidad, también conocido como módulo de Young, se refiere a la rigidez del acero la cual relaciona la tensión con la deformación en la región elástica de un material. Esto quiere decir que es la medida de cuánto se deforma el material bajo carga antes de entrar en la zona plástica y en el sistema internacional, esta tiene unidades de Gigapascuales (GPa). (H & B, 2021). Por último, se tiene que la dureza es la resistencia que opone un material a la deformación superficial permanente, especialmente a la penetración, rayado, abrasión o desgaste. Aunque la dureza no posee una unidad única en el sistema internacional, existen varias escalas específicas según el método de ensayo como Brinell, Vickers o Rockwell, sin embargo, a lo largo del presente estudio solo se hablará de la dureza de Brinell. (Fatemi, 2000).

Los elementos aleantes son aquellos que se adicionan al acero con el propósito de modificar y mejorar sus propiedades mecánicas, físicas y químicas, permitiendo ajustar el material a requerimientos específicos de la industria. Estos desempeñan un papel fundamental en la determinación del comportamiento mecánico de los aceros, ya que influyen directamente en la microestructura del material. Entre los más utilizados se encuentran el cromo, níquel, molibdeno, vanadio y manganeso, los cuales influyen en la dureza, resistencia a la tracción, tenacidad, resistencia a la corrosión y estabilidad a altas temperaturas. (*Effect of nutrient-based alloying elements on biodegradable magnesium alloys: Evolution, challenges, and strategies for orthopaedic applications - ScienceDirect*, s/f; Jr & Rethwisch, 2020). Por ejemplo, el cromo y el níquel son esenciales en la fabricación de aceros inoxidables utilizados en la industria biomédica y alimentaria debido a su resistencia a la corrosión, mientras que el molibdeno mejora el comportamiento a altas temperaturas, lo cual es crítico en aplicaciones aeroespaciales y petroquímicas. El manganeso, por su parte, incrementa la templeabilidad y la resistencia al impacto, siendo ampliamente usado en la industria automotriz y en maquinaria pesada. (Ghali, 2021; Kako et al., 2002). Adicionalmente, a nivel microestructural se ha demostrado que la combinación de estos elementos puede modificar la formación de fases como ferrita, perlita, bainita y martensita, las cuales determinan propiedades clave como la ductilidad, la resistencia y la dureza. (Dong et al., 2023).

Por otro lado, los tratamientos térmicos representan una de las herramientas más importantes para ajustar las propiedades mecánicas de los aceros sin modificar su composición química y transformando la microestructura de los aceros. Procesos como el recocido, normalizado, temple y revenido permiten controlar la transformación de fases y el tamaño de grano, afectando directamente las propiedades mecánicas. (Bhat et al., 2021).



Para el desarrollo de la presente investigación, se empleó el dataset “*Materials and their Mechanical Properties*”, para el cual se identifican múltiples tratamientos térmicos con diferentes condiciones en procesos clásicos y variantes específicas. El tratamiento normalizado (*Normalized*) consiste en calentar el acero por encima de su temperatura crítica y enfriarlo al aire, lo que permite obtener una microestructura más uniforme y de grano fino, mejorando la tenacidad del material. También se tiene el tratamiento recocido (*Annealed*), el cual implica un calentamiento seguido de un enfriamiento lento dentro del horno, con el objetivo de ablandar el material, eliminar tensiones internas y facilitar procesos posteriores como el mecanizado. Dentro del mismo existen variantes como recocido o revenido alto (*Annealing or high tempering*) que combinan efectos de ablandamiento y estabilización estructural, reduciendo la dureza y aumentando la ductilidad. (Orlando & David et al., 2017).

Uno de los tratamientos más importantes es el temple (*Quenching*), presente en formas como temple y enfriamiento en aceite (*Quenching and cooling in the oil*) o temple y enfriamiento en agua (*Quenching and cooling in the water*). Este proceso consiste en calentar el acero hasta la región de austenita y enfriarlo rápidamente para formar martensita, una fase dura y resistente. El medio de enfriamiento influye directamente en la velocidad de enfriamiento y, por tanto, en la microestructura final: el agua genera enfriamientos más rápidos que el aceite, produciendo mayor dureza pero también mayor riesgo de fragilidad. (Pérez-Ruiz et al., 2019). Así mismo, el acero suele someterse a revenido (*tempering*), como en templado y revenido (*Quenched and tempered*) o con condiciones específicas como 400°F, 600°F u 800°F. El revenido reduce la fragilidad inducida por el temple, alivia tensiones internas y mejora la tenacidad del material.

Adicionalmente, el dataset incluye condiciones como cementado o endurecimiento superficial (*Case-hardened*) y cementado seguido de temple en aceite (*Case-hardening, quenching and cooling in the oil*), que corresponden a tratamientos termoquímicos en los cuales se modifica la composición química de la superficie del material, generalmente aumentando el contenido de carbono para obtener una capa superficial dura y resistente al desgaste, manteniendo un núcleo más dúctil. También se identifican estados del material asociados al proceso de fabricación, como laminado en caliente (*As-rolled*), que corresponde al material sin tratamiento térmico posterior, y trabajo en frío (*Cold working*), en el cual el material es deformado plásticamente a temperatura ambiente, generando endurecimiento por deformación. Asimismo, aparecen condiciones como completamente endurecido (*Full-hard*) y fracciones como Hard-1/4, Hard-1/2, Hard-3/4, que representan distintos niveles de endurecimiento del material, usualmente asociados a tratamientos de deformación o procesamiento industrial. (Monsalve, 2022).

Finalmente, se incluyen estados más generales como tratado térmicamente (*Heat treated*) y mejorado (*Improved*), los cuales indican que el material ha sido sometido a algún proceso térmico, aunque sin especificar el detalle del mismo. También aparece la condición *Quenching and heating*, que sugiere ciclos térmicos combinados, posiblemente asociados a procesos industriales más complejos.

## 2.2 Machine learning

El aprendizaje automático (*machine learning*) es una rama de la inteligencia artificial que permite a los sistemas desarrollar algoritmos capaces de aprender patrones a partir de datos para hacer predicciones o tomar decisiones sin ser programados explícitamente para cada tarea. En lugar de seguir reglas fijas, los modelos se entrenan con datos históricos para identificar relaciones entre variables y realizar predicciones sobre nuevos datos. Este enfoque se ha convertido en una herramienta fundamental en el modelado predictivo, ya que, en lugar de depender de reglas fijas, estos modelos identifican relaciones entre variables de entrada y una variable objetivo, por lo que son especialmente útiles cuando el fenómeno es complejo, multivariable o no lineal. En problemas de regresión, como la predicción de propiedades mecánicas de aceros, Machine Learning permite relacionar composición química, tratamientos térmicos y condiciones de procesamiento con respuestas a las propiedades mecánicas, facilitando la predicción de comportamientos sin recurrir exclusivamente a ensayos experimentales. (Ali et al., 2025; Janiesch et al., 2021; Wang, 2025).

En términos metodológicos, el proceso suele incluir preparación de datos, selección de variables, entrenamiento del modelo, validación y evaluación con métricas de desempeño. La calidad del modelo depende tanto del algoritmo como de la calidad y representatividad de los datos, por lo que la validación cruzada y el ajuste de hiperparámetros son etapas críticas en investigaciones aplicadas. Esto significa que el aprendizaje automático aplicado en la investigación sirve tanto para predecir como para identificar qué variables tienen mayor peso en el comportamiento mecánico del acero. (Wang, 2025). Dentro de este estudio se emplearon tres modelos de aprendizaje automático: Random Forest, XG Boost y redes neuronales artificiales, cada uno con características particulares.

### 2.2.1 Random Forest

Este es un modelo de aprendizaje supervisado que combina múltiples árboles de decisión contruidos sobre subconjuntos aleatorios de los datos y de las variables.

El modelo Random Forest puede emplearse tanto para tareas de clasificación como de regresión, manteniendo en ambos casos la misma filosofía de funcionamiento basada en el aprendizaje por ensamble. Su funcionamiento consiste en construir múltiples árboles de decisión a partir de diferentes subconjuntos de datos y variables, de manera que cada árbol capture una parte de los patrones presentes en la información. Posteriormente, las predicciones individuales se combinan mediante un mecanismo de agregación para obtener una predicción final más robusta. En problemas de regresión, esta agregación suele realizarse mediante el promedio de las predicciones de los árboles, aunque existen variantes que utilizan otras medidas de tendencia central, como la mediana. En problemas de clasificación, la decisión final puede obtenerse mediante votación mayoritaria o mediante el promedio de las probabilidades estimadas por cada árbol. Esta estrategia de agregación

permite reducir la varianza del modelo y mejorar su capacidad de generalización, disminuyendo el riesgo de sobreajuste en comparación con un árbol de decisión individual. (Dutta et al., 2021; Gustafsson, 2019; Song, 2023).

Este modelo es útil cuando existen relaciones no lineales, interacciones complejas entre variables y ruido en los datos, porque puede capturar estructuras difíciles de representar con modelos lineales. En investigaciones de materiales, Random Forest suele funcionar bien cuando la composición química y el tratamiento térmico interactúan de forma no trivial, porque no exige supuestos estrictos sobre la forma de la relación entre variables. (Gustafsson, 2019)




Figura 2. Funcionamiento de random forest (Figura generada con la IA Gemini)

## 2.2.2 XG Boost

El aumento de gradiente extremo (*Extreme Gradient Boosting*), más conocido como XG Boost, es un modelo basado en técnicas de boostig que construye árboles de manera secuencial, donde cada nuevo árbol intenta corregir los errores del conjunto anterior. Adicionalmente, XG Boost ha sido ampliamente reconocido en la literatura por su eficiencia computacional y su capacidad para manejar grandes volúmenes de datos y relaciones no lineales complejas ya que este aprende de forma iterativa para minimizar una función de pérdida mediante gradiente descendente y regularización. Esa combinación de secuencialidad y regularización suele darle muy buen desempeño en datos tabulares, especialmente cuando hay relaciones complejas y no lineales. (Chen & Guestrin, 2016; Gustafsson, 2019; Onyebueke et al., 2023).

Este modelo es bueno cuando se busca alta precisión predictiva en conjuntos de datos estructurados, como bases experimentales de materiales con variables de composición, temperatura, tiempo de tratamiento o condición mecánica. Su ventaja principal es que suele capturar patrones sutiles mejor que modelos más simples, aunque puede ser más sensible al ajuste de hiperparámetros y al riesgo de sobreajuste si no se valida correctamente. (Gustafsson, 2019; Onyebueke et al., 2023).




Figura 3. Funcionamiento del XG Boost (Figura generada con la IA Gemini)

### 2.2.3 Redes neuronales artificiales

Las redes neuronales son modelos inspirados en el funcionamiento y la estructura del cerebro que consisten en capas de nodos conectados que procesan la información de manera jerárquica. Estas redes son capaces de modelar relaciones altamente no lineales y complejas entre variables ya que durante el entrenamiento, el modelo ajusta esos pesos para reducir el error entre predicción y valor real mediante retropropagación y optimización numérica, siendo especialmente útiles en problemas donde existen interacciones difíciles de representar mediante modelos tradicionales. Sin embargo, su desempeño depende en gran medida de la cantidad y calidad de los datos disponibles, y pueden ser más sensibles a problemas como el sobreajuste o la falta de información representativa. Son especialmente útiles cuando la relación entre composición, proceso y propiedad no puede describirse bien con funciones simples. Sin embargo, suelen requerir más datos, más cuidado en la normalización de variables y más control del sobreajuste que modelos como Random Forest o XG Boost. (Gustafsson, 2019; Wang, 2025)




Figura 4. Funcionamiento de las redes neuronales (Figura generada con la IA Gemini)

### 2.2.4 Métricas de evaluación

Para evaluar el desempeño de los diferentes modelos, se emplean métricas de regresión ampliamente utilizadas en la literatura, como  $R^2$ , MAE, RMSE y MAPE. El coeficiente de determinación ( $R^2$ ) mide la proporción de la variabilidad de la característica objetivo que es explicada por el modelo. Su valor suele interpretarse entre 0 y 1, donde valores cercanos a 1 indican mejor ajuste, aunque también puede ser negativo si el modelo predice peor que usar el promedio de los datos observados. Se calcula como  $R^2 = 1 - \frac{SS_{res}}{SS_{tot}}$ , donde  $SS_{res}$  es la suma de errores cuadrados del modelo y  $SS_{tot}$  es la variabilidad total de los datos. Sin embargo, un  $R^2$  cercano a 1 no garantiza por sí solo que el modelo sea bueno ya que no informa el tamaño real del error. (Botchkarev, 2018; Chicco et al., 2021).

El error absoluto medio (MAE), mide el promedio de las diferencias absolutas entre valores reales y predichos siendo una métrica fácil de interpretar al interpretar su valor directamente en las mismas unidades de la variable objetivo. se calcula como  $MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$ , y cuanto menor sea, mejor es el modelo. (Botchkarev, 2018; Chicco et al., 2021).

El RMSE, o raíz del error cuadrático medio, penaliza más los errores grandes porque eleva al cuadrado las desviaciones antes de promediarlas; luego aplica raíz cuadrada para volver a las mismas unidades de la variable objetivo y se calcula  $RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$ , y también se considera que el modelo es mejor cuanto menor sea su valor. (Botchkarev, 2018; Chicco et al., 2021).

Por último, se tiene el error porcentual absoluto medio (MAPE), el cual expresa el error promedio en porcentaje respecto al valor real. Este se calcula como  $MAPE = \frac{100}{n} \sum \left| \frac{y_i - \hat{y}_i}{y_i} \right|$ , por lo que resulta útil para comunicar el error de forma intuitiva. (Botchkarev, 2018; Chicco et al., 2021). Su limitación principal es que se vuelve problemático cuando hay valores reales cercanos a cero, ya que el denominador puede inflar artificialmente el error. (Botchkarev, 2018; Chicco et al., 2021).

## 2.3 La ciencia de datos en la ciencia de los materiales

La aplicación del aprendizaje automático en el dominio de los materiales metálicos ha emergido como una línea de investigación muy prometedora, en la cual se busca modelar las relaciones complejas entre composición química, microestructura, procesamiento y propiedades mecánicas. Por ejemplo, (Xiong et al., 2020) utilizaron 360 muestras de aceros al carbono y de baja aleación provenientes de la base de datos NIMS para predecir propiedades mecánicas como resistencia a la

fatiga, resistencia a la tracción, resistencia a la fractura y dureza mediante diferentes algoritmos de aprendizaje automático. Los autores identificaron que variables como la temperatura de revenido y los elementos de aleación carbono, cromo y molibdeno presentaban una influencia significativa sobre las propiedades mecánicas del acero. Adicionalmente, emplearon técnicas de regresión simbólica para obtener ecuaciones matemáticas interpretables y proponer el diseño de nuevos materiales con altas prestaciones mecánicas. Aunque este trabajo demuestra el potencial de la informática de materiales (*materials informatics*) para el descubrimiento de nuevos aceros, la presente investigación se enfoca en la comparación de múltiples modelos predictivos, la evaluación de su desempeño para la predicción simultánea de propiedades mecánicas y la implementación de escenarios de aplicación orientados a apoyar procesos de selección y diseño de materiales en contextos de ingeniería.

Asimismo, investigaciones más recientes amplían el alcance y refinan la metodología, empleando composición, procesamiento, microestructura, defectos y condiciones extremas como la temperatura elevada. En la investigación llevada a cabo por Shaheen, se puede reflejar el desarrollo de modelos supervisados capaces de estimar resistencia a la fluencia, módulo de elasticidad y esfuerzo máximo para aceros de alta resistencia bajo temperaturas elevadas, alcanzando una precisión significativamente alta. (Shaheen et al., 2022). De igual forma, la revisión realizada por Frydrych, Karimi, Pecelerowicz, Alvarez, Dominguez-Gutiérrez, Rovaris y Papanikolaou, aborda cómo los métodos de regresión y clasificación se han utilizado para predecir propiedades mecánicas a partir de grandes volúmenes de datos experimentales o simulados, destacando que el mayor reto está en la calidad de los datos, la integración de microestructura y la interpretabilidad del modelo. (Frydrych et al., 2021). Tales avances posicionan al aprendizaje automático no sólo como herramienta predictiva, sino también como vía para descubrir relaciones de causalidad y optimizar el diseño de materiales hacia resultados más rápidos, eficientes y menos costosos.

Cuando se tienen suficientes datos, se pueden desarrollar modelos para la detección de reglas físicas como lo son las propiedades mecánicas de los materiales, ya que una computadora es capaz de determinar las leyes físicas que conducen a los datos dados sin entrada humana. Esto es posible gracias a que los enfoques de aprendizaje automático aprenden las reglas que subyacen a un conjunto de datos evaluando una parte de esos datos y construyendo un modelo para hacer predicciones, sin embargo, para que esta tarea tenga buenos resultados, el ser humano debe elegir y/o diseñar correctamente modelos de aprendizaje de máquina adecuados que representen correctamente los datos. (Stoll & Benner, 2021).

## **2.4 Dataset: Materials and their Mechanical Properties**

Para conocer más a fondo el dataset, se realizó una búsqueda exhaustiva sobre el mismo. El dataset “*Materials and their Mechanical Properties*” encontrada en (*Materials and Their Mechanical Properties*, s/f-b), fue publicado el 15 de abril de 2023 por Purushottam Nawale. Este dataset

recopila propiedades mecánicas de distintos materiales con composiciones químicas variadas, incluyendo aleaciones metálicas, polímeros, cerámicas, entre otros.

El dataset tiene un tamaño de ~142 KB, lo que se traduce a 1552 registros equivalentes a un total de 17918 datos. Sin embargo, hay que tener en cuenta que no todos los datos fueron utilizados ya que el dataset contiene información de otro tipo de materiales. Al aplicar los filtros y realizar la limpieza del mismo, se obtuvo un total de 344 registros, equivalente a 4128 datos realmente empleados provenientes de este dataset. Adicionalmente, se debe tener en cuenta la realización del dataset sintético que, junto al dataset “*Materials and their Mechanical Properties*” se obtienen los mismo 344 registros pero con un total de 6536 datos, ya que se añaden las nuevas columnas del dataset sintético. Esta es una cantidad de registros suficiente para explorar relaciones entre composiciones, condiciones, origen y propiedades mecánicas. Esta afirmación se efectúa gracias

a (Xiong et al., 2020), ya que en su investigación se desarrollaron modelos predictivos para propiedades mecánicas de aceros utilizando 360 muestras experimentales, equivalentes a 5760 datos, obteniendo resultados satisfactorios con algoritmos como Random Forest. De igual forma, la literatura reconoce que el desempeño de diferentes modelos depende de la cantidad de datos disponibles ya que un modelo como el Random Forest tiende a alcanzar la estabilidad con aproximadamente 3400 datos, el XGBoost converge a su máximo rendimiento con aproximadamente 9800 datos y el modelo de Redes Neuronales con cerca de 12000 datos. (Silvey et al., 2026; Silvey & Liu, 2024)

Está estructurada en dos archivos CSV que incluyen variables de entrada como lo son la composición, tratamiento, clase de material, entre otros y variables de salida que representan las propiedades mecánicas. El archivo anexo CSV llamado “data.csv”, se encuentran las siguientes variables:

|   |                |                                        |
|---|----------------|----------------------------------------|
| 1 | STD            | Estándar de referencia                 |
| 2 | ID             | Identificador único de material        |
| 3 | Material       | Nombre del material                    |
| 4 | Heat treatment | Tratamiento térmico aplicado           |
| 5 | Su             | Resistencia última a la tracción (MPa) |
| 6 | Sy             | Límite elástico (MPa)                  |
| 7 | A5             | Elongación (%)                         |
| 8 | Bhn            | Dureza Brinell (BHN)                   |

|    |      |                                    |
|----|------|------------------------------------|
| 9  | E    | Módulo de elasticidad (MPa)        |
| 10 | G    | Módulo de corte (MPa)              |
| 11 | mu   | Coefficiente de Poisson            |
| 12 | Ro   | Densidad (Kg/m3)                   |
| 13 | pH   | Presión en el límite elástico      |
| 14 | Desc | Descripción adicional del material |
| 15 | HV   | Dureza Vickers                     |

Tabla 1. Variables del dataset original





## **3.2 Comprensión de los datos**

La fase de comprensión de los datos tuvo diferentes retos. En primera instancia, se realizó una exploración del dataset para identificar su estructura, calidad, origen y consistencia. En este se encontraron múltiples valores faltantes, los cuales se eliminaron del dataset al igual que las columnas no relevantes. El número de muestras se redujo significativamente, sin embargo, no se encontró un dataset o una base de datos similar para complementar la anterior.

En esta fase se identificaron las variables clave asociadas a la composición química, los tratamientos térmicos y las propiedades mecánicas de los aceros, lo cual ayudó más adelante a establecer las características con mayor influencia en el desarrollo de modelos de machine learning.

Para entender más a fondo el dataset, se realizó un análisis exploratorio profundo de los datos (EDA), generando visualizaciones, estadísticas descriptivas y evaluaciones preliminares que ayudaron a identificar patrones, anomalías y relaciones entre las diferentes variables.

## **3.3 Preparación de los datos**

El proceso de la preparación de los datos se basó en la aplicación de diferentes filtros y la creación de datos sintéticos según la literatura para complementar aún mejor el dataset original.

### **3.3.1 Dataset original**

El dataset original viene con materiales como cerámicos, siliconas y otros metales que no se querían incluir en el desarrollo del proyecto, así que el primer filtro aplicado permitió dejar en la tabla solo los aceros. Seguido esto, se encontró que el dataset contenía columnas prácticamente vacías que no aportaban datos significativos al desarrollo del proyecto, por lo que se tomó la decisión de eliminar dichas columnas utilizando las librerías NumPy y Pandas. El último factor que se tuvo en cuenta fueron los datos faltantes de la columna de “Heat treatment”, la cual contiene la información de los tratamientos térmicos de cada una de las aleaciones. Esta es una de las columnas más importantes para el desarrollo de los modelos, por lo cual se eliminan las filas con valores faltantes en la misma. Al momento de realizar el análisis exploratorio de datos (EDA), también se emplean librerías como NumPy y Pandas para realizar ciertos análisis previos y se utilizan librerías como Seaborn y Matplotlib para desarrollar temas de visualización de datos y obtener un mejor panorama del dataset original.

### **3.3.2 Dataset sintético**

Posterior a la filtración y limpieza del dataset original, se puso como desafío realizar los modelos con algunas propiedades mecánicas y composiciones químicas de las distintas aleaciones de acero junto con su respectivo tratamiento térmico.

Para llevar esto a la práctica, se desarrolló un dataset sintético, el cual desempeñó un papel fundamental dentro de la presente investigación. Este permitió complementar la información contenida en la base de datos original sin alterar la naturaleza experimental de las propiedades mecánicas utilizadas para el entrenamiento de los modelos ya que la base de datos obtenida de Kaggle contenía información correspondiente a diferentes aceros y sus propiedades mecánicas, sin embargo, no incluía de forma explícita la composición química de cada una de las aleaciones. Esta información extra se torna fundamental para cumplir el objetivo de desarrollar un modelo predictivo basado en la composición química y el tratamiento térmico del material.

Para esto se llevó a cabo una investigación profunda de información metalúrgica y técnica en fuentes académicas e industriales especializadas, como los sitios web AZoM (Material Science | News | Materials Engineering | News, s/f) y Materiales Gelson Luz (Materiales (ES), s/f), en los que se determinaron las proporciones usuales de composición química (porcentaje en peso) de elementos aleantes importantes como carbono (C), manganeso (Mn), silicio (Si), cromo (Cr), níquel (Ni), entre otros vinculados con cada aleación de acero registrada en la base. Conforme a las proporciones, se establecieron límites mínimos y máximos para cada elemento químico en función de la aleación, asegurando la consistencia con los textos metalúrgicos y las regulaciones técnicas vinculadas a los aceros explorados.

Posteriormente, utilizando scripts y funciones desarrollados en Python en el entorno Google Colab, se produjeron valores aleatorios controlados dentro de esos intervalos, garantizando que las composiciones sintéticas sean físicamente creíbles y que reflejen adecuadamente la conducta real de los materiales. Este procedimiento posibilitó extender el conjunto de datos mientras se conservaba la consistencia metalúrgica, disminuir inconvenientes de falta de información química y hacer más sencillo el entrenamiento de modelos predictivos más sólidos, sin incluir combinaciones químicamente inviables o irreales.

El dataset construido consta de los diferentes elementos aleantes presentes en los diferentes tipos de acero, como se muestra en la tabla 2.

|   | C        | Mn       | P        | S        | Si       | Ni  | Cr  | Mo  | Fe        | Aleacion                 |
|---|----------|----------|----------|----------|----------|-----|-----|-----|-----------|--------------------------|
| 0 | 0.649107 | 1.093896 | 0.011472 | 0.328900 | 0.338481 | 0.0 | 0.0 | 0.0 | 97.578144 | Steel 25ChS GOST 4543-71 |
| 1 | 0.661561 | 0.952008 | 0.033726 | 0.190987 | 0.247611 | 0.0 | 0.0 | 0.0 | 97.914108 | Steel 25ChS GOST 4543-71 |
| 2 | 0.664959 | 1.163877 | 0.007215 | 0.254978 | 0.283318 | 0.0 | 0.0 | 0.0 | 97.625653 | Steel 25ChS GOST 4543-71 |
| 3 | 0.640359 | 1.151906 | 0.028972 | 0.011105 | 0.201182 | 0.0 | 0.0 | 0.0 | 97.966475 | Steel 25ChS GOST 4543-71 |
| 4 | 0.686116 | 1.194729 | 0.008613 | 0.177742 | 0.195787 | 0.0 | 0.0 | 0.0 | 97.737013 | Steel 25ChS GOST 4543-71 |

Tabla 2. Dataset sintético

Finalmente, se combinaron las propiedades mecánicas y las variables de proceso filtradas con el dataset sintético. Luego, antes de ser empleada en los procesos de modelación y evaluación, fue sometida a validaciones elementales como la verificación de rangos, la coherencia estadística y la no presencia de valores incoherentes. Esta táctica logró optimizar la habilidad de generalización de los modelos y reforzar el enfoque de ciencia de datos en la predicción del comportamiento mecánico de los aceros.

### **3.4 Modelado**

En la fase de modelado, se llevaron a cabo tres métodos de aprendizaje automático supervisado orientados a la predicción de propiedades mecánicas de las aleaciones de aceros basándose en sus atributos físico-químicos y de proceso. Los modelos escogidos posibilitaron el análisis desde relaciones lineales sencillas hasta patrones no lineales complejos que aparecen en los datos. Esta selección responde a la necesidad de comparar modelos con diferentes niveles de complejidad y capacidad de generalización y analizar su rendimiento utilizando un conjunto idéntico de variables de entrada para predecir las mismas propiedades mecánicas.

El proceso de elección de las variables predictoras requirió de varios ensayos con los tres modelos. Principalmente se tomaron las composiciones químicas sintéticas en las cuales están los porcentajes de carbono (C), manganeso (Mn), fósforo (P), azufre (S), silicio (Si), níquel (Ni), cromo (Cr), molibdeno (Mo) y hierro (Fe) y también por defecto se tomó el tratamiento térmico (Heat treatment) codificado a través de métodos de one-hot encoding. Por otro lado, se hicieron varias pruebas para determinar qué otras características ayudaban al desempeño del modelo, ya que el objetivo principal es la reducción de costos. Se encontró que lo más óptimo era incluir la dureza Brinell (Bhn) y la densidad (RO) en las variables de entrada del modelo.

A diferencia de un enfoque multisalida, en este proyecto se desarrollaron modelos independientes para cada propiedad mecánica objetivo, permitiendo analizar de forma específica el desempeño predictivo para cada una de las propiedades. Las variables de salida del modelo fueron la resistencia última a la tracción (Su), el límite elástico (Sy) y la elongación al 5% (A5). Esta perspectiva permite evaluar la capacidad del modelo para capturar las relaciones particulares entre las variables de entrada y cada respuesta mecánica

Como se mencionó anteriormente, para el modelado se implementaron tres algoritmos con diferentes niveles de complejidad en los cuales están el Random Forest, XG Boost y una red neuronal artificial de tipo MLP Regressor para los cuales se emplearon las bibliotecas de modelado Scikit-learn y xgboost que permitieron importar los estimadores RandomForestRegressor, XGBRegressor y MLPRegressor respectivamente. El Random Forest se escogió por su solidez ante el ruido y las correlaciones entre variables, su habilidad para modelar relaciones no lineales y su óptimo rendimiento en datos tabulares. El XG Boost, que se basa en métodos de boosting sobre árboles de decisión, se empleó por su eficiencia al optimizar modelos complejos y por su gran

capacidad para realizar predicciones. Por último, se utilizó una red neuronal artificial de arquitectura multicapa (MLP) para capturar patrones no lineales y potenciales interacciones complejas entre la composición química, el tratamiento térmico y las propiedades resultantes.

### 3.5 Evaluación

Una vez los modelos fueron entrenados con conjuntos de entrenamiento y prueba previamente definidos, se realizó una evaluación de su rendimiento, aplicando métricas estadísticas de desempeño, con el propósito de cotejar su capacidad para calcular con precisión las propiedades mecánicas de resistencia última a la tracción ( $S_u$ ), límite elástico ( $S_y$ ) y elongación al 5% (A5) de los aceros para cada modelo implementado. Esto permitió realizar comparaciones directas entre algoritmos bajo las mismas condiciones experimentales.

La evaluación se llevó a cabo mediante cuatro métricas estadísticas comúnmente utilizadas en problemas estadísticos para medir el rendimiento, las cuales son: el coeficiente de determinación ( $R^2$ ), el error porcentual absoluto medio (MAPE), el error absoluto medio (MAE) y el error cuadrático medio (RMSE). El coeficiente  $R^2$  permite cuantificar la proporción de la variabilidad de los datos reales que es explicada por el modelo, donde valores próximos a 1 son claros indicios de una alta capacidad para realizar predicciones correctas. El MAPE proporcionó una medida relativa de la equivocación en términos porcentuales, lo que hizo más fácil contrastar propiedades con escalas y magnitudes diferentes, en términos más coloquiales, este indicador dice que el modelo se equivoca en un X%, siendo así valores menores al 10% indicadores de un excelente desempeño. Por otro lado, el MAE realiza la evaluación del error promedio entre los valores reales y los valores predichos utilizando las mismas unidades de la propiedad mecánica evaluada, por lo que se trata de una interpretación directa del error. Por último, el RMSE, al castigar más los errores de gran magnitud, ayudó a detectar modelos con predicciones inestables o que tenían valores atípicos mal calculados.

Adicionalmente, con el propósito de evaluar la robustez y la capacidad de generalización de los modelos desarrollados, se implementó una validación cruzada mediante la técnica K-Fold. Para ello, se utilizó una configuración de cinco particiones ( $n\_splits=5$ ), con mezclado aleatorio de los datos ( $shuffle=True$ ) y una semilla fija ( $random\_state=50$ ) para garantizar la reproducibilidad de los resultados. Este procedimiento se aplicó a los modelos Random Forest, XGBoost y MLPRegressor en la predicción de las propiedades mecánicas resistencia a la tracción ( $S_u$ ), límite elástico ( $S_y$ ), elongación (A5), módulo de elasticidad (E) y módulo de corte (G). En cada iteración, el conjunto de entrenamiento fue dividido en cinco subconjuntos, utilizando cuatro de ellos para el entrenamiento del modelo y el restante para la validación, repitiendo el proceso hasta completar las cinco particiones. Como métrica de evaluación se empleó el coeficiente de determinación ( $R^2$ ), calculando posteriormente el valor promedio y la desviación estándar obtenidos en las diferentes particiones.

Esta metodología permitió evaluar no solo el desempeño medio de los modelos, sino también su estabilidad y consistencia frente a diferentes divisiones de los datos.

La integración de estas métricas posibilitó una evaluación completa del rendimiento de cada modelo, evitando la dependencia exclusiva de un solo indicador. Así se pudo determinar qué algoritmo tiene mejor balance entre estabilidad, precisión y capacidad de generalización para cada propiedad mecánica analizada. Esto permitió escoger el modelo más apropiado para cada propiedad y tenerlo en cuenta para futuras aplicaciones en la optimización del diseño de aleaciones y en la predicción del comportamiento mecánico de las aleaciones de los aceros.

## 4 Resultados

Esta sección muestra los resultados obtenidos durante la evaluación y desarrollo de modelos de aprendizaje automático que se aplicaron para la predicción de las propiedades mecánicas de aceros con composiciones químicas y tratamientos térmicos diversos. Se presentan los resultados obtenidos del análisis de datos procesados, así como el rendimiento logrado por cada modelo a través de las métricas de evaluación definidas, lo que facilita la comparación entre su estabilidad y su capacidad predictiva.

Los hallazgos posibilitan el análisis de la conexión entre las variables de entrada y las propiedades mecánicas calculadas, así como determinar cuál modelo es el que brinda un rendimiento superior para cada propiedad analizada. Para verificar el uso de las técnicas de aprendizaje automático como instrumento auxiliar en la caracterización y selección de materiales, disminuyendo la dependencia de los ensayos experimentales tradicionales, este análisis es un paso esencial.

Antes del tratamiento de los datos, se debe tener en cuenta la estructura inicial con la que se inició a trabajar todo el proyecto, como se evidencia en la tabla 3.

|   | Std  | ID                               | Material       | Heat treatment | Su  | Sy  | A5   | Bhn   | E      | G     | mu  | Ro   | pH    | Desc | HV  |
|---|------|----------------------------------|----------------|----------------|-----|-----|------|-------|--------|-------|-----|------|-------|------|-----|
| 0 | ANSI | D8894772B88F495093C43AF905AB6373 | Steel SAE 1015 | as-rolled      | 421 | 314 | 39.0 | 126.0 | 207000 | 79000 | 0.3 | 7860 | NaN   | NaN  | NaN |
| 1 | ANSI | 05982AC66F064F9EBC709E7A4164613A | Steel SAE 1015 | normalized     | 424 | 324 | 37.0 | 121.0 | 207000 | 79000 | 0.3 | 7860 | NaN   | NaN  | NaN |
| 2 | ANSI | 356D6E63FF9A49A3AB23BF66BAC85DC3 | Steel SAE 1015 | annealed       | 386 | 284 | 37.0 | 111.0 | 207000 | 79000 | 0.3 | 7860 | NaN   | NaN  | NaN |
| 3 | ANSI | 1C758F8714AC4E0D9BD8D8AE1625AECD | Steel SAE 1020 | as-rolled      | 448 | 331 | 36.0 | 143.0 | 207000 | 79000 | 0.3 | 7860 | NaN   | NaN  | NaN |
| 4 | ANSI | DCE10036FC1946FC8C9108D598D116AD | Steel SAE 1020 | normalized     | 441 | 346 | 35.8 | 131.0 | 207000 | 79000 | 0.3 | 7860 | 550.0 | NaN  | NaN |

Tabla 3. Estructura de la tabla original

### 4.1 Limpieza y aplicación de filtros

Ya que el dataset contenía diversos materiales, el primer paso para preparar el conjunto de datos fue un proceso de filtrado, con el propósito de garantizar que la investigación se centrara únicamente en los materiales relevantes. Se empleó un filtro en la columna “Material” para mantener solo aquellos registros que incluyeran la palabra “Steel”. De esa manera se aseguró que el conjunto final de los datos solo incluyera aceros, eludiendo la inclusión de variabilidad relacionada con otros materiales que tienen comportamientos mecánicos diferentes.

Posteriormente, se realizó un análisis con el fin de detectar la existencia de valores faltantes en cada columna del conjunto de datos. Este método posibilitó la cuantificación de los registros incompletos y el análisis de su posible efecto en el entrenamiento de los modelos de machine learning. Detectar los datos faltantes es un paso crucial, ya que, si no se gestionan correctamente, estos pueden introducir sesgos o perjudicar la capacidad predictiva de los modelos. Tras este diagnóstico se procedió a eliminar aquellos registros que presentaban valores faltantes en la columna “Heat treatment”, debido a que esta variable es una de las más influyentes sobre las propiedades

mecánicas del acero y es esencial para entrenar modelos predictivos. Conservar registros sin esos datos habría disminuido la calidad del entrenamiento y puesto en riesgo la coherencia de los resultados. Por otro lado, los valores faltantes.

Por último, se estandarizó la escritura de los nombres de los tratamientos térmicos mediante el uso consistente de mayúsculas iniciales. Aunque esta transformación no afecta directamente el rendimiento de los modelos, contribuye a la calidad y consistencia del dataset al evitar categorías duplicadas originadas por diferencias en la escritura.

## 4.2 Análisis exploratorio de datos (EDA)

El apartado de análisis exploratorio de datos se llevó a cabo en 2 etapas. La primera corresponde a las tablas de contenido y al análisis estadístico del dataset y la segunda se centra en los diferentes hallazgos obtenidos mediante gráficas y comparaciones entre las columnas.

|                       |         |
|-----------------------|---------|
| <b>Std</b>            | object  |
| <b>ID</b>             | object  |
| <b>Material</b>       | object  |
| <b>Heat treatment</b> | object  |
| <b>Su</b>             | int64   |
| <b>Sy</b>             | int64   |
| <b>A5</b>             | float64 |
| <b>Bhn</b>            | float64 |
| <b>E</b>              | int64   |
| <b>G</b>              | int64   |
| <b>mu</b>             | float64 |
| <b>Ro</b>             | int64   |
| <b>pH</b>             | float64 |
| <b>Desc</b>           | object  |
| <b>HV</b>             | float64 |

Figura 6. Tipos de datos

|                       |     |
|-----------------------|-----|
| <b>Std</b>            | 0   |
| <b>ID</b>             | 0   |
| <b>Material</b>       | 0   |
| <b>Heat treatment</b> | 59  |
| <b>Su</b>             | 0   |
| <b>Sy</b>             | 0   |
| <b>A5</b>             | 68  |
| <b>Bhn</b>            | 176 |
| <b>E</b>              | 0   |
| <b>G</b>              | 0   |
| <b>mu</b>             | 0   |
| <b>Ro</b>             | 0   |
| <b>pH</b>             | 435 |
| <b>Desc</b>           | 109 |
| <b>HV</b>             | 454 |

Figura 7. Cantidad de datos faltantes



|       | Su          | Sy          | A5         | Bhn        | E             | G             | mu         | Ro          | pH          | HV  |
|-------|-------------|-------------|------------|------------|---------------|---------------|------------|-------------|-------------|-----|
| count | 395.000000  | 395.000000  | 327.000000 | 243.000000 | 395.000000    | 395.000000    | 395.000000 | 395.000000  | 17.000000   | 0.0 |
| mean  | 805.972152  | 557.582278  | 19.325382  | 237.358025 | 205118.987342 | 166594.936709 | 0.297139   | 7865.916456 | 729.411765  | NaN |
| std   | 362.635820  | 368.923458  | 11.169739  | 108.278220 | 5498.824885   | 226597.818939 | 0.004525   | 68.778284   | 383.723054  | NaN |
| min   | 290.000000  | 190.000000  | 1.000000   | 111.000000 | 193000.000000 | 77000.000000  | 0.290000   | 7640.000000 | 310.000000  | NaN |
| 25%   | 575.000000  | 320.000000  | 12.000000  | 170.000000 | 200000.000000 | 79000.000000  | 0.290000   | 7820.000000 | 420.000000  | NaN |
| 50%   | 689.000000  | 405.000000  | 17.000000  | 207.000000 | 206000.000000 | 79000.000000  | 0.300000   | 7860.000000 | 550.000000  | NaN |
| 75%   | 916.000000  | 650.000000  | 23.000000  | 255.000000 | 207000.000000 | 82000.000000  | 0.300000   | 7860.000000 | 1210.000000 | NaN |
| max   | 2220.000000 | 2048.000000 | 60.000000  | 627.000000 | 219000.000000 | 769000.000000 | 0.300000   | 8030.000000 | 1300.000000 | NaN |

Figura 8. Estadística descriptiva

En la primera parte del análisis exploratorio de datos se logró verificar la estructura y calidad general del conjunto de datos utilizado en el estudio. Se determinó que las variables relacionadas con propiedades físicas y mecánicas fueron correctamente comprendidas como datos numéricos. Por otro lado, los campos vinculados al estándar identificador, material y tratamiento térmico permanecen siendo variables categóricas, lo cual es consistente con el carácter descriptivo de los atributos. Esta categorización corrobora que las variables mecánicas se pueden usar directamente en los modelos, pero las variables categóricas necesitan ser codificadas antes de ser incluidas en los modelos de aprendizaje automático.

El resumen estadístico revela que las variables contienen cerca de 395 registros válidos, una cantidad adecuada para el entrenamiento de los modelos supervisados clásicos. No obstante, uno de los factores más importantes a analizar son los valores faltantes, ya que esta métrica permite determinar si hay algunos valores en ciertas columnas que pueden ser imputados o si la mejor decisión es eliminar el registro. En los registros se detectan valores ausentes en ciertas propiedades, especialmente en dureza Brinell (Bhn) y elongación (A5), aunque variables como el pH y la dureza Vickers (HV) tienen poca o ninguna información disponible. Esta conducta avaló la exclusión o el tratamiento particularizado de estas dos últimas variables a lo largo de la preparación del conjunto de datos, dando prioridad a aquellas características que eran más completas y relevantes para el modelo.

El análisis de las distribuciones muestra también que características como el límite elástico (Sy) y la resistencia última a la tracción (Su) tienen distribuciones asimétricas. Estas distribuciones se concentran en rangos medios y tienen una cola hacia valores altos, lo cual está ligado a aceros resistentes. Durante la formación de los modelos, hay que tener en cuenta la existencia de estos valores extremos, ya que tienen el potencial de afectar la estabilidad y exactitud de las predicciones. Adicionalmente, variables como el módulo de elasticidad (E), el módulo de corte (G) o el coeficiente de Poisson (mu) presentan distribuciones altamente concentradas alrededor de valores típicos de los aceros, lo cual confirma que estas propiedades varían poco entre aleaciones ferrosas y dependen principalmente de la estructura cristalina del material más que del tratamiento térmico. De manera semejante, la densidad muestra una dispersión baja, acorde con los materiales que tienen

como base el hierro. Sin embargo, se pueden apreciar diferencias que se deben a la presencia de elementos aleantes o variaciones en la composición química.




Figura 9. Distribución de variables numéricas




Figura 10. Boxplot para cada variable

Los histogramas son una gran ayuda visual que permite observar la distribución de los valores de cada propiedad dentro del conjunto de datos, evidenciando la frecuencia con que aparecen ciertos rangos. La distribución de la resistencia última a la tracción ( $S_u$ ) es notablemente asimétrica a la izquierda, teniendo una concentración de datos más alta entre 450 a 800 MPa. Para el límite elástico ( $S_y$ ) muestra un comportamiento similar con una concentración de datos más evidente entre 200 a 500 MPa. La elongación al 5% ( $A_5$ ) presenta una distribución más dispersa con la mayoría de valores entre el 10 y 20%. La dureza de Brinell ( $B_{hn}$ ) muestra un comportamiento semejante al de las resistencias mecánicas: predominan valores entre 150 y 250 HB, aunque se encuentran también materiales con una dureza por encima de 400 HB, lo que sugiere la presencia de aceros endurecidos. Al igual que se dedujo del análisis estadístico, el módulo de elasticidad ( $E$ ), el coeficiente de Poisson ( $\mu$ ) y la densidad ( $R_o$ ) muestran una distribución muy concentrada en torno a valores típicos del acero, lo que es consistente con la teoría de materiales. Finalmente, la variable pH muestra una escasez de datos y una amplia dispersión, lo que sugiere que esta variable no tiene una estructura constante dentro del conjunto de datos y es posible que no sea útil para modelar.

Por otra parte, los diagramas de caja permiten identificar la presencia de valores atípicos en cada propiedad. Para la resistencia última a la tracción ( $S_u$ ) y el límite elástico ( $S_y$ ), se puede evidenciar una cantidad considerable de puntos por encima del rango intercuartílico, lo que confirma la presencia de aceros de muy alta resistencia. La dureza de Brinell ( $B_{hn}$ ) muestra números valores extremos, esto es coherente con características de aceros endurecidos, lo que puede llegar a ser muy útil para el entrenamiento de los modelos. La propiedad con más motivos de análisis detallado es el módulo de corte ( $G$ ) ya que presenta algunos valores extremadamente altos, lo que puede indicar errores en las mediciones o un cambio en las unidades.




Figura 11. Matriz de correlación

La matriz de correlación, como su nombre lo indica, permite entender cómo se relacionan las diferentes propiedades entre sí y da opciones de posibles variables predictoras. La correlación más destacada está entre la resistencia última a la tracción ( $S_u$ ) y el límite elástico ( $S_y$ ) con un valor del 0.96, lo cual confirma que ambas propiedades están fuertemente relacionadas, cuando aumenta una, aumenta la otra. La dureza de Brinell ( $B_{hn}$ ) muestra una correlación del 0.94 - 0.96 con el límite elástico ( $S_y$ ) y la resistencia última a la tracción ( $S_u$ ) respectivamente, lo que indica que esta característica puede funcionar como un buen predictor indirecto. Por otro lado, la elongación ( $A_5$ ) presenta correlaciones negativas, lo que físicamente es coherente, ya que a mayor resistencia, menor es la ductilidad. Una relación interesante se presenta en el módulo de corte ( $G$ ) y la densidad ( $R_o$ ), sin embargo, estas pueden deberse a la forma en la que fueron calculados.




Figura 12. Conteo de tratamientos térmicos

La gráfica de conteo de tratamientos térmicos muestra una distribución claramente desigual en la frecuencia de registros asociados a cada condición de procesamiento. Se evidencia que los tratamientos “Normalized”, “Quenched and tempered” y “Annealed” concentran la mayor cantidad de datos dentro del conjunto, lo cual indica que estos estados metalúrgicos son los más reportados en la literatura y en bases de datos industriales, probablemente debido a que representan

condiciones comunes de suministro y uso de aceros estructurales e industriales. En contraste, tratamientos más específicos o combinaciones particulares de endurecimiento, temple y revenido aparecen con una frecuencia considerablemente menor, generando una larga cola de categorías con pocos registros. Esta distribución implica que el modelo de aprendizaje automático contará con abundante información para aprender patrones en los tratamientos más comunes, pero tendrá menor capacidad de generalización para tratamientos poco representados. Por ello, resulta importante considerar estrategias de agrupación o normalización de categorías durante el modelado para evitar sesgos y mejorar la estabilidad de las predicciones cuando se enfrenten a tratamientos térmicos menos frecuentes.

### **4.3 Preparación de los datos**

Tras la etapa del análisis exploratorio de datos, se llevó a cabo la limpieza y preparación del conjunto de datos para asegurar su calidad y consistencia antes del modelado. Primero, se detectaron los outliers en la columna del módulo de corte (G), con registros mayores a 100000. Físicamente estos valores no son consistentes para aceros estructurales, ya que el módulo de corte para los aceros en la literatura no es mayor a 85000. Por lo tanto, estos registros se eliminaron del conjunto de datos para no generar sesgos en el entrenamiento de los modelos.

A continuación se eliminaron las columnas “pH”, “Desc” y “HV”, ya que contenían muy pocos datos válidos o estaban prácticamente vacías. Fijar estas variables habría añadido demasiado ruido innecesario y habría aumentado la dimensionalidad del problema sin mejorar la capacidad predictiva. Esta elección simplificó el conjunto de datos y se centró en las variables más completas y físicamente significativas.

Debido a los datos faltantes en las columnas de elongación (A5) y dureza de Brinell (Bhn), fue necesario realizar una imputación de datos con el fin de conservar el mayor número posible de registros disponibles para el entrenamiento de los modelos. Para ello se empleó un modelo RandomForestRegressor. Este modelo fue capaz de predecir los valores faltantes en función de las demás variables disponibles, aprendiendo relaciones no lineales entre la composición, el tratamiento térmico y las propiedades mecánicas. Se seleccionó este método por su robustez frente a distribuciones no normales y su capacidad para modelar interacciones complejas. La imputación se realizó aprovechando la información contenida en las demás variables del conjunto de datos, bajo el supuesto de que las propiedades mecánicas de los aceros presentan una fuerte interdependencia derivada de su composición química, tratamiento térmico y comportamiento metalúrgico. De esta manera, los valores estimados para A5 y Bhn fueron consistentes con los patrones presentes en los datos experimentales y permitieron disponer de un conjunto de datos completo para el desarrollo de los modelos predictivos. No obstante, es importante reconocer que esta estrategia puede introducir un grado de dependencia entre algunas variables mecánicas, debido a que las propiedades utilizadas durante la imputación también forman parte del conjunto de variables analizadas en la investigación. En consecuencia, existe la posibilidad de una fuga parcial de información,

especialmente en aquellos escenarios donde A5 o Bhn fueron empleadas posteriormente como variables de entrada para predecir otras propiedades mecánicas. Sin embargo, esta decisión respondió al objetivo de preservar la cantidad de información disponible en un conjunto de datos relativamente reducido, evitando la eliminación de un número considerable de registros que habría disminuido la capacidad de aprendizaje de los modelos.

Luego, se validó la coherencia estructural entre el dataset original de propiedades mecánicas y el dataset sintético de composiciones químicas creado anteriormente. Se verificó que ambos conjuntos tuvieran la misma cantidad de registros, asegurando así que a cada material le correspondiera una única composición química. Esta verificación fue crucial para garantizar la integridad de los conjuntos de datos al momento de combinarlos y prevenir errores en el entrenamiento de los modelos.

|   | Std  | ID                               | Material       | Heat treatment | Su  | Sy  | A5   | Bhn   | E      | G     | mu  | Ro   |
|---|------|----------------------------------|----------------|----------------|-----|-----|------|-------|--------|-------|-----|------|
| 0 | ANSI | D8894772B88F495093C43AF905AB6373 | Steel SAE 1015 | As-rolled      | 421 | 314 | 39.0 | 126.0 | 207000 | 79000 | 0.3 | 7860 |
| 1 | ANSI | 05982AC66F064F9EBC709E7A4164613A | Steel SAE 1015 | Normalized     | 424 | 324 | 37.0 | 121.0 | 207000 | 79000 | 0.3 | 7860 |
| 2 | ANSI | 356D6E63FF9A49A3AB23BF66BAC85DC3 | Steel SAE 1015 | Annealed       | 386 | 284 | 37.0 | 111.0 | 207000 | 79000 | 0.3 | 7860 |
| 3 | ANSI | 1C758F8714AC4E0D9BD8D8AE1625AEC  | Steel SAE 1020 | As-rolled      | 448 | 331 | 36.0 | 143.0 | 207000 | 79000 | 0.3 | 7860 |
| 4 | ANSI | DCE10036FC1946FC8C9108D598D116AD | Steel SAE 1020 | Normalized     | 441 | 346 | 35.8 | 131.0 | 207000 | 79000 | 0.3 | 7860 |

Tabla 4. Dataset original preparado

Como resultado de estas etapas, se generó un conjunto de datos limpio, constante e imputado y sin inconsistencias obvias con alta completitud en las variables de interés. Este último conjunto fue el utilizado para entrenar y probar los modelos de aprendizaje automático desarrollados en la presente investigación.

|   | Material       | Heat treatment | Su  | Sy  | A5   | Bhn   | E     | G    | mu  | Ro   | C        | Mn       | P        | S        | Si  | Ni  | Cr  | Mo  | Fe        |
|---|----------------|----------------|-----|-----|------|-------|-------|------|-----|------|----------|----------|----------|----------|-----|-----|-----|-----|-----------|
| 0 | Steel SAE 1015 | As-rolled      | 421 | 314 | 39.0 | 126.0 | 207.0 | 79.0 | 0.3 | 7860 | 0.136184 | 0.342828 | 0.001075 | 0.007927 | 0.0 | 0.0 | 0.0 | 0.0 | 99.511986 |
| 1 | Steel SAE 1015 | Normalized     | 424 | 324 | 37.0 | 121.0 | 207.0 | 79.0 | 0.3 | 7860 | 0.149983 | 0.563571 | 0.027726 | 0.028617 | 0.0 | 0.0 | 0.0 | 0.0 | 99.230103 |
| 2 | Steel SAE 1015 | Annealed       | 386 | 284 | 37.0 | 111.0 | 207.0 | 79.0 | 0.3 | 7860 | 0.172061 | 0.356569 | 0.002655 | 0.045889 | 0.0 | 0.0 | 0.0 | 0.0 | 99.422826 |
| 3 | Steel SAE 1020 | As-rolled      | 448 | 331 | 36.0 | 143.0 | 207.0 | 79.0 | 0.3 | 7860 | 0.220168 | 0.455266 | 0.027873 | 0.020515 | 0.0 | 0.0 | 0.0 | 0.0 | 99.276178 |
| 4 | Steel SAE 1020 | Normalized     | 441 | 346 | 35.8 | 131.0 | 207.0 | 79.0 | 0.3 | 7860 | 0.222798 | 0.465205 | 0.014807 | 0.036727 | 0.0 | 0.0 | 0.0 | 0.0 | 99.260463 |

Tabla 5. Dataset completo

#### 4.4 Resultados de los modelos

Se entrenaron tres configuraciones experimentales para la predicción de la resistencia última a la tracción (Su), el límite elástico (Sy) y la elongación (A5) cambiando el conjunto de variables de

entrada para determinar la influencia de la información adicional sobre en el desempeño de los modelos.

Para el primer conjunto de variables de entrada, se emplearon únicamente variables de composición química: C, Mn, P, S, Si, Ni, Cr, Mo y Fe junto con el tratamiento térmico. Para el segundo conjunto de variables de entrada, se emplearon las mismas variables de composición química, se mantuvo el tratamiento térmico y adicionalmente se incorporaron Bhn y Ro. Por último, en el tercer conjunto de variables de entrada, se reemplazó Bhn por G y el coeficiente de Poisson.

#### 4.4.1 Su - Resistencia última a la tracción

Bajo la configuración del primer conjunto de variables de entrada, los coeficientes de determinación ( $R^2$ ) se situaron en un rango moderado, alcanzando 0.6 con Random Forest y la red neuronal y 0.5 con XG Boost. Los errores también fueron relativamente elevados, con valores de RMSE superiores a 214 MPa en todos los casos. Estos resultados indican que, si bien la composición química contiene información relevante para estimar la Su, por sí sola no logra capturar por completo la variabilidad del comportamiento mecánico del material.

|                      | $R^2$  | MAPE    | MAE      | RMSE     |
|----------------------|--------|---------|----------|----------|
| <b>Random forest</b> | 0.6391 | 22.5313 | 162.1221 | 218.0130 |
| <b>XG Boost</b>      | 0.5452 | 23.4705 | 179.9533 | 244.755  |
| <b>Red neuronal</b>  | 0.6516 | 19.8582 | 151.3234 | 214.2015 |

Tabla 6. Resultados de Su para la primera configuración

La configuración del segundo conjunto de variables produjo una mejora sustancial en el desempeño de los tres modelos. El  $R^2$  aumentó hasta 0.9 para todos los modelos, mientras que RMSE se redujo significativamente a 89.0651 en el mejor caso. Asimismo, el MAPE descendió a valores cercanos al 9-10 %, evidenciando una predicción considerablemente más precisa. Esta mejora puede deberse a la fuerte correlación existente entre la dureza y la resistencia mecánica, ya observada en el análisis exploratorio, lo que convierte a Bhn en una variable predictora altamente informativa para Su.

|                      | $R^2$  | MAPE    | MAE     | RMSE     |
|----------------------|--------|---------|---------|----------|
| <b>Random forest</b> | 0.9397 | 9.1946  | 63.4536 | 89.0651  |
| <b>XG Boost</b>      | 0.9193 | 9.7670  | 70.4272 | 103.0666 |
| <b>Red neuronal</b>  | 0.9073 | 10.1498 | 75.1956 | 110.4962 |

Tabla 7. Resultados de Su para la segunda configuración

Para el escenario de la tercera configuración, el desempeño volvió a disminuir, con valores de  $R^2$  de 0.6 para Random Forest y 0.5 para XG Boost y la red neuronal. Los errores RMSE fueron similares a los obtenidos en la primera configuración, con un RMSE mayor a 209.626 en todos los casos. Esto indica que, aunque  $G$  y  $\mu$  son propiedades mecánicas vinculadas al comportamiento elástico del material, no proporcionan información tan directamente relacionada con la resistencia última como lo hace la dureza.

|                      | $R^2$  | MAPE    | MAE      | RMSE     |
|----------------------|--------|---------|----------|----------|
| <b>Random forest</b> | 0.6664 | 21.1124 | 153.3419 | 209.626  |
| <b>XG Boost</b>      | 0.5753 | 21.5899 | 167.6976 | 236.5006 |
| <b>Red neuronal</b>  | 0.5665 | 19.0735 | 151.1249 | 238.955  |

Tabla 8. Resultados de Su para la tercera configuración

Resulta evidente que la segunda configuración es la que tiene mejor desempeño para la predicción de la resistencia última a la tracción ( $S_u$ ). Por otro lado, realizando la comparativa entre los modelos, se aprecia que el modelo Random Forest obtuvo el mayor  $R^2$  y los errores más bajos. Estos resultados confirman que la incorporación de variables mecánicas más relacionadas con la resistencia mejora sustancialmente la capacidad predictiva de los modelos, mientras que variables relacionadas principalmente con el comportamiento elástico no generan el mismo impacto en la estimación de la resistencia última a la tracción.

#### 4.4.2 $S_y$ - Límite elástico

Del mismo modo que en el análisis realizado para la resistencia última a la tracción ( $S_u$ ), se evaluó el desempeño de los modelos para predecir el límite elástico ( $S_y$ ) empleando tres configuraciones diferentes de variables de entrada mencionadas anteriormente. El objetivo fue analizar cómo la incorporación de las propiedades adicionales afecta la capacidad predictiva de los modelos.

Para la primera configuración, el modelo Random Forest presentó el mejor desempeño de los tres modelos con un  $R^2$  de 0.7374 y de 0.63 para XG Boost y la red neuronal. Los errores cometidos al predecir los valores fueron relativamente altos, obteniéndose valores de RMSE que oscilaron entre 186 MPa y 220 MPa. Estos resultados indican que la composición química por sí sola permite capturar una parte importante de la variabilidad del límite elástico, aunque no es suficiente para explicar completamente su comportamiento, ya que este también depende de factores microestructurales asociados al procesamiento del material.



|                      | <b>R<sup>2</sup></b> | <b>MAPE</b> | <b>MAE</b> | <b>RMSE</b> |
|----------------------|----------------------|-------------|------------|-------------|
| <b>Random forest</b> | 0.7374               | 25.0759     | 128.6740   | 186.7895    |
| <b>XG Boost</b>      | 0.6329               | 24.9317     | 141.6685   | 220.8605    |
| <b>Red neuronal</b>  | 0.6925               | 21.8521     | 120.3517   | 202.1243    |

Tabla 9. Resultados de Sy para la primera configuración

La segunda configuración resultó en un incremento importante del desempeño de los modelos. En particular, Random Forest obtuvo un  $R^2$  de 0.94, mientras que XG Boost y la red neuronal lograron valores de 0.91 y 0.88 respectivamente. Los errores de predicción se vieron reducidos de forma muy considerable, y el RMSE mínimo fue de 85.21 MPa aproximadamente en el caso de Random Forest con un MAPE del 12.87%. Esta mejora puede deberse a la estrecha relación entre la dureza y las propiedades de resistencia del material, ya que la dureza es un reflejo indirecto de la resistencia del acero a la deformación plástica.

|                      | <b>R<sup>2</sup></b> | <b>MAPE</b> | <b>MAE</b> | <b>RMSE</b> |
|----------------------|----------------------|-------------|------------|-------------|
| <b>Random forest</b> | 0.9453               | 12.8714     | 61.2396    | 85.2121     |
| <b>XG Boost</b>      | 0.9154               | 13.7852     | 70.2808    | 105.9647    |
| <b>Red neuronal</b>  | 0.8803               | 18.5120     | 87.0777    | 126.0930    |

Tabla 10. Resultados de Sy para la segunda configuración

Con la tercera configuración los modelos volvieron a disminuir su desempeño, con resultados muy similares a la primera configuración. Los resultados de  $R^2$  para cada uno de los modelos fueron de 0.74 para Random Forest, mientras que para XG Boost y la red neuronal fueron de 0.62 y 0.49 respectivamente. Se mantuvieron errores de predicción elevados, con RMSE cercanos a los 184–257 MPa y errores porcentuales mayores a 24%.

|                      | <b>R<sup>2</sup></b> | <b>MAPE</b> | <b>MAE</b> | <b>RMSE</b> |
|----------------------|----------------------|-------------|------------|-------------|
| <b>Random forest</b> | 0.7448               | 24.7745     | 128.3778   | 184.1357    |
| <b>XG Boost</b>      | 0.6221               | 24.2706     | 143.0940   | 224.0808    |
| <b>Red neuronal</b>  | 0.4996               | 28.5142     | 156.5624   | 257.8517    |

Tabla 11. Resultados de Sy para la tercera configuración

Nuevamente se puede apreciar un mayor rendimiento con la segunda configuración. Esto puede exponer a la dureza Brinell como una mejor variable de entrada ya que mejora significativamente la capacidad predictiva de los modelos para estimar el límite elástico. Entre los modelos evaluados, el Random Forest presento el mejor desempeño en las tres configuraciones analizadas evidenciando su capacidad para capturar relaciones no lineales.

#### 4.4.3 A5 - Elongación

Para la propiedad de la elongación se realizó exactamente el mismo ejercicio que se desarrolló con Su y Sy. La predicción de la elongación al 5% (A5) se evaluó mediante las mismas tres configuraciones de entrada, con el objetivo de analizar el impacto de diferentes tipos de información sobre la capacidad de los diferentes modelos para estimar esta propiedad mecánica. A diferencia de las propiedades de resistencia analizadas previamente, la elongación está asociada al comportamiento dúctil del material, por lo que su relación con la composición química y otras propiedades puede ser más compleja.

En la primera configuración, los modelos Random Forest, XG Boost y red neuronal mostraron un desempeño moderado, alcanzando coeficientes de determinación  $R^2$  de entre 0.59 y 0.61, con valores de RMSE cercanos a 5 unidades de elongación.

|                      | $R^2$  | MAPE    | MAE    | RMSE   |
|----------------------|--------|---------|--------|--------|
| <b>Random forest</b> | 0.5929 | 28.1018 | 3.7291 | 5.1238 |
| <b>XG Boost</b>      | 0.5954 | 28.2126 | 3.6893 | 5.1081 |
| <b>Red neuronal</b>  | 0.6148 | 27.4605 | 3.5353 | 4.9836 |

Tabla 12. Resultados de A5 para la primera configuración

Con la segunda configuración se obtuvieron mejores resultados en los tres modelos de valores de  $R^2$  de entre 0.85 y 0.86 respectivamente. También se redujeron de manera considerable los errores de predicción, con RMSE menor a 4 unidades y con un MAPE menor a 22%.

|                      | $R^2$  | MAPE    | MAE    | RMSE   |
|----------------------|--------|---------|--------|--------|
| <b>Random forest</b> | 0.8590 | 17.1835 | 2.2868 | 3.0148 |
| <b>XG Boost</b>      | 0.8625 | 17.5771 | 2.2981 | 2.9771 |
| <b>Red neuronal</b>  | 0.8014 | 21.1313 | 2.6768 | 3.5784 |

Tabla 13. Resultados de A5 para la segunda configuración

En la tercera configuración, los tres modelos volvieron a mostrar un desempeño moderado, con valores de  $R^2$  de entre 0.52 y 0.61, y errores de predicción ligeramente superiores a los del segundo intento.

|                      | $R^2$  | MAPE    | MAE    | RMSE   |
|----------------------|--------|---------|--------|--------|
| <b>Random forest</b> | 0.5974 | 28.0112 | 3.7179 | 5.0954 |
| <b>XG Boost</b>      | 0.6182 | 27.2497 | 3.5748 | 4.9620 |
| <b>Red neuronal</b>  | 0.5293 | 29.4511 | 4.0443 | 5.5092 |

Tabla 14. Resultados de A5 para la tercera configuración

En general, los resultados muestran que predecir la deformación es más difícil que predecir las propiedades de resistencia estudiadas anteriormente. Sin embargo, la inclusión de la dureza Brinell como variable de entrada permitió mejorar sustancialmente la capacidad predictiva de los modelos XG Boost y Red Neuronal, lo que sugiere que las propiedades relacionadas con la resistencia del material pueden aportar información relevante para estimar su comportamiento dúctil. De entre las configuraciones estudiadas, el segundo intento obtuvo el mejor comportamiento global en la predicción de la elongación.

#### 4.4.4 E - Módulo de elasticidad y G - módulo de corte

La predicción del módulo de elasticidad (E) y el módulo de corte (G) se realizó únicamente mediante el empleo de la segunda configuración de variables de entrada, la cual incluye los elementos de composición química (C, Mn, P, S, Si, Ni, Cr, Mo y Fe), así como el tratamiento térmico, la dureza Brinell (Bhn) y la densidad (Ro). Esta configuración fue elegida porque previamente había dado el mejor desempeño para predecir otras propiedades mecánicas, como la resistencia última a la tracción y el límite elástico.

Por un lado, los resultados de las métricas tradicionales de evaluación mostraron un desempeño limitado de la capacidad predictiva de los modelos. Los valores de  $R^2$  para el módulo de elasticidad fueron cercanos a 0.32 para los modelos Random Forest y XG Boost, mientras que la red neuronal tuvo un valor negativo de  $R^2$  (-1.365), lo que sugiere que el modelo no pudo capturar adecuadamente la relación entre las variables de entrada y esta propiedad. Un comportamiento análogo fue observado en la predicción del módulo de corte, donde los valores de  $R^2$  fueron aún menores (0.2676 para Random Forest y 0.1934 para XG Boost), mientras que la red neuronal nuevamente arrojó un valor negativo (-2.1069). Estos resultados indican que las variables estudiadas no explican de forma adecuada la variabilidad de estas propiedades elásticas cuando se evalúan con las métricas convencionales.

|                      | <b>R<sup>2</sup></b> | <b>MAPE</b> | <b>MAE</b> | <b>RMSE</b> |
|----------------------|----------------------|-------------|------------|-------------|
| <b>Random forest</b> | 0.3036               | 1.0371      | 2162.65    | 3653.0961   |
| <b>XG Boost</b>      | 0.3169               | 0.9906      | 2061.59    | 3617.92     |
| <b>Red neuronal</b>  | -3.6617              | 2.7701      | 5751.25    | 9451.75     |

Tabla 15. Resultados de E para la segunda configuración

|                      | <b>R<sup>2</sup></b> | <b>MAPE</b> | <b>MAE</b> | <b>RMSE</b> |
|----------------------|----------------------|-------------|------------|-------------|
| <b>Random forest</b> | 0.2656               | 1.2112      | 974.4444   | 1.5433      |
| <b>XG Boost</b>      | 0.1934               | 1.1904      | 0.9588     | 1.6197      |
| <b>Red neuronal</b>  | -1.6589              | 2.3244      | 1857.0183  | 2940.8961   |

Tabla 16. Resultados de G para la segunda configuración

Desde el punto de vista físico, este comportamiento puede explicarse, ya que tanto el módulo de elasticidad como el módulo de corte son propiedades determinadas fundamentalmente por la naturaleza del enlace atómico y la estructura cristalina del material. Para los aceros, estas propiedades exhiben una variabilidad relativamente baja entre las distintas aleaciones, lo cual restringe la habilidad de los modelos de aprendizaje automático para descubrir patrones importantes en los datos.

Debido a estas limitaciones, se realizó una evaluación adicional utilizando la ecuación del error porcentual, con el fin de analizar la precisión real de las predicciones realizadas por los modelos.

$$E\% = \frac{|Valor\ medido - valor\ real|}{valor\ real} * 100$$

Con este criterio los resultados obtenidos fueron bastante más favorables. En cuanto al módulo de elasticidad, los errores porcentuales se ubicaron en torno al 1 % para los modelos Random Forest (1,025 %) y XG Boost (0,992 %), mientras que la red neuronal presentó un error mayor de aproximadamente el 3,5 %. Los errores porcentuales para el módulo de corte también fueron bajos, con valores cercanos al 1.2% para Random Forest y XG Boost, y cerca del 3.1% para la red neuronal.

|                      | <b>E% para E</b> | <b>E% para G</b> |
|----------------------|------------------|------------------|
| <b>Random forest</b> | 1.025            | 1.203            |

|                     |       |       |
|---------------------|-------|-------|
| <b>XG Boost</b>     | 0.992 | 1.186 |
| <b>Red neuronal</b> | 3.525 | 3.124 |

Tabla 17. Resultados de la ecuación error configuración

#### 4.4.5 Validación cruzada

La validación cruzada se llevó a cabo para cada una de las propiedades mecánicas en cada uno de los modelos aplicados. Este procedimiento permitió entrenar y evaluar cada modelo sobre diferentes subconjuntos del conjunto de entrenamiento, obteniendo como resultado el valor promedio del coeficiente de determinación ( $R^2$ ) y su desviación estándar.

Para la resistencia última a la tracción ( $S_u$ ) se obtuvieron los siguientes resultados:

|                      | <b><math>R^2</math></b> | <b>Promedio</b> | <b>Desviación</b> |
|----------------------|-------------------------|-----------------|-------------------|
| <b>Random forest</b> | 0.9397                  | 0.9351          | 0.0328            |
| <b>XG Boost</b>      | 0.9193                  | 0.9417          | 0.0228            |
| <b>Red neuronal</b>  | 0.9073                  | 0.8958          | 0.0772            |

Tabla 18. Validación cruzada de  $S_u$

Los resultados para el Random Forest indican que el modelo mantuvo un desempeño consistente entre las diferentes particiones de la validación cruzada, evidenciando una baja variabilidad entre los subconjuntos evaluados. En el caso del modelo XGBoost, se puede observar que el promedio es el valor más alto entre los tres modelos empleados para esta propiedad y la desviación estándar refleja una estabilidad elevada durante el proceso de validación. Por último, aunque el desempeño general fue satisfactorio para la Red Neuronal, la variabilidad entre las diferentes particiones fue superior a la observada en los modelos basados en árboles.

Para el límite elástico ( $S_y$ ) se obtuvieron los siguientes resultados:

|                      | <b><math>R^2</math></b> | <b>Promedio</b> | <b>Desviación</b> |
|----------------------|-------------------------|-----------------|-------------------|
| <b>Random forest</b> | 0.9453                  | 0.9162          | 0.0396            |
| <b>XG Boost</b>      | 0.9154                  | 0.9159          | 0.0186            |
| <b>Red neuronal</b>  | 0.8803                  | 0.9007          | 0.0485            |

Tabla 19. Validación cruzada de  $S_y$

Los valores para el modelo Random Forest indican una gran estabilidad en los resultados obtenidos durante las diferentes iteraciones de la validación cruzada. Por otro lado, los resultados para el modelo XGBoost muestran un comportamiento muy similar al obtenido por Random Forest. Por su parte, la Red Neuronal artificial mostró una ligera disminución del desempeño respecto a los modelos de árboles, aunque manteniendo una capacidad predictiva elevada.

Para la elongación (A5) se obtuvieron los siguientes resultados:

|                      | <b>R<sup>2</sup></b> | <b>Promedio</b> | <b>Desviación</b> |
|----------------------|----------------------|-----------------|-------------------|
| <b>Random forest</b> | 0.8590               | 0.8350          | 0.0528            |
| <b>XG Boost</b>      | 0.8625               | 0.8295          | 0.0420            |
| <b>Red neuronal</b>  | 0.8014               | 0.8087          | 0.0428            |

Tabla 20. Validación cruzada de A5

Para la propiedad de elongación, el modelo Random Forest este resultado indica un desempeño adecuado y una alta consistencia entre las distintas particiones del conjunto de entrenamiento. Los valores para el modelo XGBoost evidenciaron un comportamiento relativamente estable durante el proceso de validación. La Red Neuronal artificial presentó un desempeño ligeramente inferior al de los otros modelos.

Para el módulo de elasticidad (E) se obtuvieron los siguientes resultados:

|                      | <b>R<sup>2</sup></b> | <b>Promedio</b> | <b>Desviación</b> |
|----------------------|----------------------|-----------------|-------------------|
| <b>Random forest</b> | 0.3036               | 0.3344          | 0.0574            |
| <b>XG Boost</b>      | 0.3169               | 0.3315          | 0.1446            |
| <b>Red neuronal</b>  | -3.6617              | -30.2697        | 35.5038           |

Tabla 21. Validación cruzada de E

Los resultados obtenidos para el módulo de elasticidad fueron considerablemente inferiores a los alcanzados para las propiedades de resistencia y ductilidad. En el caso del XGBoost, se observó que hay una mayor variabilidad entre las diferentes particiones del conjunto de datos con respecto al Random Forest. Por otro lado, en el caso de la red neuronal, el desempeño fue considerablemente inferior, lo que puede denotar que durante el entrenamiento se generaron advertencias de convergencia, indicando que el algoritmo no logró alcanzar la convergencia dentro del número máximo de iteraciones establecido.

Para el módulo de corte (G) se obtuvieron los siguientes resultados:

|                      | <b>R<sup>2</sup></b> | <b>Promedio</b> | <b>Desviación</b> |
|----------------------|----------------------|-----------------|-------------------|
| <b>Random forest</b> | 0.2656               | 0.3248          | 0.0494            |
| <b>XG Boost</b>      | 0.1934               | 0.3018          | 0.0826            |
| <b>Red neuronal</b>  | -1.6589              | -25.2345        | 30.4072           |

Tabla 22. Validación cruzada de G

Para la predicción del módulo de corte, se encuentran resultados constantes entre las distintas particiones. Para el XGBoost se evidenció una variabilidad moderada durante el proceso de validación. Por último, se encontró que al igual que en el módulo de elasticidad, se presentaron advertencias de convergencia durante el entrenamiento, indicando dificultades en el proceso de optimización de la red.

## 4.5 Casos de prueba

Con el fin de evaluar la aplicabilidad práctica de los modelos desarrollados, se implementaron dos casos de prueba interactivos en el cual el usuario puede ingresar manualmente las variables de entrada correspondientes a un acero específico. Estas variables son exactamente las mismas que se saurón para la predicción de los modelos la cual corresponde a la composición química (C, Mn, P, S, Si, Ni, Cr, Mo y Fe), la dureza Brinell (Bhn), la densidad (Ro) y el tratamiento térmico (HT). A partir de estos datos, el sistema genera como salida la predicción de las principales propiedades mecánicas las cuales corresponden a la resistencia última a la tracción (Su), límite elástico (Sy), elongación (A5), módulo de elasticidad (E) y módulo de corte (G). Es importante señalar que los aceros empleados en los casos de prueba no estaban presentes en el dataset original utilizado para entrenar los modelos, por lo que las predicciones realizadas corresponden a nuevas combinaciones de características. Este ejercicio permite simular un escenario real de uso y analizar la capacidad de los modelos para apoyar procesos de diseño y selección de materiales.

### 4.5.1 Primer caso de prueba

Como primer caso de prueba se utilizó el acero AISI 316, cuyas propiedades de entrada fueron definidas de acuerdo con valores típicos reportados en la literatura (Padilla, 1999) de la siguiente manera: C=0.08, Mn=2, P=0.045, S=0.03, Si=1, Ni=12, Cr=17, Mo=2, Fe=65.845, Bhn=175, Ro=8000 y tratamiento térmico “*Annealed*”. A partir de estos datos de entrada, el modelo generó predicciones para las propiedades mecánicas, las cuales fueron comparadas con los valores teóricos de referencia.

|  | <b>Valores teóricos</b> | <b>Valores predichos</b> | <b>E% individual</b> | <b>E % general</b> |
|--|-------------------------|--------------------------|----------------------|--------------------|
|--|-------------------------|--------------------------|----------------------|--------------------|

|           |           |           |         |          |
|-----------|-----------|-----------|---------|----------|
| <b>Su</b> | 515 - 620 | 563.53    | 0 %     | 10.568 % |
| <b>Sy</b> | 205 - 290 | 358.17    | 22.24 % |          |
| <b>A5</b> | 40%       | 20.86%    | 20.79 % |          |
| <b>E</b>  | 193000    | 206103.16 | 6.79 %  |          |
| <b>G</b>  | 77000     | 79331.16  | 3.02 %  |          |

Tabla 23. Caso de prueba 1

#### 4.5.2 Segundo caso de prueba

Como segundo caso de prueba se utilizó el acero AISI D2, cuyas propiedades de entrada fueron definidas de acuerdo con valores típicos reportados en la literatura (Illanes, 2010) de la siguiente manera: C=1.6, Mn=0.6, P=0.03, S=0.03, Si=0.5, Ni=0, Cr=13, Mo=1.2, Fe=82.54, Bhn=650, Ro=7700 y tratamiento térmico “*Quenched and tempered*”. A partir de estos datos de entrada, el modelo generó predicciones para las propiedades mecánicas, las cuales fueron comparadas con los valores teóricos de referencia.

|    | Valores teóricos | Valores predichos | E% individual | E % general |
|----|------------------|-------------------|---------------|-------------|
| Su | 1900 - 2200      | 2086.19           | 0 %           | 2.216 %     |
| Sy | 1600 - 1900      | 1756.10           | 0 %           |             |
| A5 | 1 - 5            | 5.44              | 8.80 %        |             |
| E  | 210000           | 209409.16         | 0.28 %        |             |
| G  | 80000            | 81603.38          | 2 %           |             |

Tabla 24. Caso de prueba 2



## 5 Análisis de resultados

Los hallazgos de este estudio posibilitan examinar el rendimiento de diversos modelos de aprendizaje automático en la predicción de las propiedades mecánicas del acero, basándose en su composición química, características físicas y variables vinculadas con el procesamiento del material. Para esta investigación se llevó a cabo una evaluación de varias configuraciones de variables de entrada durante todos los experimentos, con el objetivo de determinar cuáles contribuyen en mayor medida a la estimación de propiedades como la elongación (A5), la resistencia última a la tracción (Su), el límite elástico (Sy), el módulo de elasticidad (E) y el módulo de corte (G). La comparación de modelos y configuraciones permitió la detección de patrones significativos sobre cómo las variables elegidas influyen en el comportamiento de los algoritmos ante distintos tipos de propiedades mecánicas y también permitió determinar el mejor modelo para cada propiedad mecánica evaluada.

En este contexto, la discusión se enfoca en analizar los resultados obtenidos teniendo como foco el objetivo principal, el cual se centra, en pocas palabras, en desarrollar un modelo apto para predecir las propiedades mecánicas de aceros basándose en datos en su mayoría de composición química, disminuyendo así la necesidad de pruebas experimentales convencionales con el ánimo de reducir costos. Así pues, en esta sección se examinan las diferencias encontradas entre los modelos, el efecto de añadir variables extra como la dureza o las propiedades elásticas y también las restricciones halladas al predecir determinadas características. Finalmente, este análisis permite comprender tanto el rendimiento de los modelos como su comportamiento mecánico de las diferentes composiciones, aportando elementos para la optimización del diseño y selección de aceros mediante herramientas basadas en datos.

### 5.1 Configuraciones y métricas

En términos generales, los resultados obtenidos evidencian que la configuración que presentó el mejor desempeño en todas las propiedades mecánicas evaluadas fue la segunda, la cual corresponde a las siguientes variables de entrada:

- **C:** Carbono
- **Mn:** Manganese
- **P:** Fósforo
- **S:** Azufre
- **Si:** Silicio
- **Ni:** Níquel
- **Cr:** Cromo
- **Mo:** Molibdeno
- **Fe:** Hierro
- **HT:** Tratamiento térmico
- **Bhn:** Dureza Brinell
- **Ro:** Densidad

En el caso de la resistencia última a la tracción (Su) y el límite elástico (Sy), esta configuración permitió alcanzar los valores más altos de  $R^2$  y los menores errores MAE y RMSE, lo cual indica una alta capacidad predictiva de los modelos. Este comportamiento se demuestra gracias a la fuerte relación que existe entre la dureza y las propiedades de resistencia del material como se muestra en la matriz de correlación en la figura 8, ya que ambas están asociadas a la capacidad del acero para resistir la deformación plástica. La inclusión de la dureza brinell (Bhn) aportó información clave

sobre el estado microestructural del material, permitiendo a los modelos capturar de manera más precisa las relaciones entre las variables.

De manera similar ocurre para la elongación (A5), aunque la predicción resultó más compleja debido a la naturaleza dúctil de esta propiedad, la segunda configuración también mostró el mejor desempeño, especialmente en modelos como XG Boost y la red neuronal. Esto sugiere que la dureza no solo está relacionada con la resistencia, sino que también aporta información indirecta sobre la ductilidad del material.

Por otro lado, los resultados de las métricas tradicionales del módulo de elasticidad (E) y el módulo de corte (G) mostraron valores anormales, particularmente el coeficiente de determinación ( $R^2$ ) obtuvo valores muy bajos o incluso negativos, lo cual lo hace objeto de profundización ya que a primera vista se podría interpretar que como un pésimo desempeño de cada uno de los modelos. Sin embargo, ese primer vistazo es errado puesto que este resultado se explica principalmente por la baja variabilidad de estas propiedades dentro del conjunto de datos.

A diferencia de propiedades como la resistencia última a la tracción ( $S_u$ ) o el límite elástico ( $S_y$ ), que pueden variar ampliamente dependiendo de la composición, el tratamiento térmico y la microestructura, los módulos elásticos de los aceros presentan valores relativamente constantes, ya que dependen principalmente de la estructura cristalina y de la rigidez de los enlaces atómicos del hierro, factores que cambian muy poco entre diferentes aleaciones de acero. En contextos donde la variable objetivo tiene una dispersión muy reducida, métricas como  $R^2$  se vuelven poco representativas, ya que incluso pequeñas desviaciones entre los valores predichos y los reales pueden generar una gran penalización estadística. Esto ocurre porque el  $R^2$  compara el error del modelo con la varianza total de los datos; cuando dicha varianza es pequeña, cualquier error absoluto se vuelve relativamente grande en términos estadísticos, produciendo valores bajos o negativos. No obstante, al evaluar los resultados mediante error porcentual, se observó que las predicciones presentan desviaciones cercanas al 1% para los modelos Random Forest y XG Boost y cercanas al 3% para Redes Neuronales, lo cual indica que, en términos prácticos, las estimaciones son bastante precisas. Por lo tanto, las métricas aparentemente desfavorables no reflejan una incapacidad real del modelo para predecir estas propiedades, sino una limitación de las métricas utilizadas cuando se aplican a variables con baja variabilidad.

## **5.2 Desempeño de los modelos para cada propiedad**

A partir de la comparación de resultados obtenidos, fue posible identificar que el desempeño de los modelos varía según la naturaleza de la propiedad mecánica a predecir, lo cual está directamente relacionado con el tipo de relaciones presentes en los datos.

En el caso de la resistencia última a la tracción ( $S_u$ ) y el límite elástico ( $S_y$ ), el modelo que presentó el mejor desempeño fue Random Forest. Esto se debe a que estas propiedades tienen una fuerte

dependencia de variables como la dureza y la composición química, las cuales presentan relaciones no lineales pero relativamente estructuradas. Random Forest, al estar basado en múltiples árboles de decisión, es eficiente para capturar este tipo de relaciones sin necesidad de supuestos previos sobre la distribución de los datos. Además, su capacidad para manejar interacciones entre variables y su robustez frente a outliers le permiten adaptarse bien a la variabilidad presente en propiedades de resistencia, donde existen tanto aceros convencionales como de alta resistencia dentro del mismo conjunto de datos.

Ahora bien, para la elongación (A5), el mejor desempeño se obtuvo con XG Boost. Esta propiedad está asociada a la ductilidad del material y presenta una relación más compleja y menos directa con las variables de entrada, ya que depende de múltiples factores microestructurales que no están completamente representados en el dataset. XG Boost, al ser un modelo de boosting, construye los árboles de manera secuencial corrigiendo los errores del modelo anterior, lo que le permite capturar patrones más sutiles y complejos. Por otro lado, se obtuvo un error extremadamente alto en la predicción de A5 con el modelo Random Forest. Esto puede explicarse porque Random Forest, al promediar múltiples árboles, tiende a suavizar las predicciones y puede perder sensibilidad frente a relaciones más complejas o dispersas como las que presenta la elongación. Además, la presencia de mayor ruido y variabilidad en esta propiedad puede generar que los árboles individuales produzcan predicciones muy distintas, lo que al combinarse en el modelo final puede generar resultados inestables.

Para el módulo de elasticidad (E) y el módulo de corte (G), el mejor desempeño se obtuvo con XG Boost. Aunque estas propiedades presentan baja variabilidad, el modelo de boosting demostró una mejor capacidad para ajustar pequeñas diferencias entre los valores reales y predichos. XG Boost optimiza iterativamente los errores residuales, lo que le permite refinar las predicciones incluso cuando las variaciones en los datos son mínimas. Esto resulta útil para propiedades elásticas, donde pequeñas desviaciones pueden ser significativas desde el punto de vista estadístico, pero no necesariamente desde el punto de vista físico. En este contexto, XG Boost logró capturar de manera más precisa estas variaciones sutiles, superando a los otros modelos evaluados.

Los resultados obtenidos mediante la validación cruzada permitieron confirmar la estabilidad y capacidad de generalización de los modelos desarrollados para la predicción de las propiedades mecánicas de los aceros. En términos generales, la segunda configuración de variables, que incorporó la dureza Brinell y la densidad junto con la composición química, presentó el mejor desempeño en prácticamente todas las propiedades evaluadas. Los valores promedio de  $R^2$  obtenidos durante la validación cruzada fueron consistentes con los resultados del conjunto de prueba, lo que indica que los modelos no se ajustaron excesivamente a los datos de entrenamiento y mantuvieron una adecuada capacidad predictiva ante datos no observados.

Profundizando los resultados de la validación cruzada, para las propiedades de resistencia última a la tracción ( $S_u$ ) y límite elástico ( $S_y$ ), el algoritmo Random Forest obtuvo los resultados más

sólidos, alcanzando los mayores coeficientes de determinación y los menores errores promedio, evidenciando una elevada capacidad para capturar las relaciones no lineales entre la composición química, el tratamiento térmico y las propiedades mecánicas. En el caso de la elongación (A5), la validación cruzada confirmó que XGBoost fue el modelo más robusto, especialmente en la segunda configuración, donde se alcanzaron valores de  $R^2$  cercanos a 0.86 y reducciones importantes en las métricas de error.

Por otra parte, las predicciones del módulo de elasticidad (E) y del módulo de corte (G) presentaron valores bajos de  $R^2$  durante la validación cruzada, lo que inicialmente podría interpretarse como un bajo desempeño del modelo. Sin embargo, los errores porcentuales obtenidos fueron inferiores al 2% para los mejores modelos, evidenciando que las pequeñas variaciones naturales de estas propiedades dificultan la interpretación del coeficiente de determinación. En consecuencia, la validación cruzada permitió demostrar que los modelos desarrollados presentan un comportamiento estable y reproducible, respaldando la capacidad predictiva de la metodología propuesta y su potencial aplicación en la estimación de propiedades mecánicas de aceros sin recurrir exclusivamente a ensayos experimentales.

### 5.3 Casos de prueba

Los resultados muestran que el modelo logra una aproximación adecuada en la mayoría de las propiedades. El desarrollo de las pruebas de los aceros ASI 316 y D2 permitió evaluar la capacidad de respuesta del modelo frente a materiales con comportamientos mecánicos significativamente distintos.

Para el primer caso correspondiente a AISI 316, se observa que el modelo logra una buena aproximación en la mayoría de las propiedades, especialmente en la resistencia última ( $S_u$ ), donde la predicción se encuentra dentro del rango teórico esperado. En el módulo de elasticidad (E) y el módulo de corte (G), obtuvieron errores relativamente bajos. Sin embargo, se presentan desviaciones más notables en el límite elástico ( $S_y$ ) y la elongación (A5), con errores cercanos al 20%, lo cual es consistente con lo observado previamente en los resultados del modelo, donde estas propiedades dependen en mayor medida de características microestructurales no incluidas explícitamente en las variables de entrada. A pesar de ello, el error general del caso se mantiene en un valor aceptable del 10.568%, lo que indica un desempeño global adecuado.

En el segundo caso de prueba correspondiente al acero D2, el modelo presenta un comportamiento aún más preciso, evidenciado en un error general considerablemente bajo del 2.216%. Las predicciones de  $S_u$  y  $S_y$  se encuentran dentro de los rangos teóricos, con errores prácticamente nulos, lo que demuestra la capacidad del modelo para capturar adecuadamente el comportamiento de aceros de alta resistencia. Asimismo, los errores en las propiedades restantes como A5, E y G son bajos, destacándose especialmente el módulo de elasticidad con un error inferior al 1%. Estos

resultados sugieren que el modelo tiene una mejor capacidad de predicción en materiales con comportamientos más definidos o representados en el conjunto de entrenamiento. En conjunto, ambos casos de prueba confirman que el modelo es capaz de generar predicciones confiables, con mayor precisión en propiedades de resistencia y propiedades elásticas, y con ciertas limitaciones en la estimación de la ductilidad.

## 5.4 Oportunidades de mejora y trabajo a futuro

Si bien los resultados obtenidos demuestran que la metodología propuesta constituye una alternativa viable para la predicción de propiedades mecánicas de aceros mediante técnicas de aprendizaje automático, existen diversas oportunidades de mejora que permitirían incrementar la precisión, robustez y aplicabilidad de los modelos desarrollados.

Una de las principales líneas de trabajo a futuro consiste en incorporar variables microestructurales dentro del conjunto de datos, especialmente el tamaño de grano, así como otras características derivadas de la microestructura, como la fracción de fases (ferrita, perlita, bainita o martensita) y la presencia de precipitados. Estas variables tienen una influencia directa sobre el comportamiento mecánico de los aceros y permitirían a los modelos capturar fenómenos metalúrgicos que no pueden ser explicados únicamente mediante la composición química y el tratamiento térmico. Su inclusión podría mejorar significativamente la capacidad predictiva, particularmente para propiedades como la elongación, el límite elástico y los módulos elásticos, cuya respuesta depende en gran medida de la microestructura final del material.

Otra mejora importante consiste en incorporar intervalos de confianza o estimaciones de incertidumbre en las predicciones realizadas por el modelo. En la presente investigación, cada caso de prueba proporciona un único valor estimado para cada propiedad mecánica, sin embargo, desde un punto de vista ingenieril resulta igualmente importante conocer el grado de confianza asociado a cada predicción. La implementación de técnicas como *Quantile Regression Forests*, *Bootstrap*, *Conformal Prediction* o métodos bayesianos permitiría generar intervalos de confianza que indique el rango dentro del cual es probable que se encuentre el valor real de la propiedad mecánica. Esta información aumentaría la confiabilidad del modelo y facilitaría su utilización como herramienta de apoyo en procesos de diseño y selección de materiales.

Asimismo, se propone realizar una validación experimental mediante ensayos físicos sobre diferentes aleaciones de acero. Para ello, sería necesario seleccionar materiales con composiciones químicas y tratamientos térmicos conocidos que no estén incluidos dentro del dataset original, obtener las predicciones del modelo y posteriormente comparar dichos resultados con los valores obtenidos mediante ensayos normalizados de laboratorio, como pruebas de tracción, dureza y caracterización mecánica. Esta validación permitiría cuantificar el desempeño del modelo en

condiciones reales de operación, establecer sus límites de aplicación y determinar su viabilidad como herramienta de apoyo para la industria y la investigación en ingeniería de materiales.

Otra línea de investigación consiste en ampliar y diversificar el conjunto de datos empleado para el entrenamiento de los modelos. La incorporación de nuevas bases de datos experimentales provenientes de diferentes fabricantes, laboratorios o publicaciones científicas permitiría aumentar la representatividad del conjunto de entrenamiento y mejorar la capacidad de generalización de los modelos frente a aceros con composiciones y tratamientos térmicos no contemplados inicialmente. De igual forma, sería conveniente fortalecer la metodología de generación de datos sintéticos incorporando información adicional proveniente de diagramas de fases, simulaciones metalúrgicas o modelos termodinámicos que permitan representar con mayor fidelidad las relaciones entre composición, procesamiento y propiedades mecánicas.

Finalmente, una línea de desarrollo con alto potencial consiste en evolucionar el prototipo implementado en Python hacia una herramienta computacional de apoyo para la ingeniería de materiales. Esta podría materializarse como una aplicación de escritorio, una plataforma web o una interfaz interactiva que permita a investigadores e ingenieros ingresar la composición química y el tratamiento térmico de un acero para obtener de forma inmediata la estimación de sus propiedades mecánicas, acompañadas de indicadores de incertidumbre y explicaciones sobre las variables que más influyen en la predicción.

## 6 Conclusiones

- El análisis y procesamiento del conjunto de datos permitió identificar las variables más relevantes en la predicción de las propiedades mecánicas de los aceros. Se evidenció que la composición química constituye una base importante para explicar el comportamiento del material, sin embargo, por sí sola resulta insuficiente para lograr predicciones de alta precisión. Por otro lado, la incorporación de variables como la dureza Brinell (Bhn) demostró ser determinante para el entrenamiento de los diferentes modelos. Asimismo, se confirmó que variables como el módulo de elasticidad y el coeficiente de Poisson presentan menor aporte predictivo por su poca dispersión.
- La implementación y comparación de diferentes modelos de aprendizaje automático permitió identificar el algoritmo más adecuado para cada propiedad mecánica. Se encontró que el modelo Random Forest presenta el mejor desempeño en la predicción de propiedades de resistencia como la resistencia última a la tracción ( $S_u$ ) y el límite elástico ( $S_y$ ), debido a su capacidad para capturar relaciones no lineales y manejar adecuadamente la variabilidad del dataset. Por su parte, el modelo XG Boost mostró un mejor desempeño en la predicción de propiedades más complejas o con mayor dispersión, como la elongación ( $A_5$ ), o en propiedades con poca dispersión como el módulo de elasticidad ( $E$ ) y el módulo de corte ( $G$ ). Estos resultados evidencian que no existe un único modelo óptimo para todas las propiedades y que adicionalmente, la selección del algoritmo depende de la naturaleza de la variable a predecir.
- La evaluación del desempeño de los modelos mediante métricas como  $R^2$ , MAE, RMSE y MAPE permitió validar su capacidad predictiva y analizar su aplicabilidad en contextos reales. Adicionalmente, la validación mediante los casos de prueba con el acero AISI 316 y AISI D2 permitieron comprobar la capacidad de generalización del modelo frente a nuevas combinaciones de entrada no utilizadas directamente en el entrenamiento. Para propiedades elásticas como el módulo de elasticidad ( $E$ ) y el módulo de corte ( $G$ ), aunque las métricas tradicionales no reflejaron un alto desempeño, el análisis mediante error porcentual y los casos de prueba demostraron que las predicciones son cercanas a los valores reales. Por otro lado, se identificaron mayores desviaciones en la predicción de la elongación ( $A_5$ ) y, en algunos casos, del límite elástico ( $S_y$ ), esto se atribuye a la influencia de factores microestructurales no incluidos en el modelo, lo que limita la precisión. No obstante los resultados globales obtenidos en ambos casos de prueba confirman que los modelos desarrollados tienen una adecuada capacidad de generalización y pueden ser utilizados como herramientas para la estimación de propiedades mecánicas.

## Bibliografía

- Zippo, V., Robotti, E., Maestri, D., Fossati, P., Valenza, D., Maggi, S., ... & Marengo, E. (2025). Development of a self-updating system for the prediction of steel mechanical properties in a steel company by machine learning procedures. *Technologies*, 13(2), 75.
- Xiong, J., Zhang, T., & Shi, S. (2020). Machine learning of mechanical properties of steels. *Science China Technological Sciences*, 63(7), 1247-1255.
- Peng, J., Yamamoto, Y., Hawk, J. A., Lara-Curzio, E., & Shin, D. (2020). Coupling physics in machine learning to predict properties of high-temperatures alloys. *npj Computational Materials*, 6(1), 141.
- Stoll, A., & Benner, P. (2021). Machine learning for material characterization with an application for predicting mechanical properties. *GAMM-Mitteilungen*, 44(1), e202100003.
- Cortina, V. G. (2015). Aplicación de la metodología crisp-dm a un proyecto de minería de datos en el entorno universitario. *Universidad Carlos III de Madrid*.
- Callister Jr, W. D., & Rethwisch, D. G. (2020). *Materials science and engineering: an introduction*. John wiley & sons.
- NB, K. B., Balaji, N. S., & Saikiran, A. (2025). Effect of nutrient-based alloying elements on biodegradable magnesium alloys: Evolution, challenges, and strategies for orthopaedic applications. *Biomedical Engineering Advances*, 9, 100161.
- Ghali, S. (2021). Development of Molybdenum Nickel Steel to Improve Mechanical Properties at High Temperature. *International Journal of Materials Technology and Innovation*, 1(2), 40-47.
- Kako, K., Kawakami, E., Ohta, J., & Mayuzumi, M. (2002). Effects of various alloying elements on tensile properties of high-purity Fe-18Cr-(14-16) Ni alloys at room temperature. *Materials transactions*, 43(2), 155-162.
- Dong, Y., Liu, D., Du, H., Sun, H., & Zuo, X. (2023). Effect of microstructure on the mechanical properties and corrosion resistance of a welded joint of 620-grade marine steel. *Frontiers in Materials*, 10, 1107125.
- Monsalve, A. (2023). Modelos constitutivos y predicción de propiedades mecánicas en aceros multifásicos. *Remetallica*, 37(25).
- Hougardy, H., Dahl, W., & Grabke, H. J. (2011). Steel, 5. Microstructures, Properties, and Adjustment of Properties. En *Ullmann's Encyclopedia of Industrial Chemistry*. John Wiley & Sons, Ltd. [https://doi.org/10.1002/14356007.o25\\_o04](https://doi.org/10.1002/14356007.o25_o04)
- Eisenhuettenleute (VDEh), V. D., & Duesseldorf (Germany). (1992). Steel. A handbook for materials research and engineering. Vol. 1. <https://inis.iaea.org/records/tv55w-5p402>
- Mataveeva, N. H., & Tolmachev, B. B. (2021). Engineering of reference materials for providing traceability of measurements of mechanical stresses by acoustic type of nondestructive check. Эталоны. Стандартные образцы, (4), 13–21.
- Gutiérrez Aguilera, P. A. (2023). Características del acero como material estructural. <https://doi.org/10.16925/gcnc.73>
- Fatemi, A. (2000). Mechanical Properties and Testing of Metallic Materials. En *Ullmann's Encyclopedia of Industrial Chemistry*. John Wiley & Sons, Ltd. [https://doi.org/10.1002/14356007.b01\\_10](https://doi.org/10.1002/14356007.b01_10)
- Gonzalez Espinosa, J. D., & Galvis Triana, D. O. (2017). Micromodelamiento mecánico del diagrama esfuerzo-deformación en un acero AISI 1045 templado desde temperaturas intercríticas.



- Pérez-Ruiz, E., Llano-Martínez, J., & Ravagli-Reyes, J. (2019). Estudio del grado de endurecimiento y resistencia al desgaste por deslizamiento del acero AISI 1045 endurecido por temple con refrigerante automotriz y para mecanizado. *Revista UIS Ingenierías*, 18(2), 113-120.
- Ali, F., Tan, A. S. C., & Wang, S. J. W. (2025). Can machine learning help accelerate article screening for systematic reviews? Yes, when article separability in embedding space is high. *Research Synthesis Methods*, 1-17.
- Janiesch, C., Zschech, P., & Heinrich, K. (2021). Machine learning and deep learning: C. Janiesch et al. *Electronic markets*, 31(3), 685-695.
- Wang, S. (2025). A Comprehensive Review of Machine Learning and Data Science Applications: From Fundamentals to Advanced Techniques. *Science and Technology of Engineering, Chemistry and Environmental Protection*, 1(2).
- GUSTAFSSON, F. Comparing Random Forest, XGBoost and Neural Networks With Hyperparameter Optimization by Nested Cross-Validation.
- Song, J. (2023, October). Comparison and analysis of accuracy of traditional random forest machine learning model and XGBoost model on music emotion classification dataset. In *Proceedings of the 2023 4th international conference on machine learning and computer application* (pp. 712-716).
- Dutta, P., Paul, S., & Kumar, A. (2021). Comparative analysis of various supervised machine learning techniques for diagnosis of COVID-19. In *Electronic devices, circuits, and systems for biomedical applications* (pp. 521-540). Academic Press.
- Chen, T., & Guestrin, C. (2016, August). Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd acm sigkdd international conference on knowledge discovery and data mining* (pp. 785-794).
- Onyebueke, A. E., David, A. A., & Munu, S. (2023). Network intrusion detection system using XGBoost and random forest algorithms. *Asian J. Pure Appl. Math*, 5(1), 321-335.
- Botchkarev, A. (2018). Evaluating performance of regression machine learning models using multiple error metrics in azure machine learning studio. *Available at SSRN 3177507*.
- Chicco, D., Warrens, M. J., & Jurman, G. (2021). The coefficient of determination R-squared is more informative than SMAPE, MAE, MAPE, MSE and RMSE in regression analysis evaluation. *Peerj computer science*, 7, e623.
- Shaheen, M., Presswood, R., & Afshan, S. (2022). Application of machine learning to predict the mechanical properties of high strength steel at elevated temperature. *ce/papers*, 5(4), 420-428.
- Frydrych, K., Karimi, K., Pecelerowicz, M., Alvarez, R., Dominguez-Gutiérrez, F. J., Rovaris, F., & Papanikolaou, S. (2021). Materials informatics for mechanical deformation: A review of applications and challenges. *Materials*, 14(19), 5764.
- Silvey, S., & Liu, J. (2024). Sample Size Requirements for Popular Classification Algorithms in Tabular Clinical Data: Empirical Study. *Journal of Medical Internet Research*, 26(1), e60231. <https://doi.org/10.2196/60231>
- Silvey, S., Amy, O., Tang, S., & Liu, J. (2026, enero 31). Sample size requirements for machine learning classification of binary outcomes in bulk RNA-Seq data | BMC Bioinformatics | Springer Nature Link.
- Chaires, J. M., Segura, J. Á., Serna Barquera, S. A., Ocampo, A. M., Cedillo, O. F., & Illianes, B. C. (2010). Evaluación de propiedades mecánicas de dos aceros grado herramienta AISI-O1, AISI-D2 y obtención de la concentración de esfuerzos en la geometría de mordazas de sujeción de especímenes compactos de tensión. *Superficies y vacío*, 23.

## Apéndices

Incluyo material suplementario alojado en un repositorio de GitHub. En este se encuentra el archivo .ipynb desarrollado durante la tesis y los datasets correspondientes.

- <https://github.com/mclau14/Tesis-Prediccion-de-propiedades-mecanicas-de-aceros>